KP08 反向傳播的加速變形

> 程度：大學三年級
>
> 圖型識別 | 第四章 §4.7

簡報閱讀與下載

學習目標

- 能說明狹長谷底為什麼讓梯度下降慢又來回擺。
- 能寫出動量的更新式，手算幾步，並說明它為什麼在平的方向加速、在陡的方向抵銷。
- 能說明自適應學習率與 quickprop 的規則，並知道它們各自的代價與限制。

KP08 反向傳播的加速變形

一句話重點：梯度下降在狹長谷底裡走得慢又來回擺；動量把上一步的 α 倍加進這一步，平的方向被放大、陡的方向被抵銷；自適應學習率讓 μ 自己調，quickprop 用兩次斜率直接估谷底。加速一律以複雜度為代價。

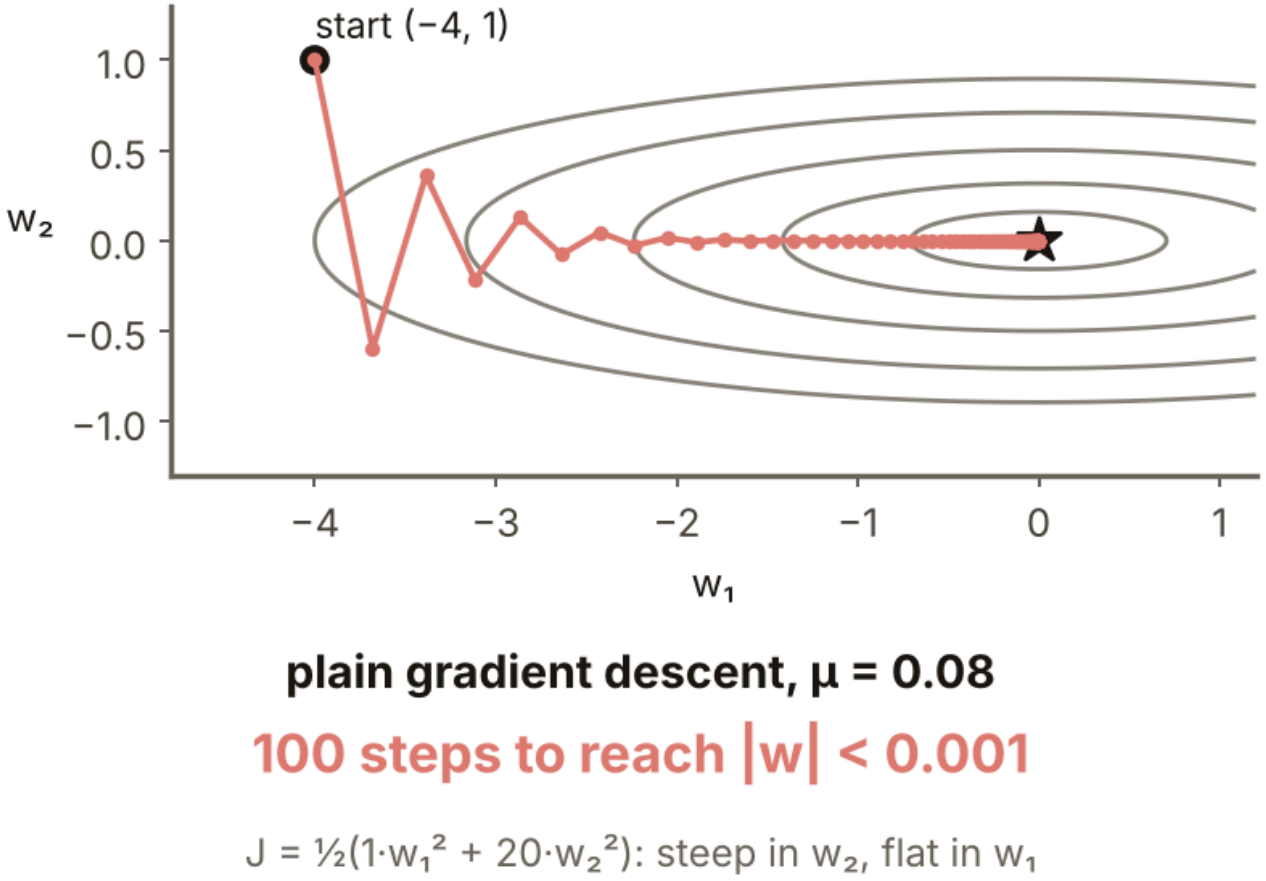
1. 狹長谷底

白話說明：KP07 的訓練動輒上千個 epoch，原因之一是梯度下降本身慢。

- **曲率**：代價面彎得多厲害。某個方向曲率大，沿那個方向走一小步，代價就變很多。
- **狹長谷底（病態代價面）**：一個方向曲率很大、另一個很小，等高線是很扁的橢圓；來源稱為 ill-conditioned，即 Hessian 的特徵值差距很大。

例子：本講義為了看清機制自行設計 $J = \frac{1}{2}(w_1^2 + 20w_2^2)$，$w_2$ 方向曲率 20，w_1 方向曲率 1，起點 $(-4, 1)$，$\mu = 0.08$。普通梯度下降走 100 步才到 $|w| < 0.001$，軌跡在 w_2 方向上下擺（程式計算）。

圖說 `lec05-kp08-valley`：等高線與普通梯度下降的軌跡。

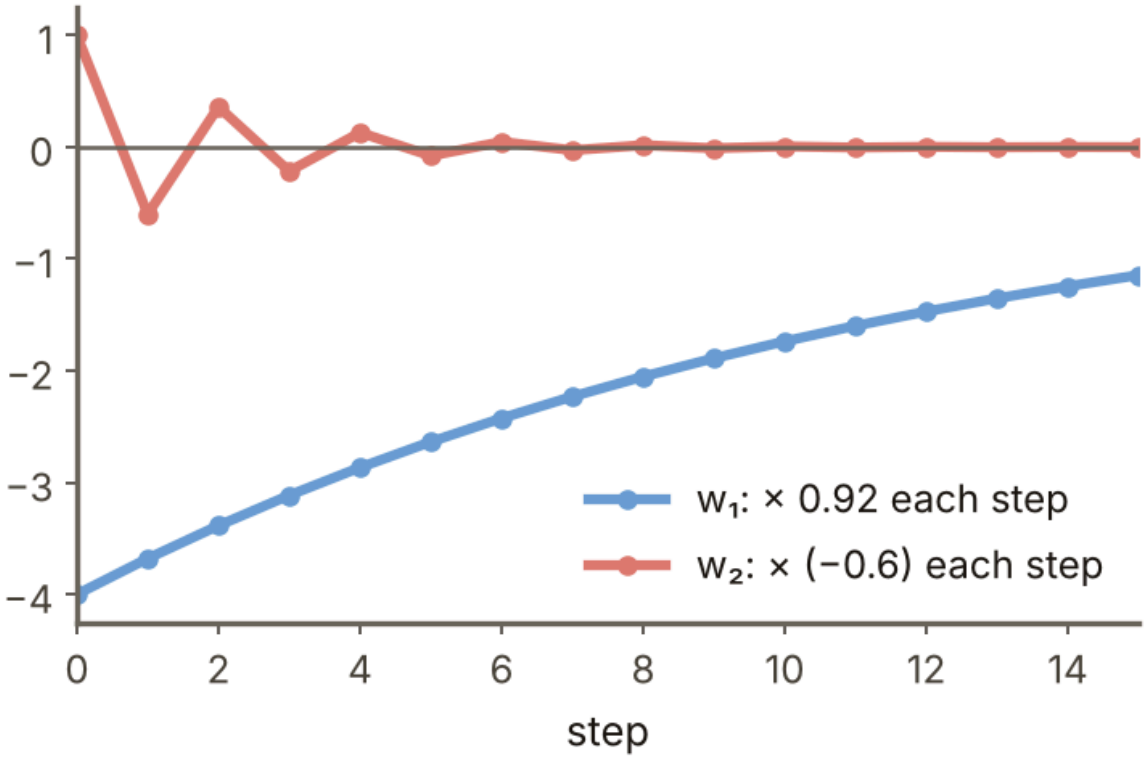


2. 為什麼來回擺

陡的方向：w_2 的梯度是 $20w_2$，更新 $w_2 \leftarrow w_2 - 0.08 \cdot 20\, w_2 = -0.6\, w_2$，每步變號、只縮到 0.6 倍。平的方向：$w_1 \leftarrow w_1 - 0.08 \cdot 1 \cdot w_1 = 0.92\, w_1$，同方向、每步只縮 8%。

兩難：μ 要小於 $2/20 = 0.1$，w_2 才不會越擺越大；$\mu = 0.12$ 時 60 步後 $|w|$ 已超過 10^8。但這麼小的步長讓 w_1 走得慢。

圖說 `lec05-kp08-zigzag`：前 15 步的 w_1 與 w_2。



1 − μ·20 = 1 − 0.08·20 = −0.6　1 − μ·1 = 0.92

μ must stay below 2/20 = 0.1 or w_2 blows up

3. 動量項

動量：讓更新帶著慣性，這一步除了本次的梯度步，還加上上一步的 α 倍。

正式定義：

$$\Delta w(t) = \alpha\, \Delta w(t-1) - \mu\, g(t),$$

g 是梯度，α 叫動量因子，實務上取 0.1 到 0.8；$\alpha = 0$ 就是普通梯度下降。

手算（$\mu = 0.08$、$\alpha = 0.6$）：第 1 步 $(0.32, -1.6)$，$w = (-3.68, -0.6)$；第 2 步 $0.6 \times (0.32, -1.6) - 0.08 \times (-3.68, -12) = (0.4864, 0)$，$w_2$ 的兩股力量（慣性 -0.96、梯度 $+0.96$）剛好抵銷。第 3 步 $(0.5473, 0.96)$，$w = (-2.646, 0.36)$。

圖說 `lec05-kp08-mom-steps`：動量前三步的表。

t	gradient g	Δw	w after
1	(−4.00, 20.0)	(0.3200, −1.60)	(−3.680, −0.60)
2	(−3.68, −12.0)	(0.4864, 0.00)	(−3.194, −0.60)
3	(−3.19, −12.0)	(0.5473, 0.96)	(−2.646, 0.36)

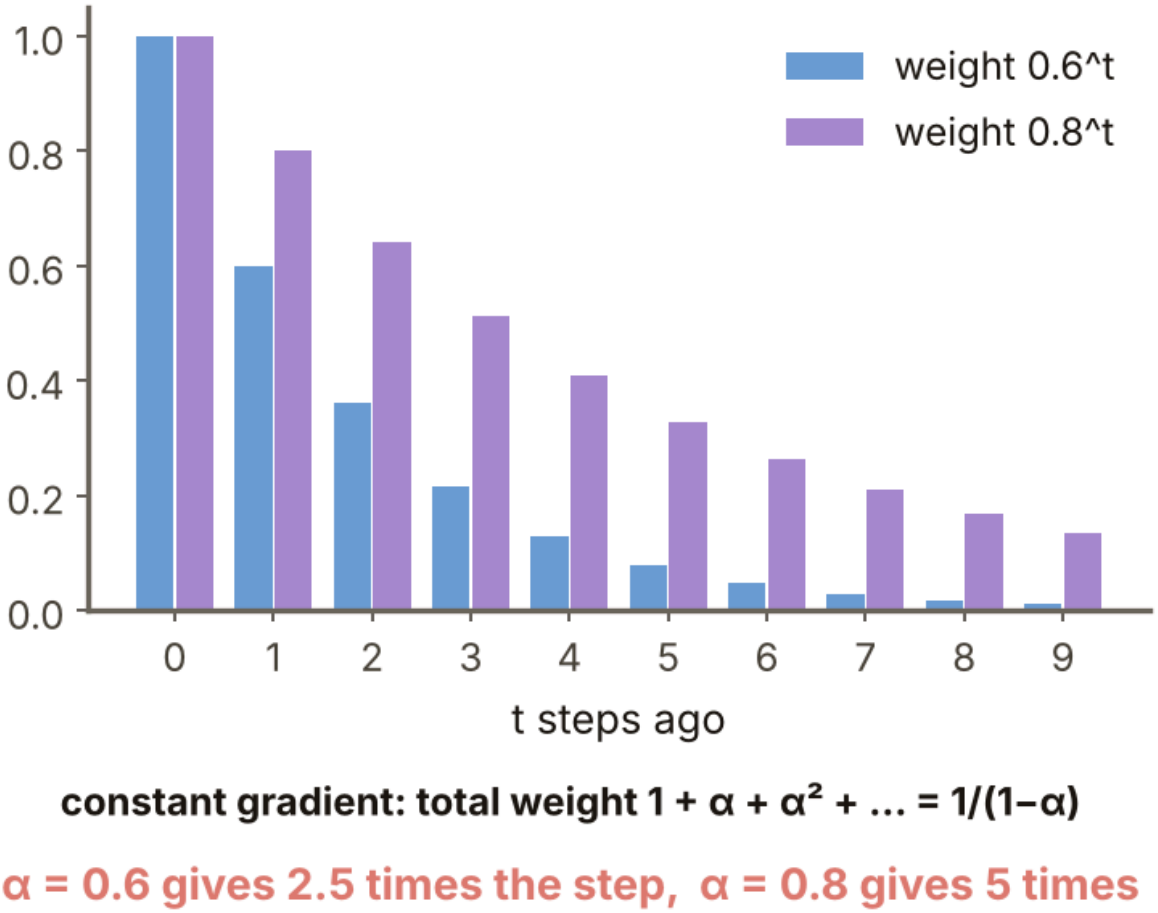
Δw(t) = 0.6·Δw(t−1) − 0.08·g(t), w starts at (−4, 1)

4. 為什麼有效：歷史梯度的指數加權平均

指數加權平均：最近的梯度權重最大，越久以前的每回合再乘 α 變小，權重是 $1, \alpha, \alpha^2, \ldots$。

展開 T 步：$\Delta w(T) = -\mu \sum_t \alpha^t g(T-t) + \alpha^T \Delta w(0)$，最後一項幾步就趨近 0。梯度不變（平的方向）時，總權重 $1 + \alpha + \alpha^2 + \cdots = 1/(1-\alpha)$，等於把學習率放大 $1/(1-\alpha)$ 倍：$\alpha = 0.6$ 是 2.5 倍，$\alpha = 0.8$ 是 5 倍（固定梯度跑 80 步驗證）。梯度正負交替（陡的方向）時，加權平均讓它們互相抵消。一個機制，該快時快、該穩時穩。

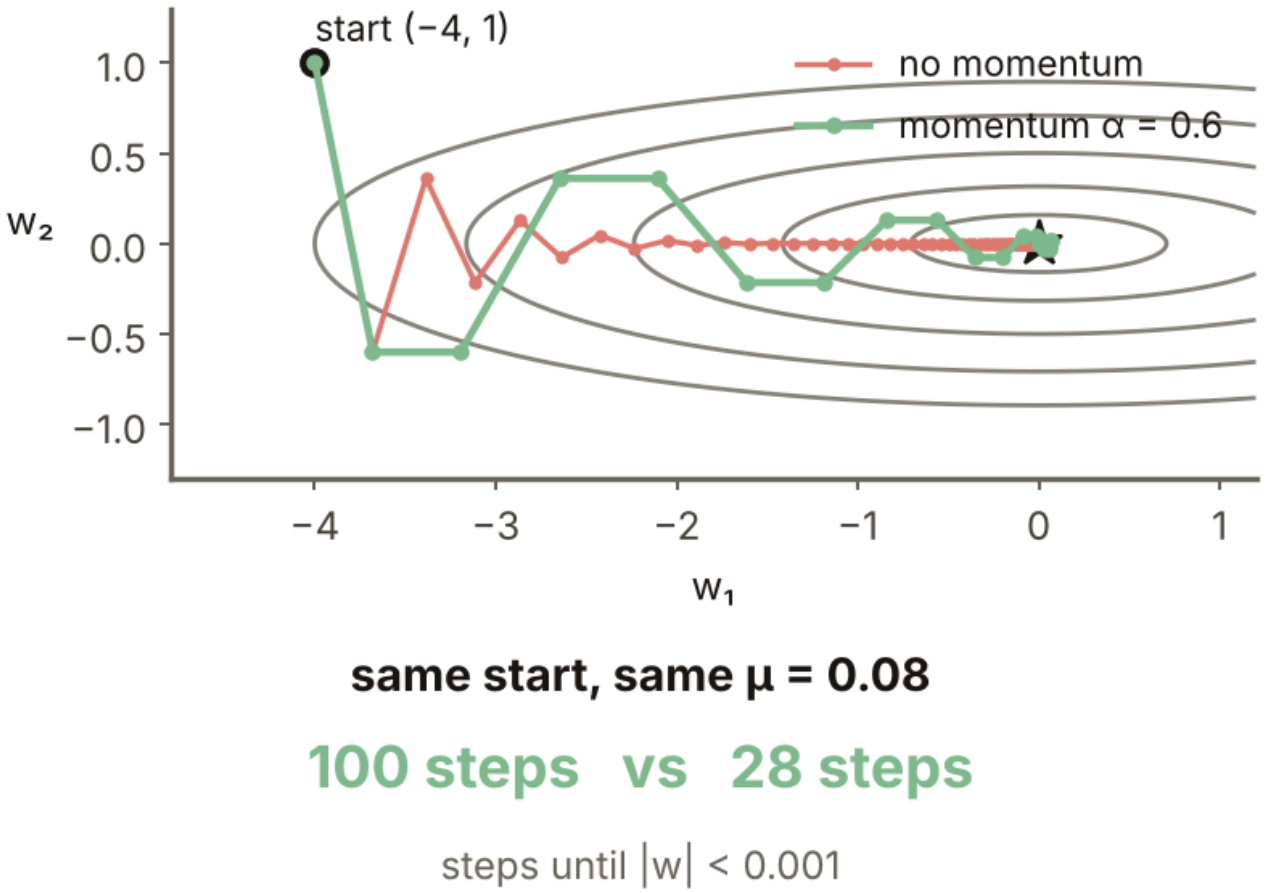
圖說 `lec05-kp08-expo`：權重 0.6^t 與 0.8^t，與固定梯度下的總權重。



5. 兩條軌跡

同起點、同 $\mu = 0.08$：普通 100 步，$\alpha = 0.6$ 的動量 28 步（程式計算）。紅色軌跡在 w_2 方向上下擺很多回，綠色的擺幅縮得更快，w_1 方向也走得更快。代價是多存一份上一步的更新量，多一個旋鈕 α。

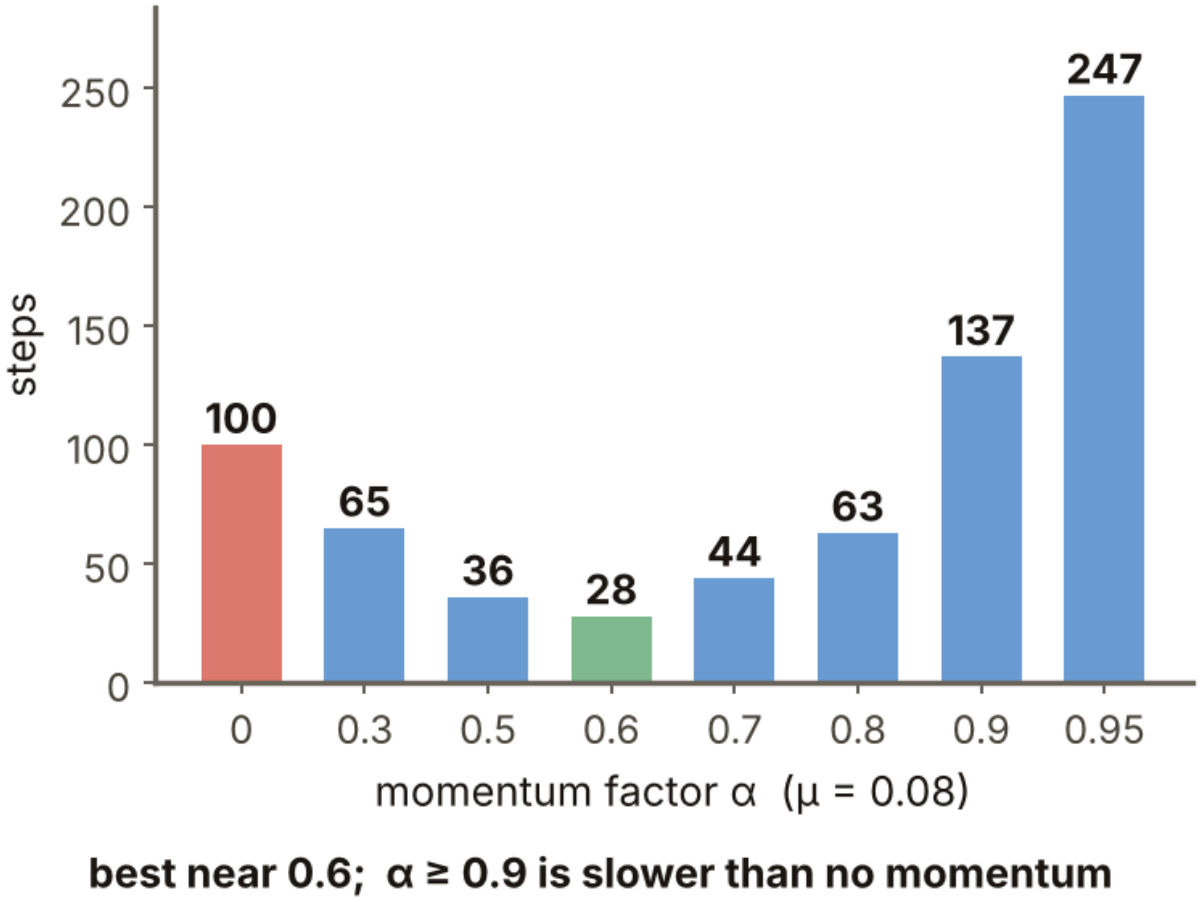
圖說 `lec05-kp08-two-paths`：兩條軌跡的比較。



6. α 的最佳值

常見迷思：α 越大越好。$\mu = 0.08$ 時，$\alpha = 0, 0.3, 0.5, 0.6, 0.7, 0.8, 0.9, 0.95$ 依序要 100、65、36、28、44、63、137、247 步。$\alpha \geq 0.9$ 比不用動量更慢：慣性太大，在谷底衝過頭，像單擺晃很久才停。實務上常取 0.1–0.8，最佳值看問題，要試；來源報告過 2 倍以上的加速。

圖說 `lec05-kp08-alpha-curve`：各 α 所需步數。



7. 自適應學習率

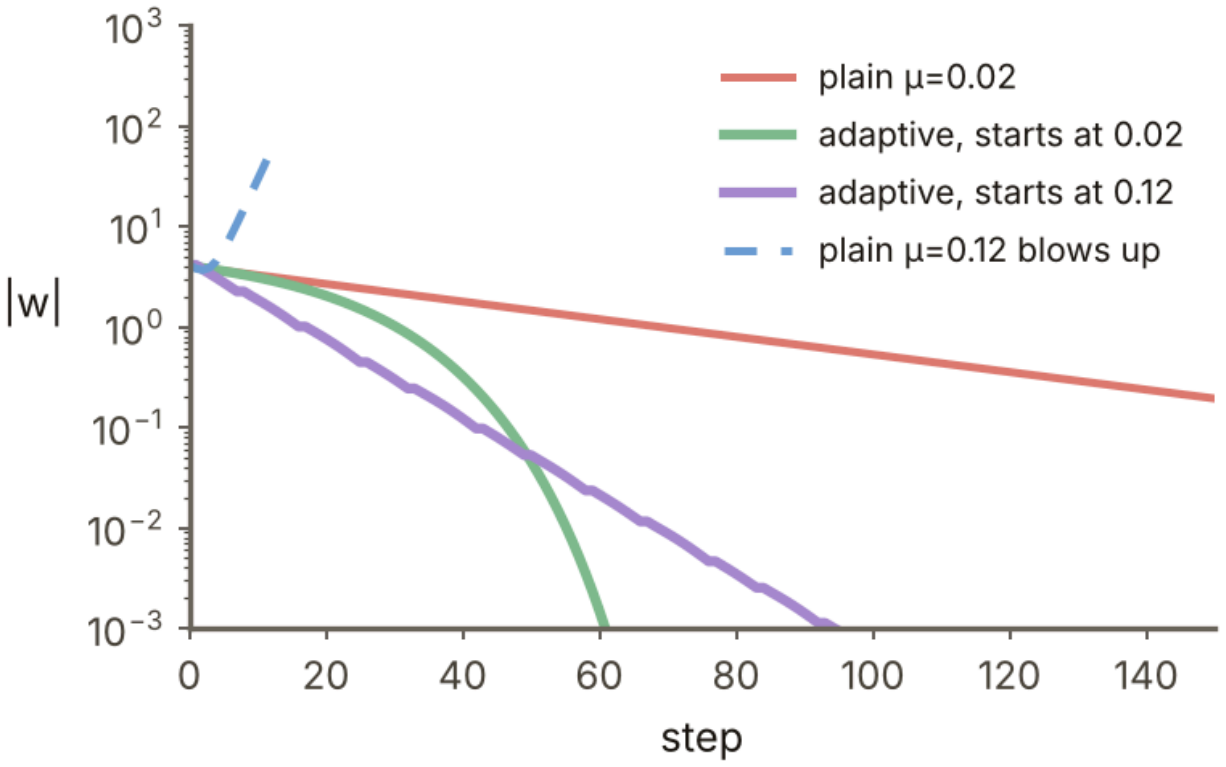
自適應學習率：看代價 J 的前後比值自動調 μ：

$$\mu(t) = \begin{cases} 1.05\,\mu(t-1), & J(t)/J(t-1) < 1 \\ 0.7\,\mu(t-1), & J(t)/J(t-1) > 1.04 \\ \mu(t-1), & \text{其餘} \end{cases}$$

典型值 $r_i = 1.05$、$r_d = 0.7$、$c = 1.04$（來源）。不對稱：變好慢慢加，變壞大力煞車；代價上升時，本講義的做法是這一步不採用、動量歸零（來源建議之一）。

結果（程式計算）：$\mu_0 = 0.02$，普通 411 步、自適應 61 步；$\mu_0 = 0.12$，普通直接爆開，自適應拒絕 12 步後 95 步收斂；$\mu_0 = 0.08$ 本來就接近最佳，自適應 93 步，沒比普通的 100 步好多少。

圖說 `lec05-kp08-adaptive`：$|w|$ 對步數的半對數曲線。



steps: plain 0.02 → 411, adaptive 0.02 → 61, adaptive 0.12 → 95

the 0.12 run rejected 12 steps and cut μ by 30% each time

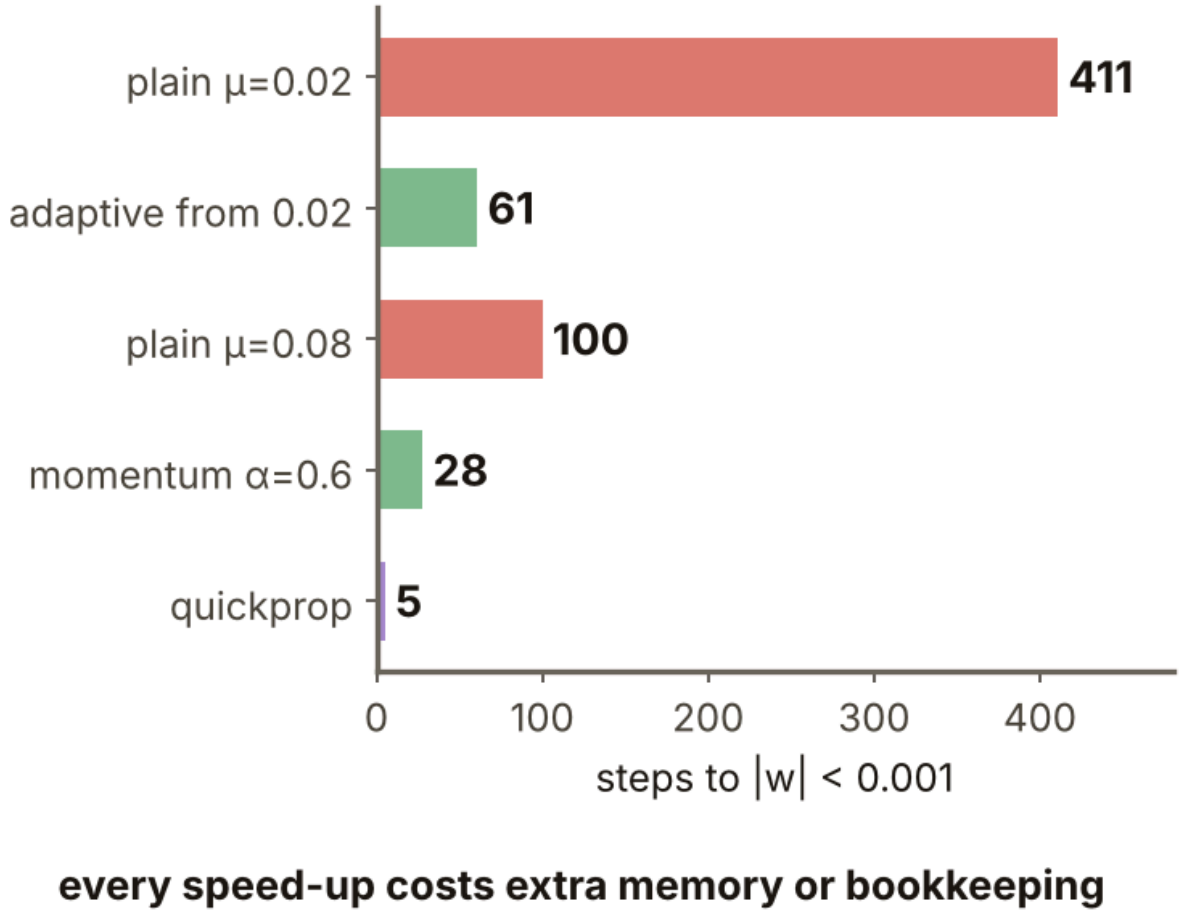
8. quickprop 與五種做法的比較

quickprop：把每個權重當成各自獨立，用最近兩次的斜率估出拋物線的谷底，直接跳過去：

$$\Delta w(t) = \alpha(t)\,\Delta w(t-1), \qquad \alpha(t) = \min\Big\{\frac{g(t)}{g(t-1)-g(t)},\ \alpha_{\max}\Big\},\ \alpha_{\max} \approx 1.75.$$

例子（w_2）：第 1 步普通步 $1 \to -0.6$，斜率 $20 \to -12$；$\alpha = -12/(20+12) = -0.375$，$\Delta = -0.375 \times (-1.6) = +0.6$，第 2 步剛好落在 0。整個二次例 5 步到達（普通 $\mu = 0.02$ 411、自適應 61、普通 $\mu = 0.08$ 100、動量 28）。但這個例子每個切面剛好是拋物線，最合 quickprop；真實代價不是二次的。加速都要付出複雜度。

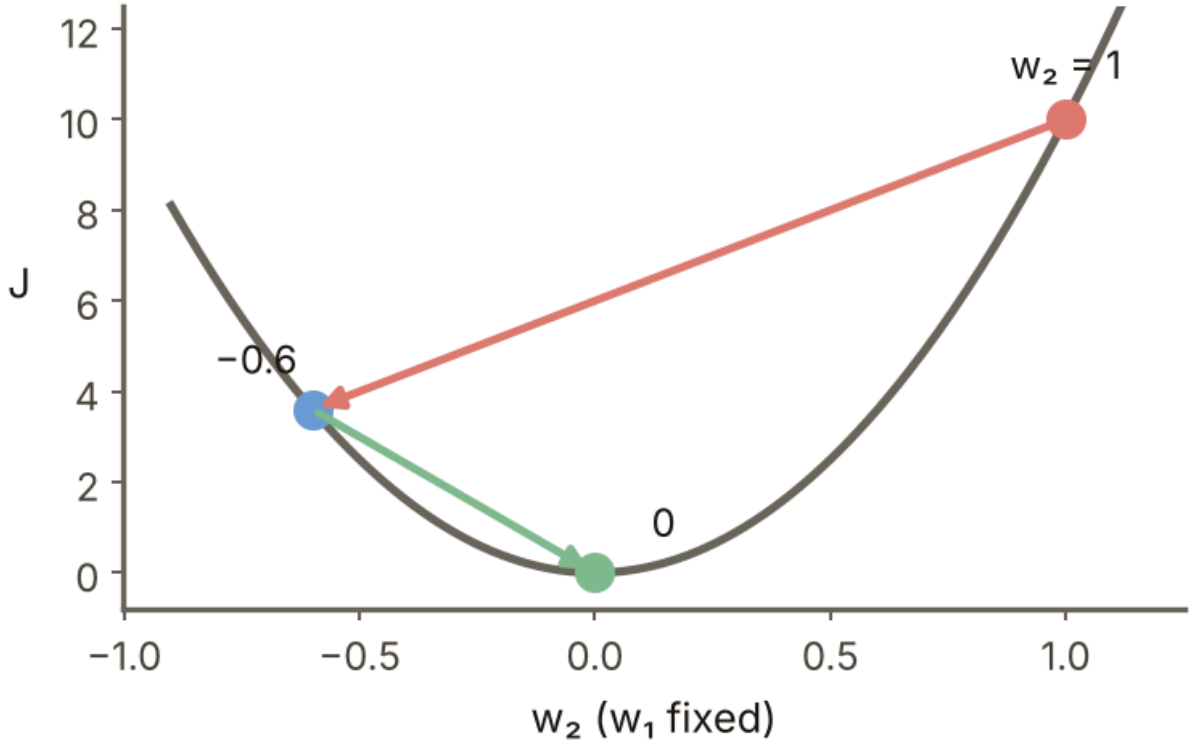
圖說 `lec05-kp08-compare`：五種做法的步數。



延伸：牛頓法、練習與解題示範

牛頓法：用曲率資訊（Hessian 矩陣 H）直接算出谷底，$\Delta w = -H^{-1}g$，二次函數一步就到。本例 $H = \mathrm{diag}(1, 20)$，$\Delta w = -w$，一步到原點；代價是要算、存、反轉 Hessian。quickprop 可看成每個權重各做一維牛頓法。來源還列了共軛梯度、Newton 家族、Kalman 濾波與 Levenberg–Marquardt，多半需要 Hessian 的元素；delta-delta 與 delta-bar-delta 讓每個權重各有一個學習率，梯度連續同號就加大、變號就縮小。

圖說 `lec05-kp08-secant`：沿 w_2 的拋物線與 quickprop 的跳躍。



step 1: ordinary step 1 → −0.6 (μ = 0.08)

step 2: α = −12 / (20 − (−12)) = −0.375, Δ = −0.375 × (−1.6) = +0.6

lands exactly on the minimum of the parabola

小練習：同一個谷底，$\mu = 0.08$、$\alpha = 0.6$。第 2 步後 $w = (-3.1936, -0.6)$，第 2 步更新量 $(0.4864, 0)$。

1. 此處的梯度 $g = (w_1, 20w_2)$ 是多少？
2. 第 3 步的更新量 $\Delta w(3) = 0.6\,\Delta w(2) - 0.08\,g(3)$ 與新的 w 是多少？

圖說 `lec05-kp08-practice`：前兩步的數字與要求。

$J = \frac{1}{2}(w_1^2 + 20 \cdot w_2^2),\ \mu = 0.08,\ \alpha = 0.6$

after step 1: $w = (-3.68, -0.6),\ \Delta w = (0.32, -1.6)$

after step 2: $w = (-3.1936, -0.6),\ \Delta w = (0.4864, 0.0)$

step 3: find g, Δw and w

$g = (w_1, 20 \cdot w_2)$ $\Delta w(3) = 0.6 \cdot \Delta w(2) - 0.08 \cdot g$

題 1、2 解題示範：① $g = (-3.1936,\ 20 \times (-0.6)) = (-3.1936, -12)$。② $\Delta w(3) = 0.6 \times (0.4864, 0) - 0.08 \times (-3.1936, -12) = (0.29184 + 0.25549,\ 0.96) = (0.54733, 0.96)$；$w = (-3.1936 + 0.5473,\ -0.6 + 0.96) = (-2.6463, 0.36)$。③ 核對：第 2 步 w_2 沒有動，這一步 w_2 的慣性是 0，梯度那份 0.96 全成了位移。

圖說 `lec05-kp08-practice-sol`：第 3 步的各項。

$g = (w_1, 20 \cdot w_2)$ $= (-3.1936, -12.0)$

$0.6 \cdot \Delta w(2)$ $= (0.29184, 0.0)$

$-0.08 \cdot g$ $= (0.25549, 0.96)$

$\Delta w(3)$ $= (0.54733, 0.96)$

w after step 3 $= (-2.6463, 0.36)$

w_2 did not move in step 2, so its inertia term is 0

術語與來源

中文	English
曲率	Curvature
狹長谷底（病態代價面）	Narrow valley (ill-conditioned surface)
動量	Momentum
指數加權平均	Exponentially weighted average
自適應學習率	Adaptive learning rate
quickprop	quickprop
牛頓法	Newton's method

來源：第四章 KP08，§4.7（2026-10-25 讀取）。動量式、$1/(1-\alpha)$ 的推導、自適應學習率的規則與典型值、quickprop 公式、牛頓法家族依來源；$J = \frac{1}{2}(w_1^2 + 20w_2^2)$ 這個例子、起點與所有步數、軌跡由本講義設計並重算（［補充］，（程式計算））。