KP09 代價函數的選擇

> 程度：大學三年級
>
> 圖型識別｜第四章 §4.8

簡報閱讀與下載

學習目標

- 能說明平方誤差的兩個毛病，以及輸出錯到極端時為什麼學不動。
- 能推導交叉熵搭配 sigmoid 或 softmax 時 δ 變成 $y - \hat{y}$，並說明交叉熵就是負對數概似。
- 能說明判別式學習與貝氏訓練各自的想法與代價。

KP09 代價函數的選擇

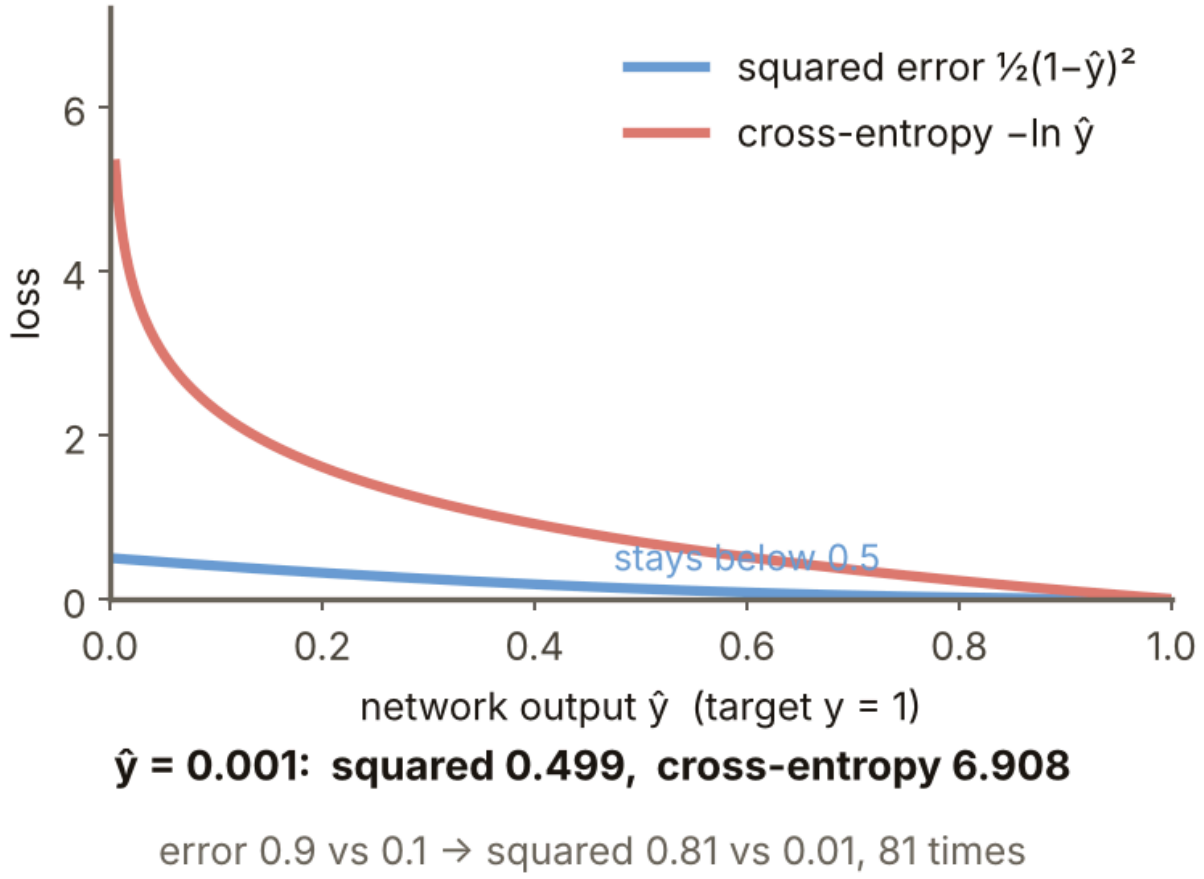
一句話重點：平方誤差不是唯一選擇。在分類任務，交叉熵常是更對的損失：它不被 sigmoid 的斜率壓掉，錯得越離譜修得越用力；搭配 softmax，反向傳播的 δ 乾淨地等於 $y - \hat{y}$。

1. 平方誤差的兩個毛病

白話說明：KP08 的加速都在改更新式，但更新往哪裡走取決於代價函數本身。

- **不公平**：誤差先平方再加總，大誤差主導學習。誤差 0.9 與 0.1 差 9 倍，平方後是 0.81 與 0.01，差 81 倍。
- **會卡住**：輸出 $\hat{y}$ 錯到極端（目標 1、輸出 0.001）時，平方誤差只有 0.499，不會再變大；梯度下降可能被困住（來源引 Witt 00）。對照：另一種損失 $-\ln \hat{y}$ 在 $\hat{y} = 0.001$ 時是 6.908。

圖說 `lec05-kp09-loss`：目標為 1 時兩種損失對輸出的曲線。

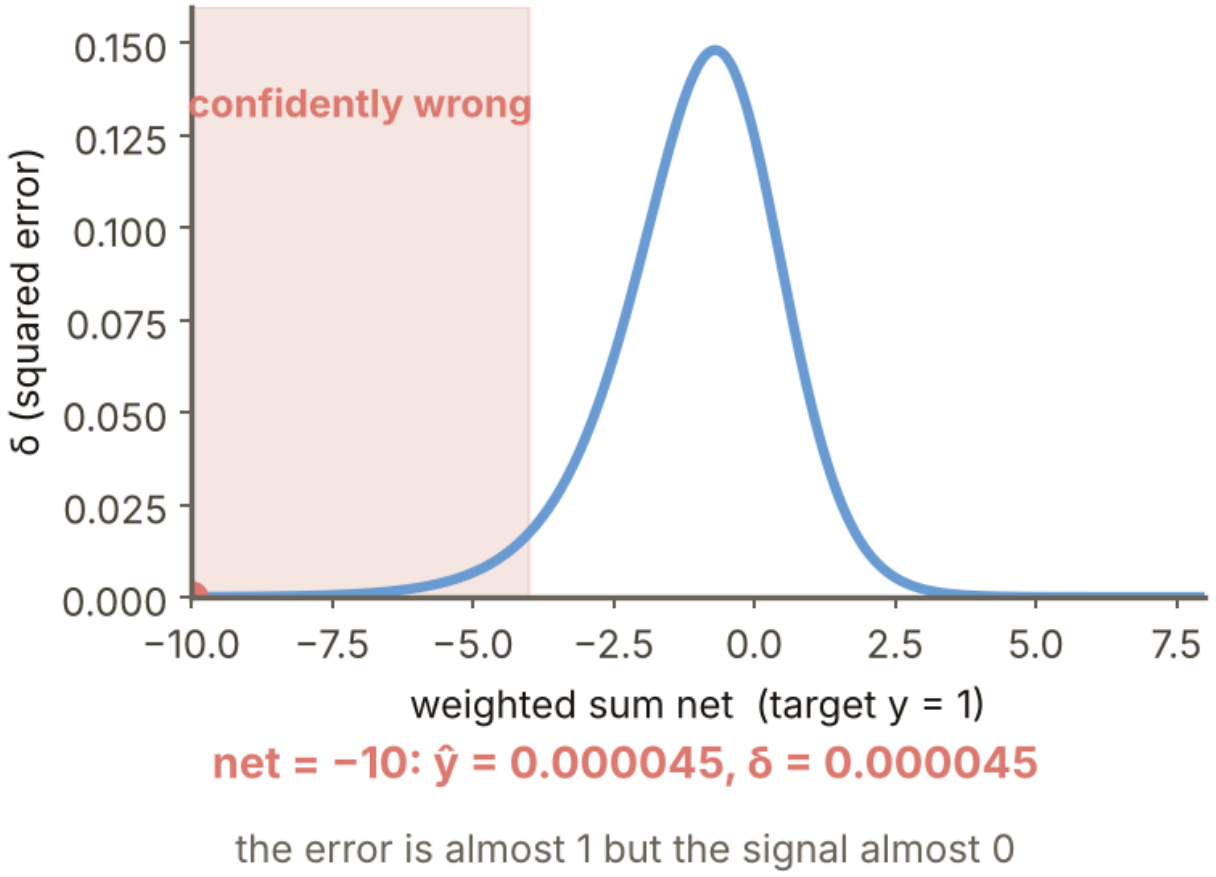


2. 高原：輸出錯在極端時 δ 趨近 0

高原：代價很大、梯度卻幾乎為 0 的平坦區，梯度下降在上面幾乎不動。

單一 sigmoid 輸出的平方誤差，$\delta = (y - \hat{y})\,\hat{y}(1 - \hat{y})$。$\hat{y}$ 越接近 0 或 1，斜率 $\hat{y}(1 - \hat{y})$ 越小，把大誤差也壓成小訊號。目標 $y = 1$、$net = -10$ 時，$\hat{y} = 0.000045$，誤差近 1，$\delta = 0.000045$。

圖說 `lec05-kp09-mse-delta`：平方誤差的 δ 對加權和 net。



3. 交叉熵：把斜率約掉

交叉熵：把輸出 $\hat{y}$ 當成「目標為 1 的機率」。**正式定義**：

$$J = -\big(y \ln \hat{y} + (1-y)\ln(1-\hat{y})\big),$$

$y=1$ 時是 $-\ln \hat{y}$。推導：$\partial J/\partial \hat{y} = -(y-\hat{y})/[\hat{y}(1-\hat{y})]$，乘上 sigmoid 斜率 $\hat{y}(1-\hat{y})$ 剛好約掉，得 $\delta = y - \hat{y}$。符號沿用 KP06（$\delta = -\partial J/\partial net$）；來源寫成 $\hat{y}-y$，差一個負號。$net = -10$ 時，平方誤差 $\delta = 0.00005$，交叉熵 $\delta = 1.0000$。

圖說 `lec05-kp09-delta-table`：不同 net 下的 $\hat{y}$ 與兩種 δ。

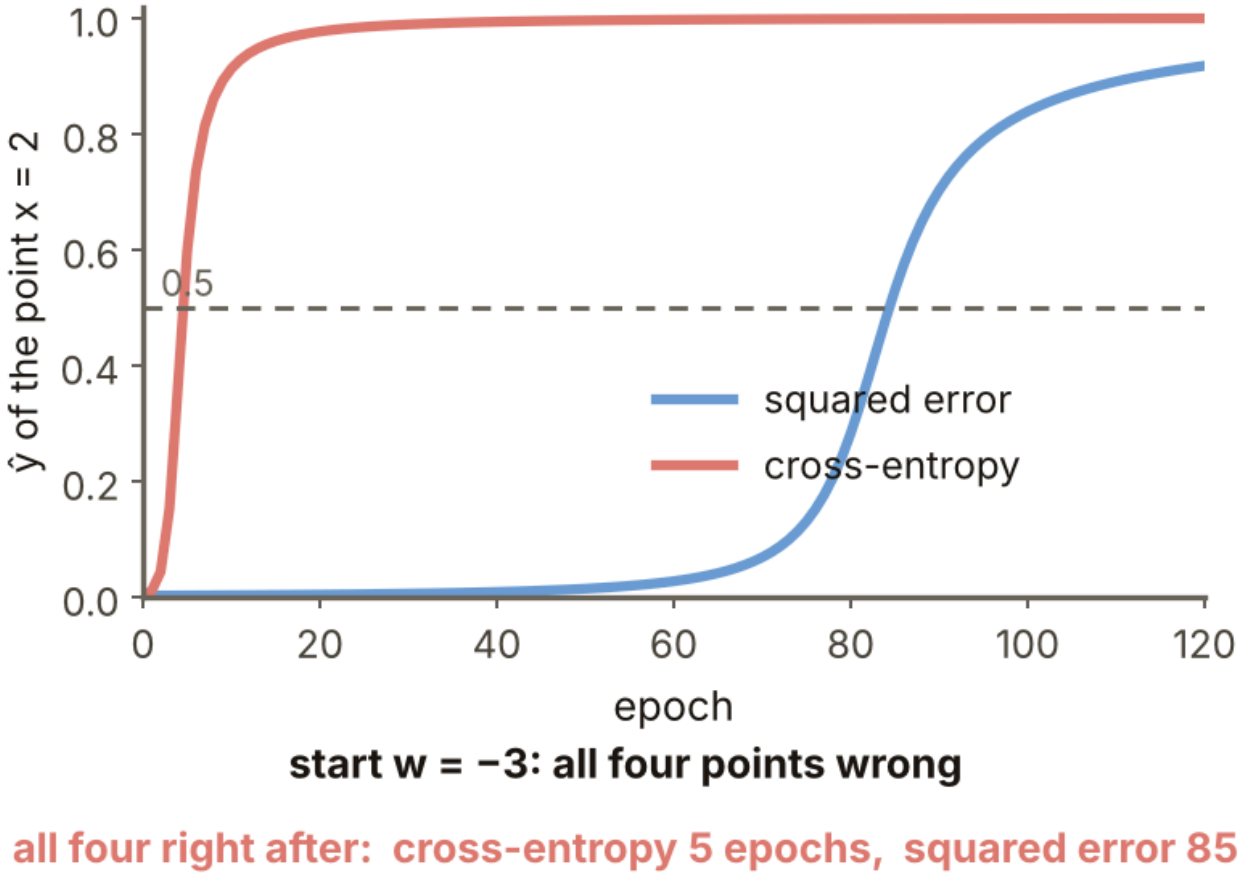
net	ŷ	δ squared	δ cross-ent.
−10	0.00005	0.00005	1.0000
−5	0.0067	0.00660	0.9933
−2	0.1192	0.09248	0.8808
0	0.5000	0.12500	0.5000
2	0.8808	0.01252	0.1192
5	0.9933	0.00004	0.0067

target y = 1; both δ defined as −∂J/∂net

4. 訓練對比

例子（本講義設計）：一個 sigmoid 神經元 $\hat{y} = \sigma(b + wx)$，四點 $x = -2, -1, 1, 2$，目標 $0, 0, 1, 1$；起點 $w = -3, b = 0$，四點全錯；$\eta = 0.5$，批次更新。交叉熵 5 個 epoch 四點全對，平方誤差要 85 個（程式計算）。**常見迷思**：換了交叉熵才分得對。其實兩種代價最後都能分對，差別是起點很錯時的速度。

圖說 `lec05-kp09-train`：點 $x = 2$ 的輸出對 epoch。



5. 概似：交叉熵就是負對數概似

概似：假設模型是對的，觀察到這批資料的機率；越大越好，獨立的各筆機率相乘。輸出 $0.9, 0.8, 0.3, 0.1$、目標 $1, 1, 0, 0$：各筆「目標的機率」是 $0.9, 0.8, 0.7, 0.9$，相乘 0.4536，$-\ln 0.4536 = 0.7905$；四筆交叉熵 $0.105 + 0.223 + 0.357 + 0.105 = 0.790$ 加總相同。最小化交叉熵就是最大化概似。

圖說 `lec05-kp09-likelihood`：四筆樣本的機率與 $-\ln$。

sample	target y	output ŷ	p of the target	−ln p
1	1	0.9	0.9	0.105
2	1	0.8	0.8	0.223
3	0	0.3	0.7	0.357
4	0	0.1	0.9	0.105

product of p: 0.4536

sum of −ln p: 0.7905

−ln 0.4536 = 0.7905: the cross-entropy is the negative log-likelihood

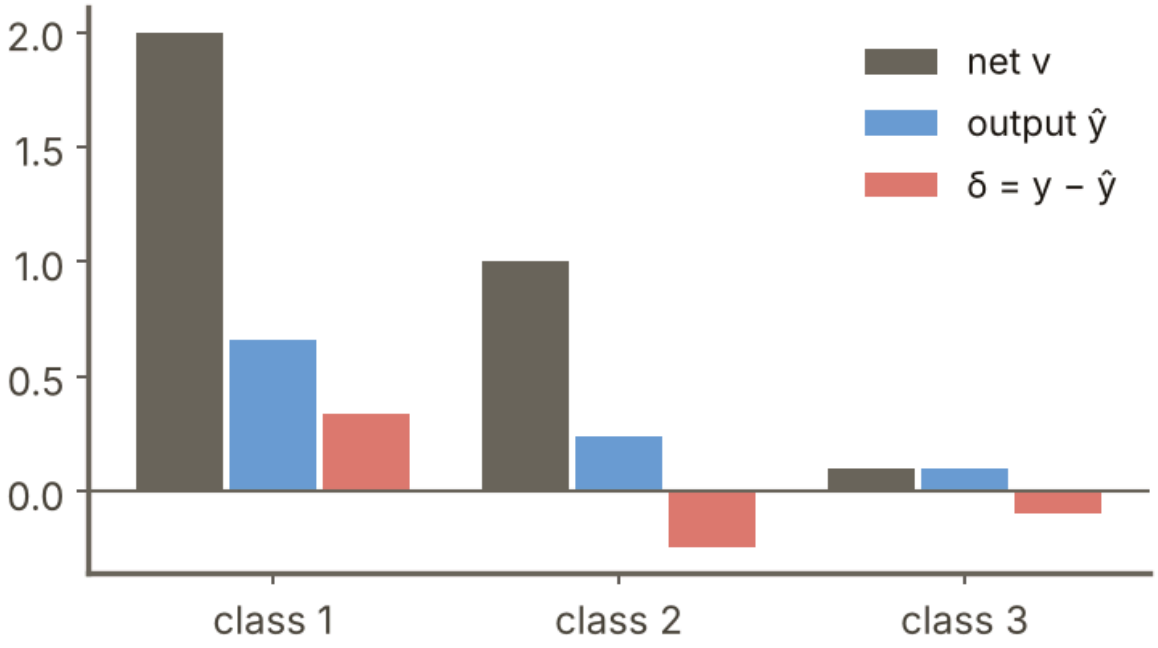
6. softmax

softmax 用於多類別：

$$\hat{y}_k = \frac{e^{v_k}}{\sum_{k'} e^{v_{k'}}},$$

輸出都在 0 與 1 之間，加總恰為 1。$v = (2, 1, 0.1)$ 得 $\hat{y} = (0.659, 0.242, 0.099)$；目標 $y = (1, 0, 0)$，$J = -\ln 0.659 = 0.417$。反向傳播需要的 $\delta_k = y_k - \hat{y}_k = (0.341, -0.242, -0.099)$，與數值差分相同（程式驗證）。

圖說 `lec05-kp09-softmax`：v、$\hat{y}$、δ 的長條圖。



ŷ = (0.659, 0.242, 0.099), sum = 1

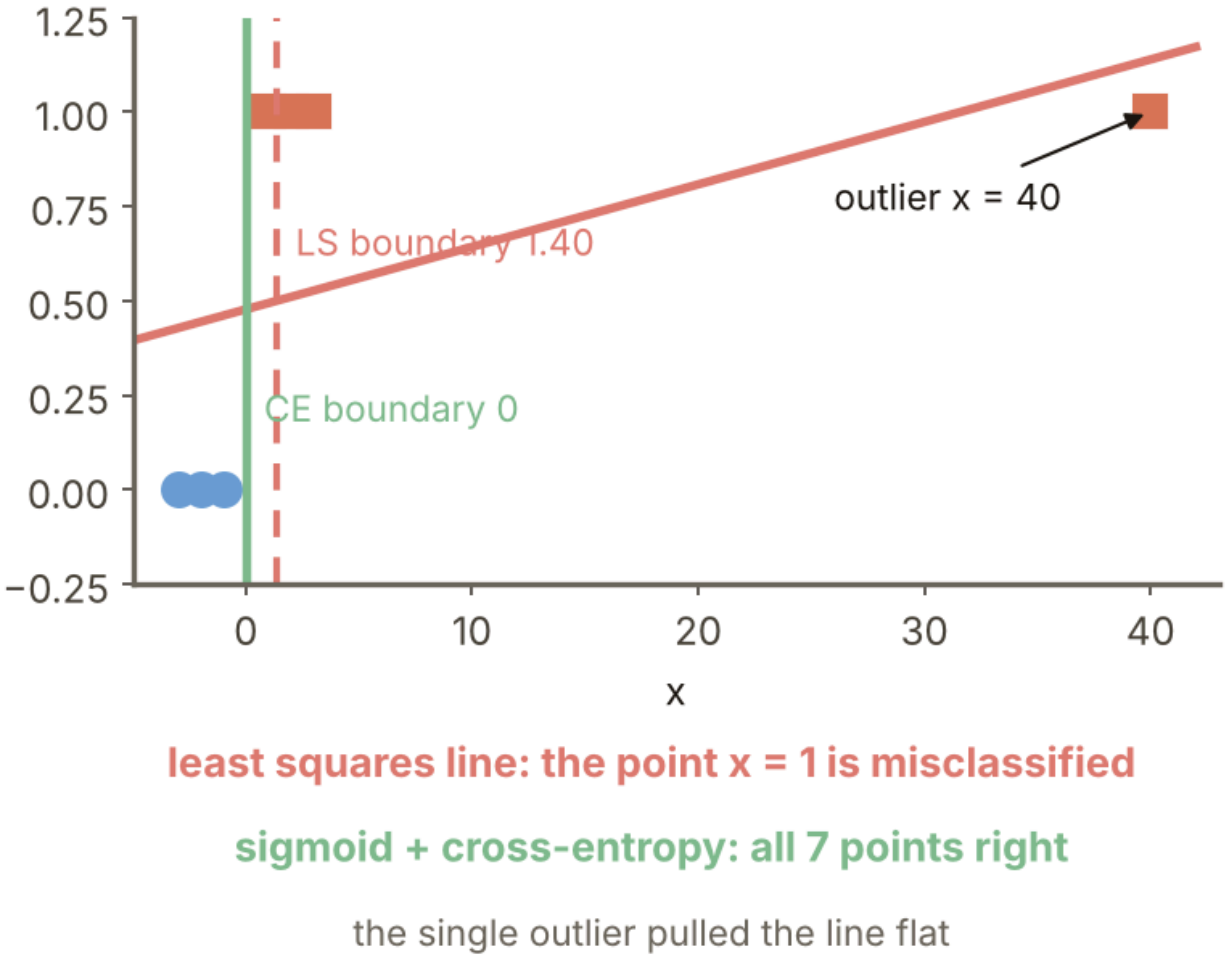
δ = (0.341, −0.242, −0.099)

checked against numerical differences of J = −ln $\hat{y}_1$

7. 判別式學習

判別式學習：既然目標是降低分類錯誤率，就直接把重心放在最大的後驗機率上，推動決策面去降低錯誤。**對照例**（本講義設計）：$x = -3, -2, -1$ 為類 0，$x = 1, 2, 3$ 與離群點 $x = 40$ 為類 1。平方誤差的直線在 1.40 切開，$x = 1$ 被分錯；sigmoid 加交叉熵在 0 切開，七點全對。這個對照同時換了輸出與代價；錯誤率本身不可微，要用平滑版，有區域極小值的風險（來源，另有 deterministic annealing 緩解）。

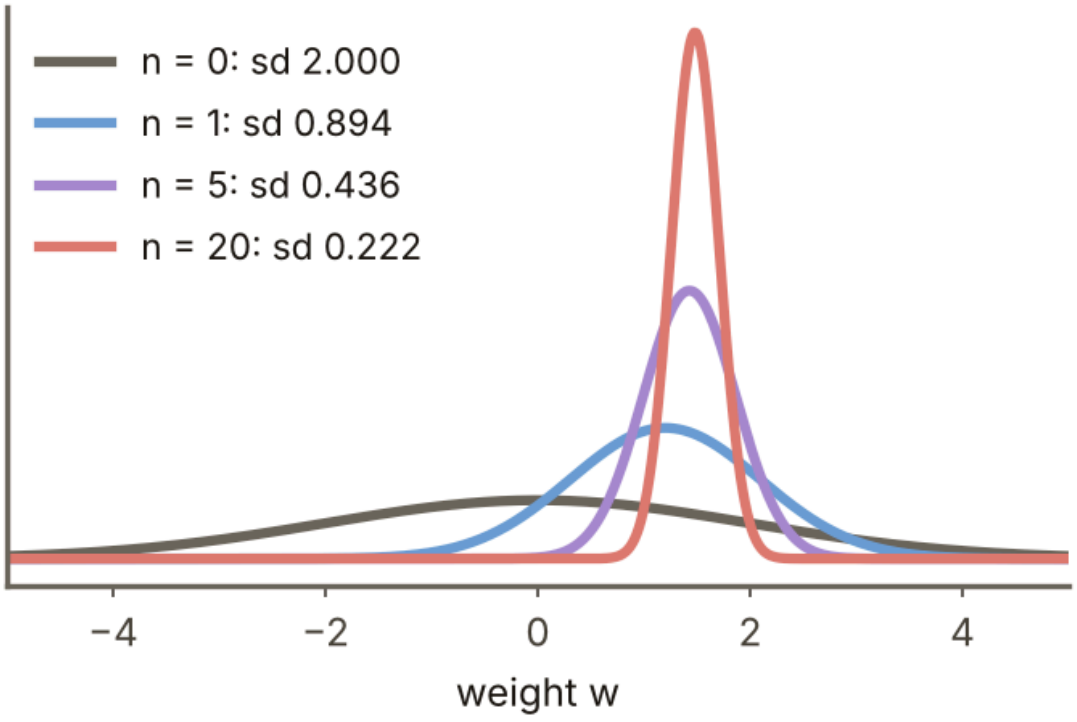
圖說 `lec05-kp09-lsfit`：七個點與兩條邊界。



8. 貝氏訓練

貝氏訓練：先設權重的先驗分布 $p(w)$，資料進場後用貝氏定理（先驗 = 看資料前的猜測，後驗 = 加入資料後的修正）得到後驗 $p(w \mid Y) = p(Y \mid w)\, p(w) / p(Y)$；分類時對所有 w 平均 $P(\omega_k \mid x; Y) = \int \phi_k(x; w)\, p(w \mid Y)\, dw$。**例子**（本講義設計）：先驗標準差 2，每筆資料都說 $w \approx 1.5$（雜訊標準差 1）；$n = 0, 1, 5, 20$ 時後驗標準差 $2, 0.894, 0.436, 0.222$、後驗平均 $0, 1.2, 1.43, 1.48$。代價：高維積分很貴；來源提醒，實務上換掉最小平方未必帶來實質提升。

圖說 `lec05-kp09-posterior`：不同 n 的後驗分布。



prior sd 2; every sample says w ≈ 1.5 (noise sd 1)

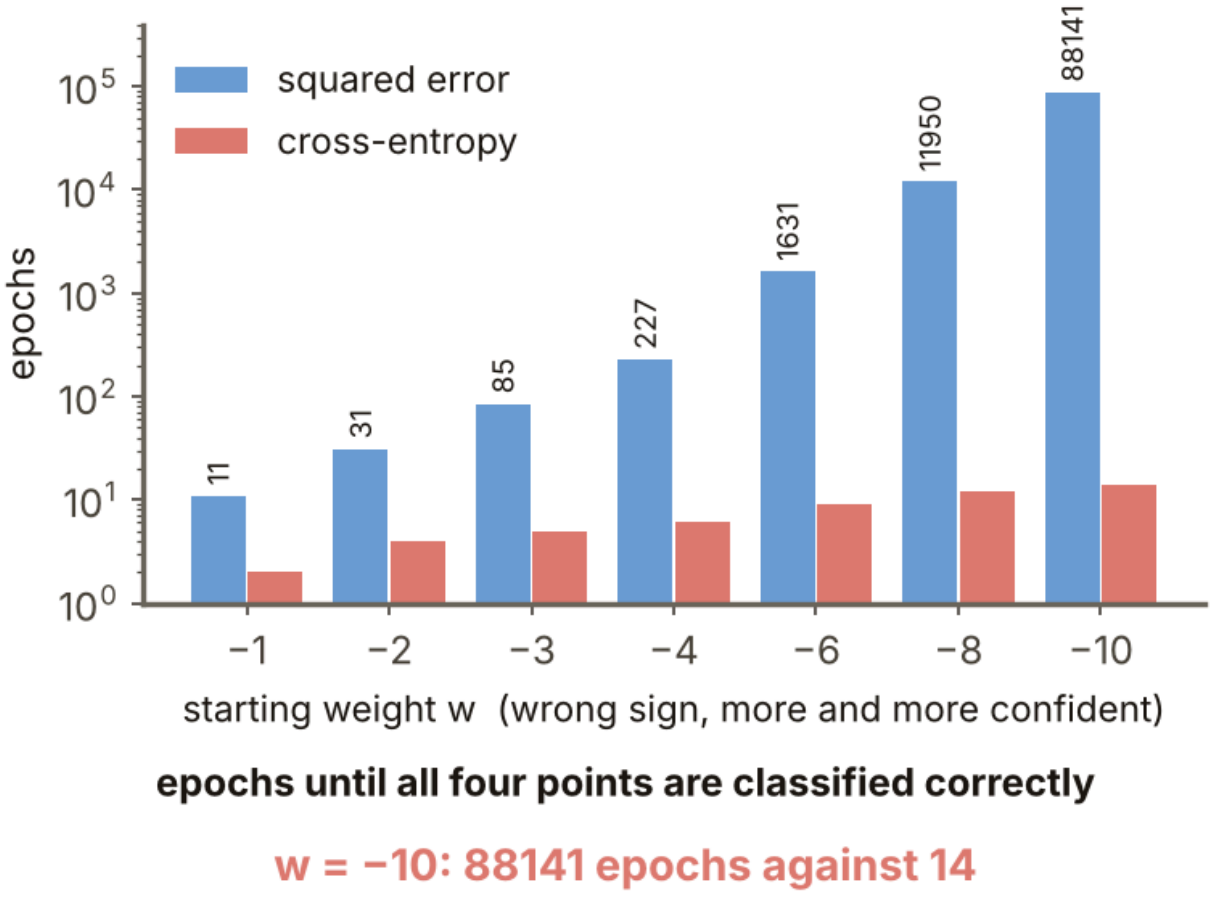
posterior mean 1.2 → 1.43 → 1.48 as n = 1, 5, 20

classifying averages over all w: a costly integral

延伸：起點越錯、練習與解題示範

起點越錯：同第 4 節的資料與 $\eta = 0.5$，起點 $w = -1, -2, -3, -4, -6, -8, -10$，平方誤差要 11、31、85、227、1631、11950、88141 個 epoch，交叉熵只要 2、4、5、6、9、12、14 個。平方誤差的 δ 隨起點變錯而指數縮小，epoch 數大致指數增加；交叉熵的 δ 保持在 1 附近。

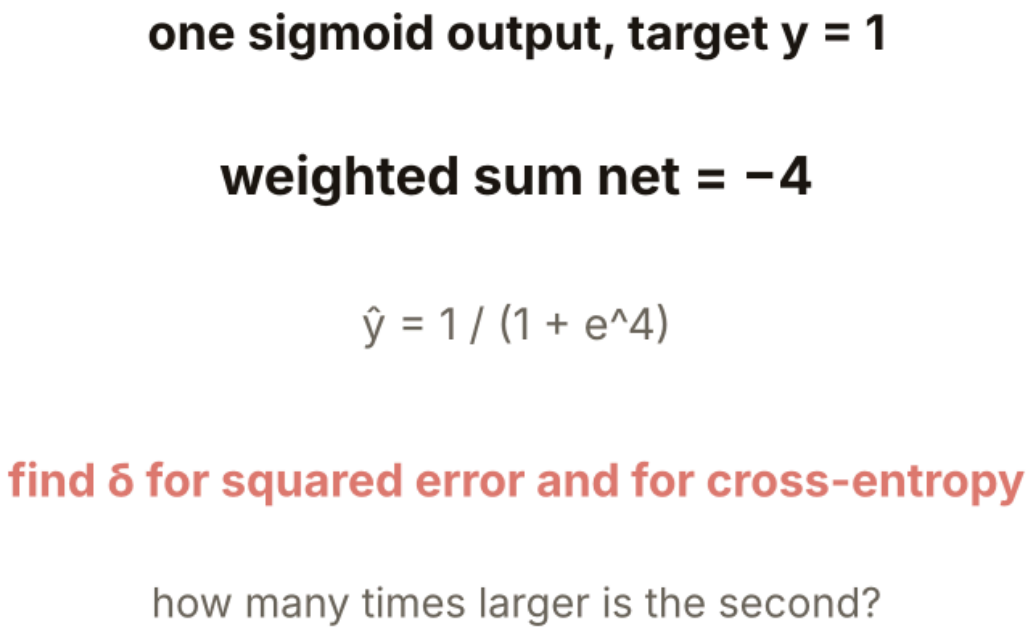
圖說 `lec05-kp09-init`：七個起點所需 epoch 數（對數座標）。



小練習：單一 sigmoid 輸出，目標 1，$net = -4$。

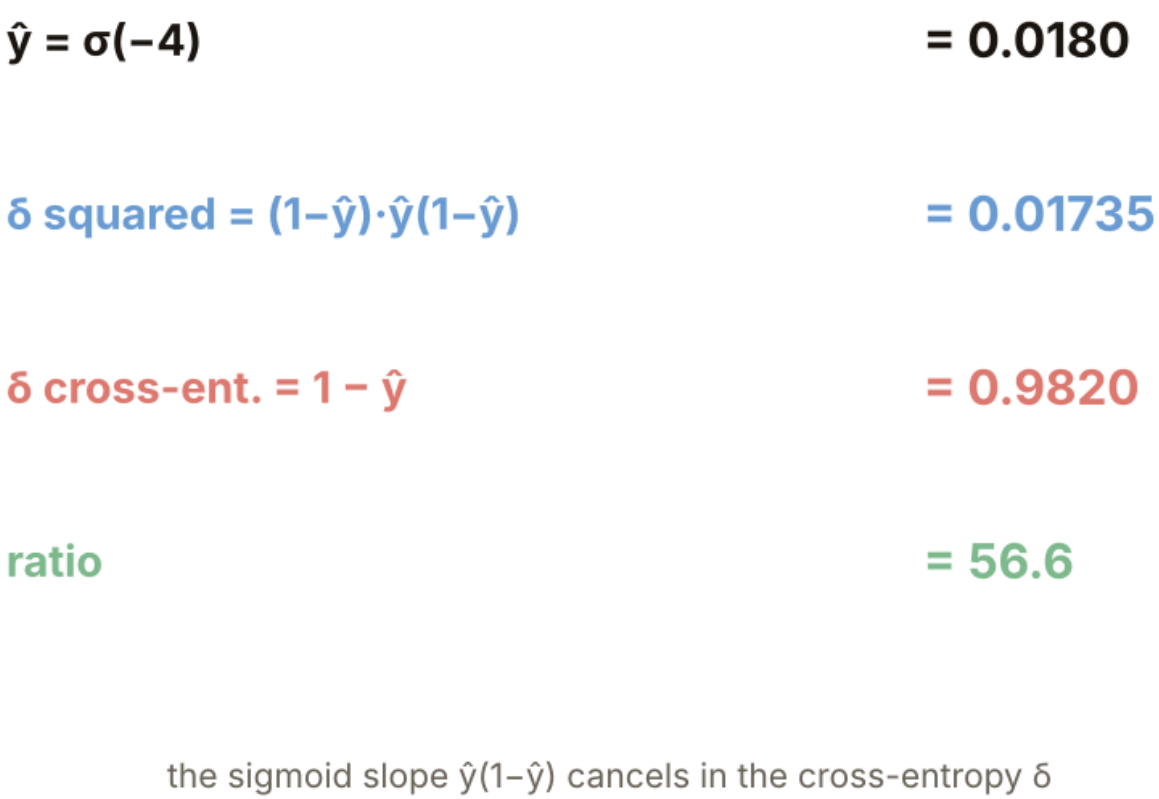
1. $\hat{y} = \sigma(-4)$ 是多少？
2. 平方誤差 $\delta = (1-\hat{y})\,\hat{y}(1-\hat{y})$ 與交叉熵 $\delta = 1-\hat{y}$ 各是多少，交叉熵的是平方誤差的幾倍？

圖說 `lec05-kp09-practice`：練習的設定。



題 1、2 解題示範：① $\hat{y} = 1/(1+e^4) = 0.0180$。② 平方誤差 $\delta = 0.9820 \times 0.0180 \times 0.9820 = 0.01735$；交叉熵 $\delta = 0.9820$；倍數 $0.9820/0.01735 = 56.6$。③ 核對：倍數就是 $1/[\hat{y}(1-\hat{y})]$，輸出越極端越大；$net = -10$ 時約 22000 倍。

圖說 `lec05-kp09-practice-sol`：兩種 δ 與倍數。



術語與來源

中文	English
高原	Plateau
交叉熵	Cross-entropy
概似	Likelihood
softmax	softmax
判別式學習	Discriminative learning
貝氏訓練	Bayesian training

來源：第四章 KP09，§4.8（2026-10-25 讀取）。平方誤差的兩個毛病、交叉熵與 softmax 的公式、δ 的簡化、判別式學習與貝氏訓練的描述依來源；單一 sigmoid 神經元的訓練對比、離群點對照例、高斯後驗例與所有數字由本講義設計並重算（［補充］，（程式計算））。δ 的符號統一為 $-\partial J/\partial net$。