KP11 剪枝、正則化與模擬實證

> 程度：大學三年級（undergrad）｜自主學習教材｜繁體中文版

本份可獨立閱讀；先備為加權計分、基本微分及矩陣。新術語會在使用時說明。

開啟同語言簡報

學習目標

- 由 Taylor 近似推導顯著度並說出假設。
- 手算懲罰值、刪除代價與補償例子。
- 區分原文模擬報告與本次教學計算。

KP11 剪枝、正則化與模擬實證

一句話重點：先估刪除的代價，再以懲罰與驗證控制模型，數量不是唯一判準。

白話說明：已經訓練好的網路可能有冗餘，但不能只看權重大小就判斷重要性。先固定我們要做的操作，再看代價曲線如何回應。

正式定義：以下各段會逐一定義名詞、符號與成立條件；公式中的同一個量維持同一符號。

例子：所有新增小算例均為［補充］，已用 Python 核對；來源實驗報告另行標示。

常見迷思：小權重不必然不重要，平滑懲罰也不等於權重已經刪除。

小練習：末段提供先做後核對的題目、提示及解題示範。

刪除量不等於刪除代價

已經訓練好的網路可能有冗餘，但不能只看權重大小就判斷重要性。先固定我們要做的操作，再看代價曲線如何回應。

剪枝：移除部分連線或單元，減少模型可調的部分，叫剪枝；刪除後仍需檢查表現。

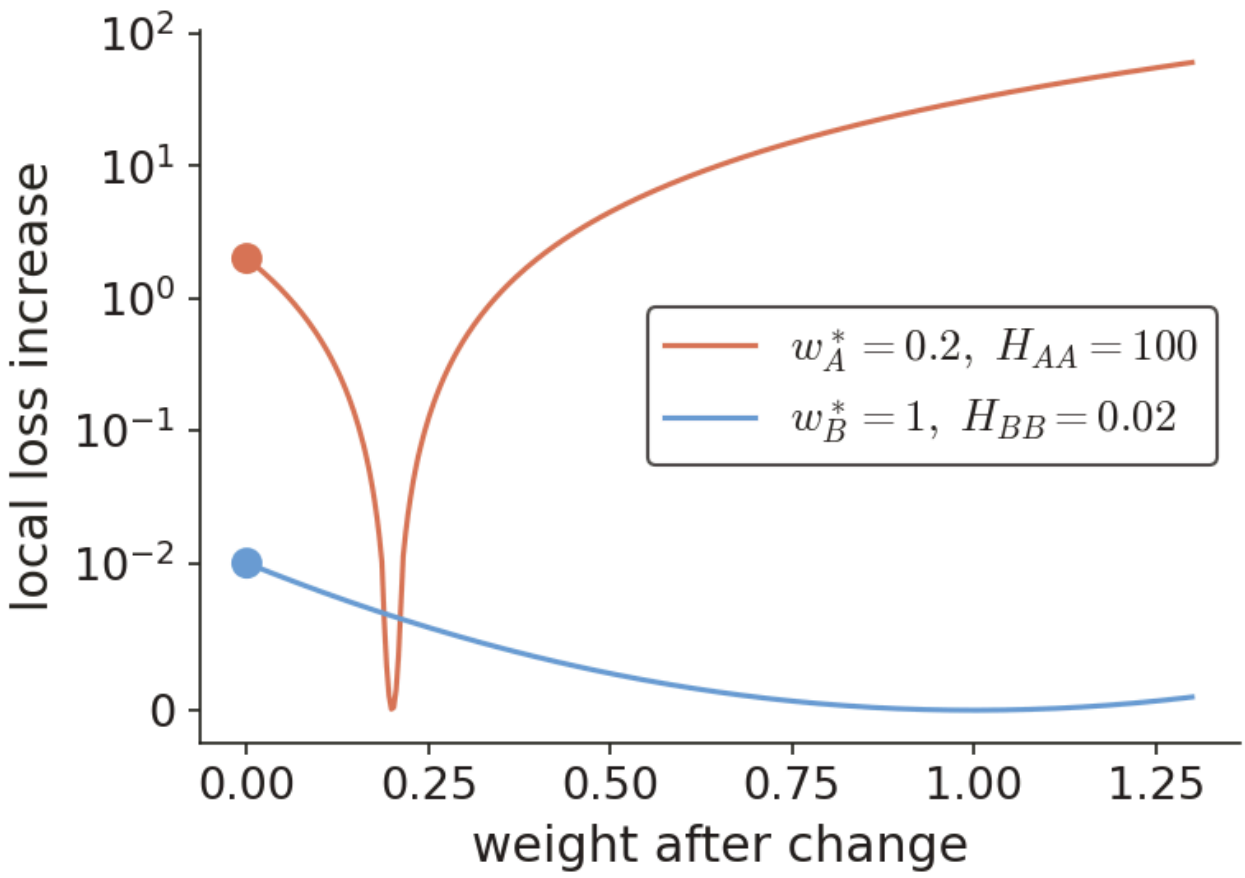
我們先研究單條連線：把它的權重設成零，等於這條輸入不再貢獻分數。

目標不是「刪最多」，而是在可接受的損失與保留資料表現下，換到較簡單的模型。

w_i 是第 i 個權重，δw_i 是修改量。$w_i + \delta w_i = 0$，所以 $\delta w_i = -w_i$。

J 是訓練代價，ΔJ 是刪除後減去刪除前的代價；它不是權重的大小。

假如 $w_i = 0.2$，刪除是加上 -0.2；別把「只改一點點」直接當成「影響一定小」。



圖說 `lec05-kp11-curvature`：[補充] 先看圖中的對照與標籤，再用本段數字核對；圖內的模型示意不代表實驗精確曲線。〔功能：精準度、具象化〕

曲率：在目前權重附近，曲率描述損失斜率改變得多快；這裡用二階導數衡量。

海森矩陣：把權重間所有二階偏導數排成矩陣 H，稱為海森矩陣；H_{ii} 描述第 i 個方向的曲率。

圖中 A 的權重較小，但所在損失曲線較陡；刪除的損失可比大權重 B 更高。

從 Taylor 展開得到顯著度

附近的斜率與曲率提供局部預測。推導的每次簡化都有條件；接著的小例子刻意讓權重大小和重要性給出相反排序。

$\Delta J \approx \sum_i g_i \delta w_i + \frac{1}{2} \sum_{i,j} H_{ij} \delta w_i \delta w_j$；$g_i = \partial J / \partial w_i$ 是當地斜率。

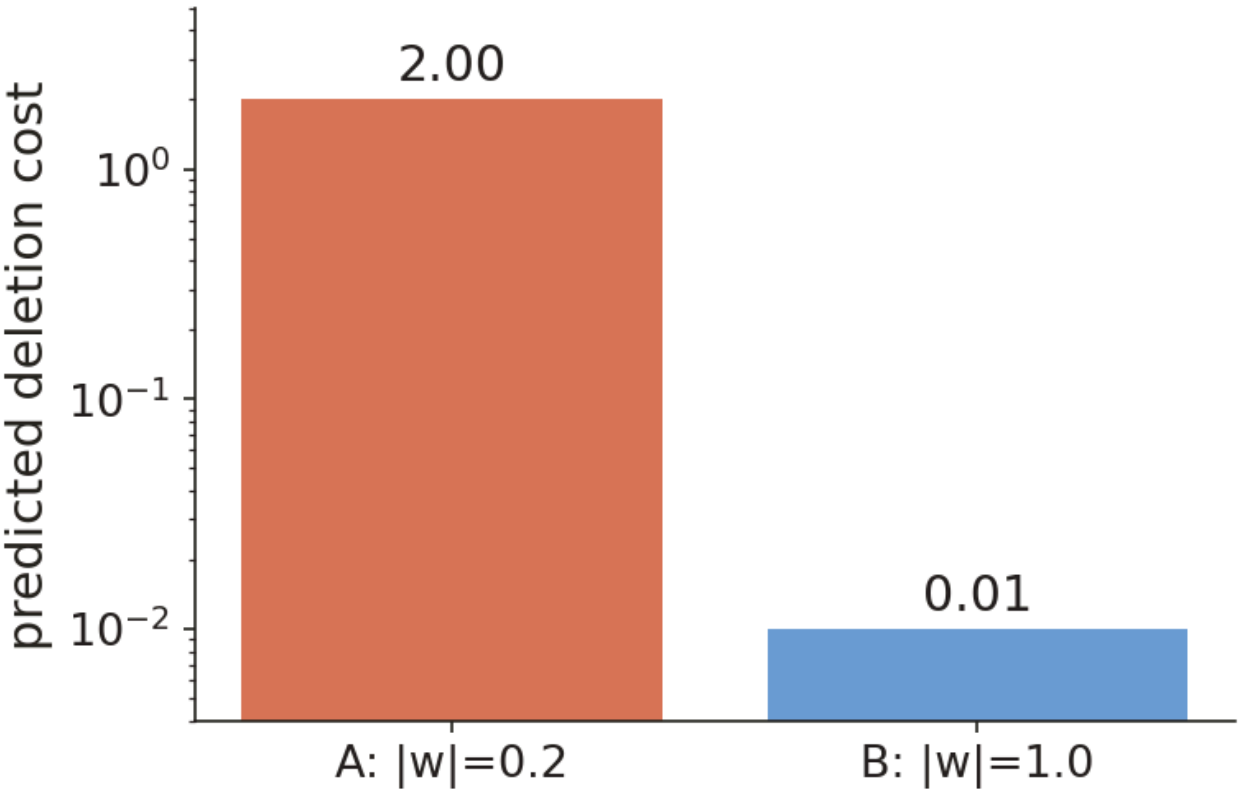
接近極小值，取 $g_i \approx 0$；用對角近似忽略跨權重交互項，得到 $\Delta J \approx \frac{1}{2} \sum_i H_{ii} (\delta w_i)^2$。

顯著度：代入 $\delta w_i = -w_i$，定義刪除代價估計 $s_i = \frac{1}{2} H_{ii} w_i^2$，稱為顯著度；是近似，不是實測損失。

A：$w_A = 0.2, H_{AA} = 100$。$s_A = \frac{1}{2} \times 100 \times 0.2^2 = 2$。

B：$w_B = 1, H_{BB} = 0.02$。$s_B = \frac{1}{2} \times 0.02 \times 1^2 = 0.01$。

比較：$2 / 0.01 = 200$。依這個局部估計先刪 B，雖然它的權重較大。



圖說 `lec05-kp11-saliency`：［補充］先看圖中的對照與標籤，再用本段數字核對；圖內的模型示意不代表實驗精確曲線。〔功能：精準度、具象化〕

尚未接近極小值時，一階項未必小；刪除幅度太大時，高階項也可能不可忽略。

同時刪多個權重可能有耦合。若海森矩陣呈現負曲率，也不能把負數直接解讀成「安全重要性」。

用小步驟刪除、重新量測代價、再訓練剩餘權重，並保留最佳驗證模型。

把估計放進可檢查的剪枝程序

顯著度不是刪除後的實測值，所以流程必須包含重新評估與再訓練，而不能把一個排序永久當成真理。

先訓練到合適位置 → 估顯著度 → 刪少量低顯著度連線 → 再訓練與驗證。

依驗證表現、允許的損失增加或資源預算停止；刪除後的較小網路不保證每次都更準。

完整海森矩陣方法還能考慮其他權重如何補償；代價是較高的儲存與計算需求。

在代價函數中加入模型偏好

剪枝改結構，正則化先改目標。先比較兩個固定候選模型，再看來源的飽和懲罰曲線，最後分清縮小數值與真正刪除。

正則化：在資料誤差之外加入對模型的限制或偏好，叫正則化；它改變我們願意接受的解。

$J_{\text{total}} = J_{\text{data}} + \alpha P(\mathbf{w})$。第一項量資料誤差，P 是權重懲罰，$\alpha \geq 0$ 控制相對比重。

若資料誤差採總和或平均，尺度不同，同一個數值的 alpha 也有不同作用；不能直接跨設定照抄。

模型 A：資料誤差 0.10、懲罰 4。模型 B：資料誤差 0.20、懲罰 1；先固定 $\alpha = 0.1$。

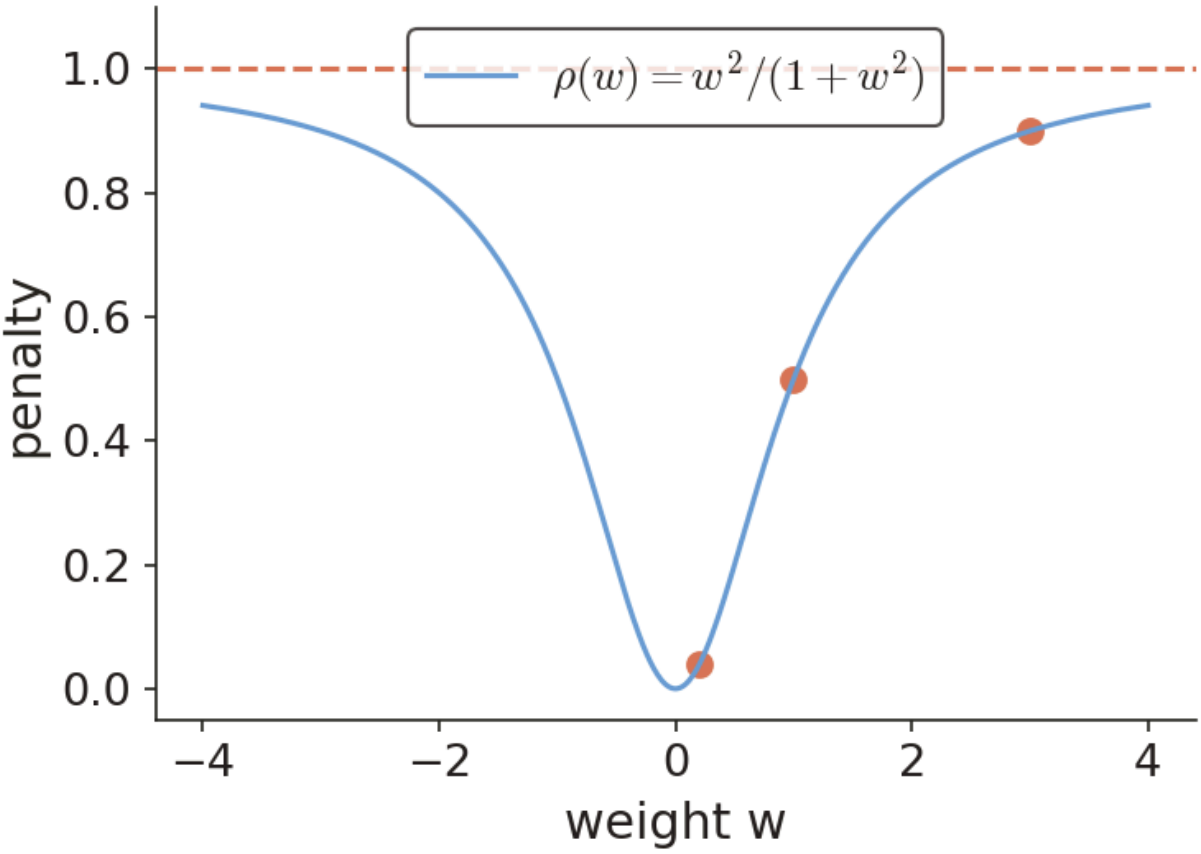
$J_A = 0.10 + 0.1 \times 4 = 0.50$；$J_B = 0.20 + 0.1 \times 1 = 0.30$。因此此目標選 B。

若 $\alpha = 0$，反而選 A。alpha 應以驗證資料選擇；總代價較小不等於測試誤差必然較小。

飽和懲罰：$\rho(w) = w^2/(\tau^2 + w^2)$，$\tau > 0$ 是尺度；權重很大時懲罰接近 1，稱為飽和。

懲罰總和 $P = \sum_i \rho(w_i)$。取 $\tau = 1$：$\rho(0.2) = 0.04/1.04 \approx 0.0385$，$\rho(1) = 0.5$，$\rho(3) = 0.9$。

用絕對值比較尺度：$|w| \ll \tau$ 才是接近零的區段，不是只比較帶正負號的 w 和 tau。

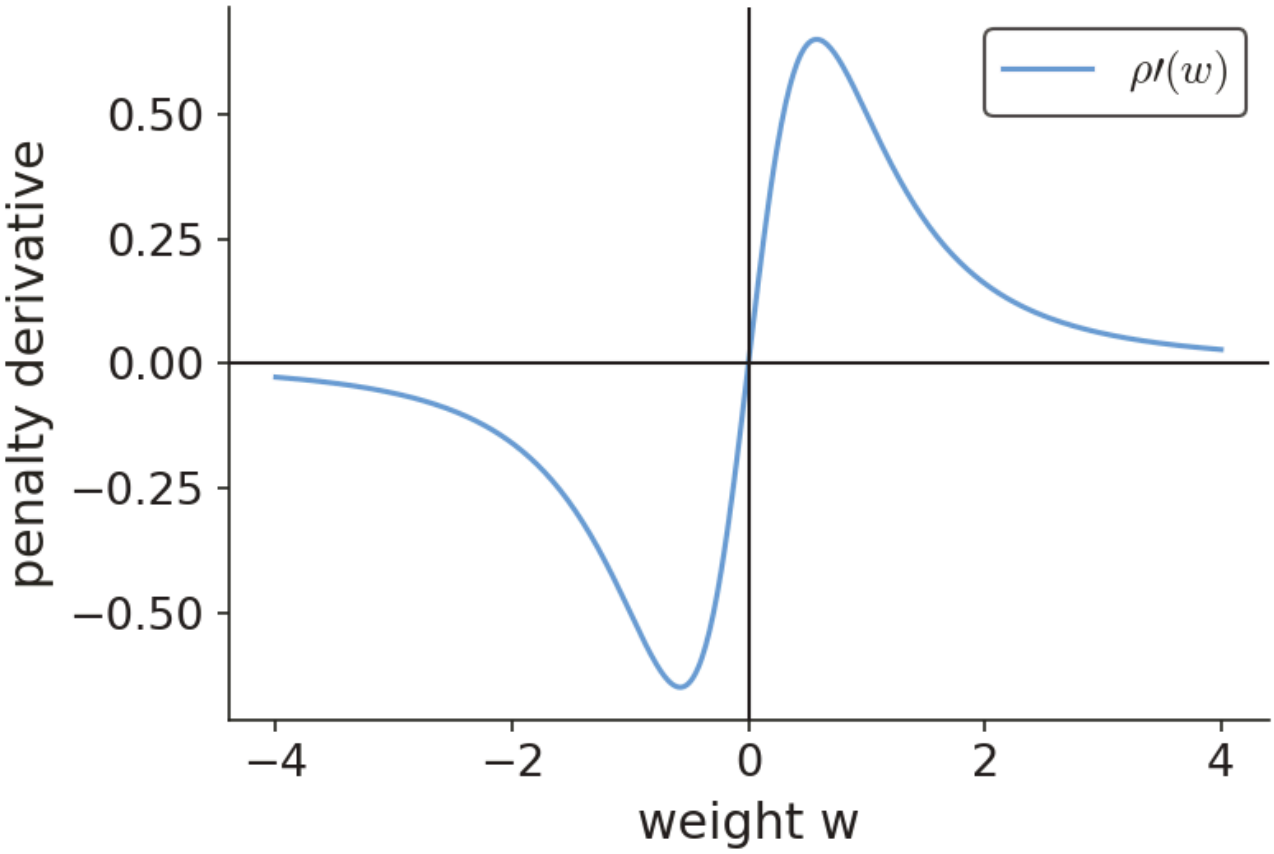


圖說 `lec05-kp11-rho`：[補充] 先看圖中的對照與標籤，再用本段數字核對；圖內的模型示意不代表實驗精確曲線。〔功能：精準度、具象化〕

$\rho'(w) = 2\tau^2 w/(\tau^2 + w^2)^2$。在 $w = 0$ 時導數是 0；有限步更新不保證恰好到零。

權重消除：訓練時促進縮小，再定期把小於門檻的權重設零或刪除，稱為權重消除。

門檻以 $|w_i| < \varepsilon$ 判斷；epsilon 是刪除門檻，tau 是懲罰尺度，兩者用途不同。



圖說 `lec05-kp11-gradient`：［補充］先看圖中的對照與標籤，再用本段數字核對；圖內的模型示意不代表實驗精確曲線。〔功能：精準度、具象化〕

單元輸出與權重範數也需要考慮

一條連線不是整個單元，一個單元也不是整條訊號路徑。把這些尺度分開，才能理解為何參數數量並非唯一複雜度指標。

來源還考慮對神經元輸出加懲罰，鼓勵某些單元反應變小；不是只對單一連線計分。

單元輸出小，仍可能被很大的下一層權重放大；應檢查整條路徑及刪除後的資料表現。

刪連線、刪單元、縮小數值是三種不同操作，必須分別記錄。

來源引述兩層 sigmoid 網路的結果：在小訓練誤差與權重範數限制等條件下，複雜度項包含 $A^3\sqrt{\log d/N}$。

A 是每個單元權重絕對值和的共同上界；d 是輸入維度，N 是樣本數。這只是來源的量級摘要，並非完整機率界。

固定 d、N，把 A 加倍，此項變為 $2^3 = 8$ 倍；不能把它直接當成分類錯誤率。

級聯相關法用新單元補殘差

另一條路從小架構出發。輸入側先找與殘差有關的反應，凍結後再讓輸出側降低誤差；兩個階段不能混成同一個訓練目標。

殘差：真實目標減去目前預測，$e_n = t_n - \hat{y}_n$，稱為殘差；n 是樣本編號。

級聯相關法：每次增加一個能回應目前殘差的隱藏單元，再重訓輸出，稱為級聯相關法。

新單元接收原輸入與先前隱藏單元；先訓練它的輸入側權重，之後凍結這些權重。

候選輸出 v 與殘差 e 的單輸出教學分數：$S = |\sum_n (v_n - \bar{v})(e_n - \bar{e})|$；橫線代表樣本平均。

取 $e = (-1, 1)$：候選 $v = (-1, 1)$ 得 $S = |-1 \times (-1) + 1 \times 1| = 2$；常數候選 $v = (1, 1)$ 中心化後為零，得 $S = 0$。

選好候選並凍結輸入側後，重訓輸出側權重以降低平方誤差；這裡的 S 未除標準差，不是 Pearson 係數。

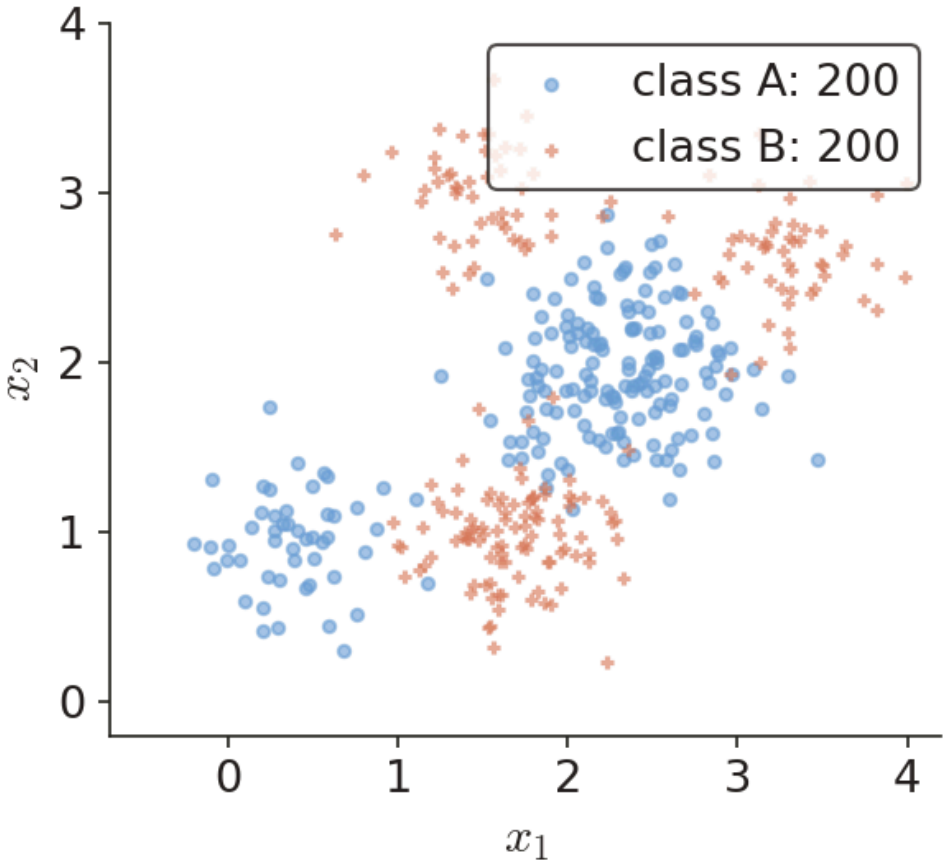
把來源模擬報告與本次計算分開

下面完整保留來源的重要設定與報告數字。重新抽樣的散點圖只檢查分布，權重長條只比較報告數量；沒有用教學示意冒充重跑原實驗。

A 類四個均值：$(0.4, 0.9), (2.0, 1.8), (2.3, 2.3), (2.6, 1.8)$；B 類：$(1.5, 1.0), (1.9, 1.0), (1.5, 3.0), (3.3, 2.6)$。

每群 50 點，共 $8 \times 50 = 400$。每群協方差 $0.08I$；I 是二維單位矩陣，標準差為 $\sqrt{0.08}$，不是 0.08。

圖用相同分布設定與固定種子重新抽樣，只核對資料分布，不是原始樣本，也沒有重跑網路訓練。



圖說 `lec05-kp11-data`：［補充］先看圖中的對照與標籤，再用本段數字核對；圖內的模型示意不代表實驗精確曲線。〔功能：精準度、具象化〕

網路為 2–3–2–1，logistic 活化的斜率參數為 1，目標為 1／0；本教材計入偏置的參數數為 $9 + 8 + 3 = 20$。

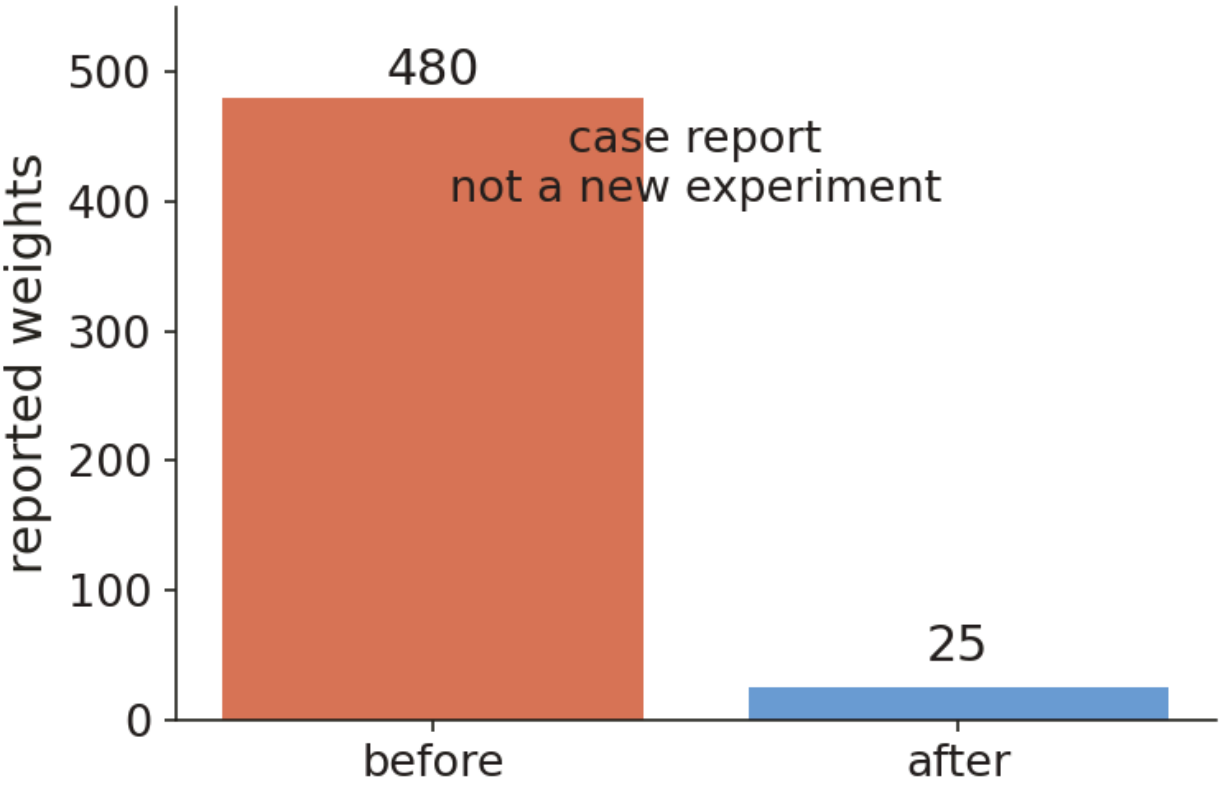
來源的動量設定：$\mu = 0.05, \alpha = 0.85$；自適應動量：$\mu = 0.01, \alpha = 0.85, r_i = 1.05, c = 1.05, r_d = 0.7$。

此處 mu 是學習率，alpha 是動量係數，r_i、r_d 是學習率放大與縮小倍率，c 是觸發縮小的代價比門檻；同名 alpha 在正則化頁用途不同。來源報告批次模式下自適應動量較快。

來源報告：兩個各 20 單元的隱藏層，先訓練含 480 權重的模型，每 100 輪檢查顯著度，最後保留 25 個權重。

剩下比例 $25/480 \approx 0.0521$，約 5.21%；刪除 $480 - 25 = 455$ 個，約 94.79%。

來源報告效能改善，原圖邊界由彎曲變得近似直線；此案例不能保證剪枝普遍提升泛化。

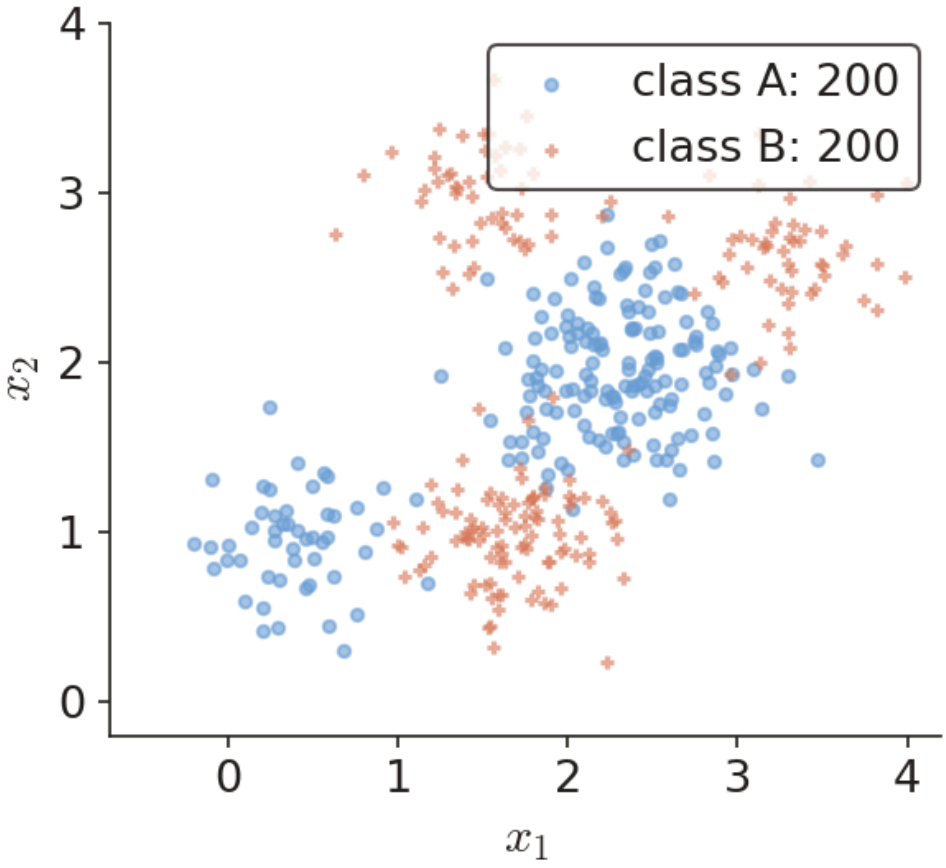


圖說 `lec05-kp11-counts`：［補充］先看圖中的對照與標籤，再用本段數字核對；圖內的模型示意不代表實驗精確曲線。〔功能：精準度、具象化〕

補充示範：取輸入分數 $r = x_2 - 0.6x_1 - 1$，連續輸出 $p = 1/(1 + e^{-r})$，以0.5為門檻。這不是來源訓練出的模型。

在二維座標鋪網格、計算每點 p、畫出 $p = 0.5$ 等高線；只有類別值才會在 0 與 1 間翻轉。

網格解析度、門檻與座標範圍都要記錄；平滑的圖形不等於正確率比較。



圖說 `lec05-kp11-boundary`：［補充］先看圖中的對照與標籤，再用本段數字核對；圖內的模型示意不代表實驗精確曲線。〔功能：精準度、具象化〕

完整二階補償、練習與解答

想再深入時，可以比較其他權重固定與允許補償的差異。最後兩題回到可手算的顯著度及懲罰，檢查是否真的理解操作。

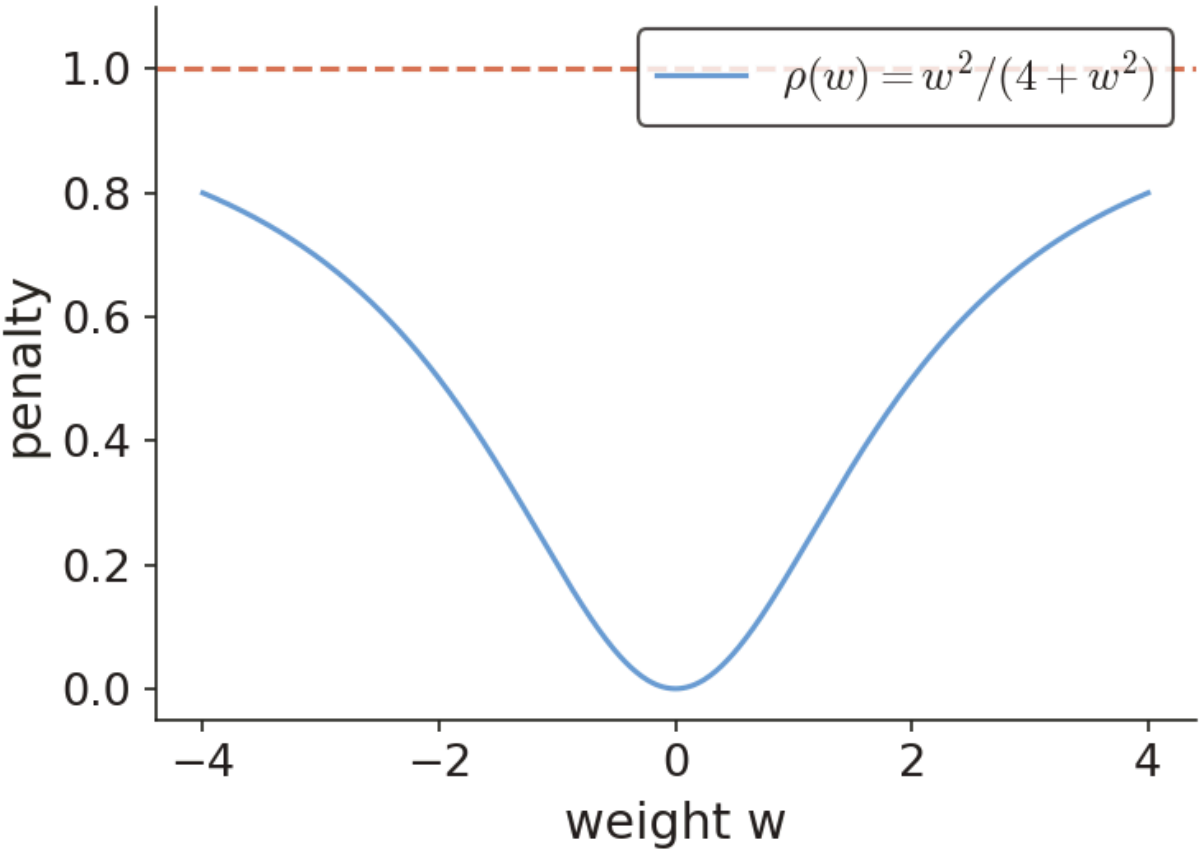
補充二次例子：$H = \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix}$，刪除 $w_1 = 0.5$，所以 $\delta w_1 = -0.5$。

若 $\delta w_2 = 0$，代價為 $\frac{1}{2} \times 4 \times 0.5^2 = 0.5$。允許補償時，$\Delta J = 0.5 - 0.5\delta w_2 + (\delta w_2)^2$。

對 delta w2 微分得 $-0.5 + 2\delta w_2 = 0$，取 $\delta w_2 = 0.25$；代價 $0.5 - 0.125 + 0.0625 = 0.4375$，比 0.5 小。

題 1：C 的權重 0.5、曲率 8；D 的權重 2、曲率 0.1。依顯著度先刪誰？提示：先算 $s = Hw^2/2$。

題 2：取 $\tau = 2, w = 2$，算 $\rho(w)$。它是否已經代表這個權重被刪掉？提示：區分懲罰和實際操作。

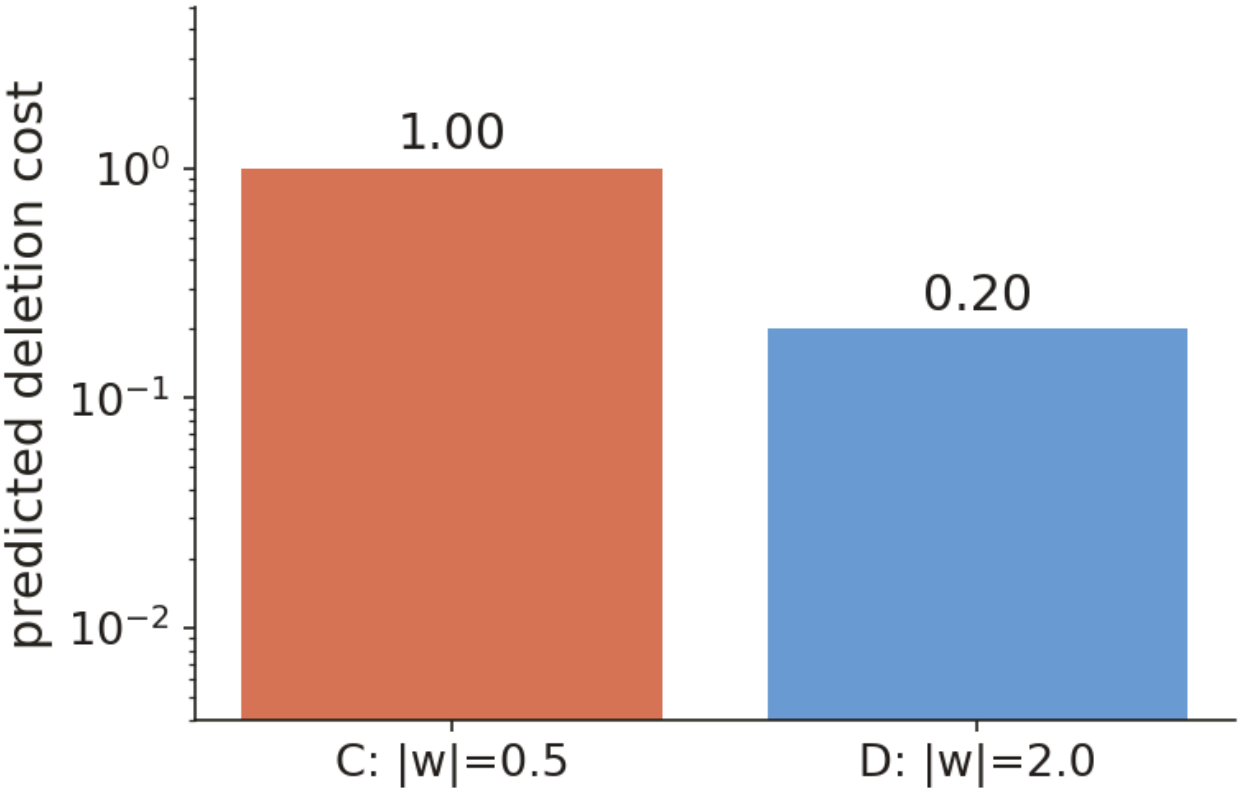


圖說 `lec05-kp11-rho-practice`：[補充] 先看圖中的對照與標籤，再用本段數字核對；圖內的模型示意不代表實驗精確曲線。〔功能：精準度、具象化〕

題 1：$s_C = \frac{1}{2} \times 8 \times 0.5^2 = 1$；$s_D = \frac{1}{2} \times 0.1 \times 2^2 = 0.2$。所以依估計先刪 D。

題 2：$\rho(2) = 2^2/(2^2+2^2) = 4/8 = 0.5$。權重仍是 2，只有執行設零或移除才叫刪除。

驗算：較大權重也可有較小顯著度。下一個 KP 改問：能否一開始就讓多條連線共用少數參數？



圖說 `lec05-kp11-saliency-practice`：［補充］先看圖中的對照與標籤，再用本段數字核對；圖內的模型示意不代表實驗精確曲線。〔功能：精準度、具象化〕

把 Taylor 近似的條件寫完整

將目前權重向量記為 $\mathbf{w}$，擾動記為 $\delta\mathbf{w}$。若代價二次可微，在附近可寫成

$$J(\mathbf{w}+\delta\mathbf{w}) - J(\mathbf{w}) \approx \nabla J(\mathbf{w})^T \delta\mathbf{w} + \frac{1}{2}\delta\mathbf{w}^T H \delta\mathbf{w}.$$

接近駐點才可忽略第一項。對角近似是計算上的簡化，並不代表所有神經網路的權重真的互相獨立。若只刪一個權重且其餘固定，二階交叉項因其他擾動為零而消失；若讓其他權重補償，則必須重新考慮非對角元素。本講義末尾的 2×2 例子，正好展示這個差別。

飽和懲罰的導數

令 $u = w^2$、$v = \tau^2 + w^2$。由商數微分法則，

$$\rho'(w) = \frac{2w(\tau^2 + w^2) - w^2(2w)}{(\tau^2 + w^2)^2} = \frac{2\tau^2 w}{(\tau^2 + w^2)^2}.$$

正權重的導數為正，梯度下降的懲罰部分往零拉；負權重則往相反方向拉回零。很大的權重處導數也很小，因為曲線已飽和。這不是凸的 L1 懲罰，也不能保證有限次更新得到精確零。

來源報告的計數疑義

來源報告剪枝模型有兩個各20單元的隱藏層及480權重，但沒有完整交代輸入、輸出及偏置的計數口徑。不能反推一個唯一架構，再把推得的數字當成原文事實。400樣本的2–3–2–1模擬與480→25的剪枝展示，分開記錄，不假定是同一批資料。

不直接求二階導數時的數值檢查

只沿第i個權重改動小步長h，其他權重固定，可用中心差分估計

$$H_{ii} \approx \frac{J(\mathbf{w} + h\mathbf{e}_i) - 2J(\mathbf{w}) + J(\mathbf{w} - h\mathbf{e}_i)}{h^2}.$$

$\mathbf{e}_i$ 是第i個座標為1、其餘為0的方向；h 是差分步長，不是刪除門檻。取 $J(w) = (w - 0.5)^2$、目前 w=0.5、h=0.1，三個代價為0.01、0、0.01，估得 $(0.01 - 2 \times 0 + 0.01)/0.01 = 2$，與解析二階導數一致。步長太大會有近似誤差，太小可能有浮點相消；不能把差分公式當成完全精確的黑盒。

術語表與符號提醒

中文	English
剪枝	Pruning
曲率	Curvature
海森矩陣	Hessian
顯著度	Saliency
正則化	Regularization
飽和懲罰	Saturating penalty
權重消除	Weight elimination
殘差	Residual
級聯相關法	Cascade correlation

依本段定義讀取符號，特別區分權重、分數、模型預測與損失；不同實驗的同名超參數不一定有相同用途。

來源與補充範圍

- Chapter 4, KP11，讀取日期：2026-10-25。
- 480→25、每100輪檢查與兩組動量參數均為來源報告；本次沒有重跑這些實驗，也沒有原始精確曲線。Bartlett結果只有來源量級摘要，未讀得原始完整定理，不作無條件誤差證書。
- Source reference codes: [Lecu 90], [Hass 93], [Wein 90], [Bart 98], [Fahl 90].
- 來源原圖已檢視：KP10 Figure 4.14；KP11 Figure 4.15、4.16。本教材用自己的圖解講解，沒有把來源圖片或精確實驗曲線冒充新結果。
- 本文使用來源的歷史引用代碼，不宣稱已取得其所有原始論文；無法核對的完整定理與實驗細節均保留限制。