KP17 通用近似定理

> 程度：大學三年級
>
> 圖型識別｜第四章 §4.16

簡報閱讀與下載

學習目標

- 能說明多項式、一層 sigmoid 網路與 RBF 都是通用近似器，差別在誤差下降的速度與最佳化的難易。
- 能說出 Weierstrass 定理與龍格現象，並看懂一維平滑目標與高維脊函數的不同結果。
- 能說明固定基底與資料自適應基底的差別，以及多層為什麼可能更有效率。

KP17 通用近似定理

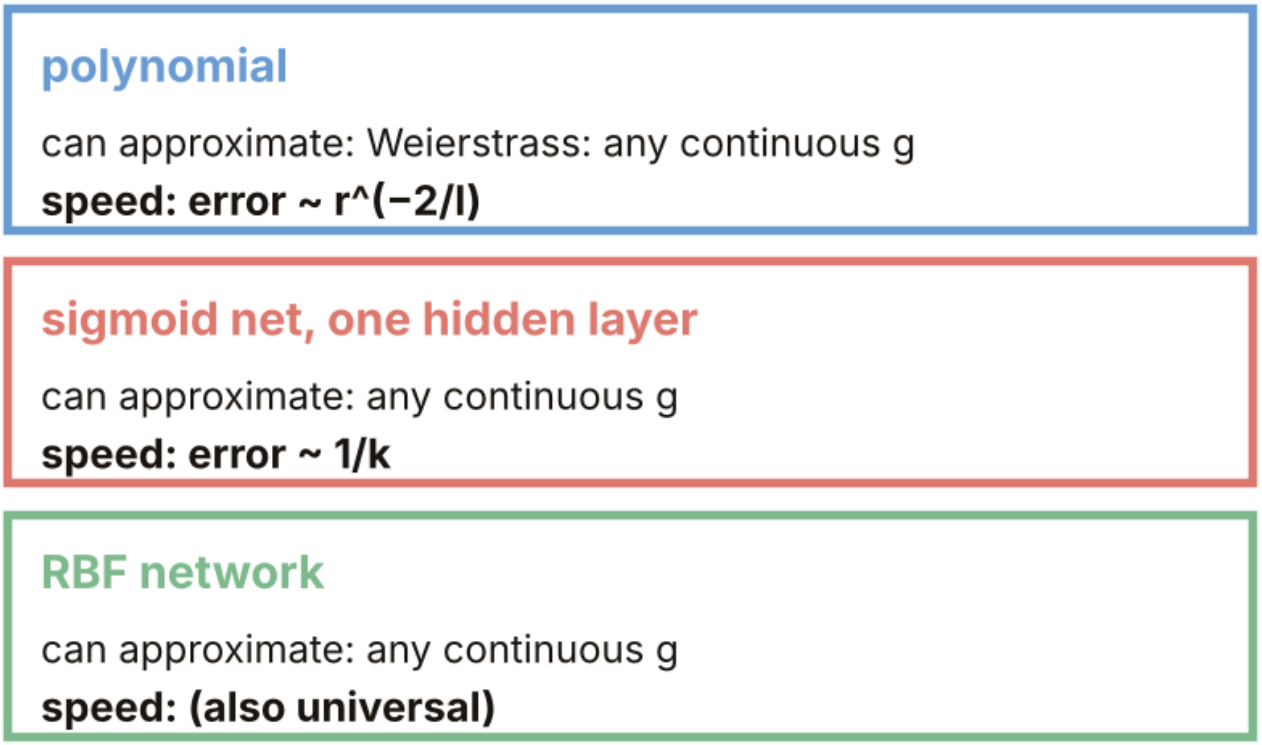
一句話重點：多項式、sigmoid 網路、RBF 都是通用近似器，通用近似是入場券而不是競爭優勢；真正的差別在誤差下降的速率（多項式 $O(r^{-2/l})$ 對網路 $O(1/k)$）與最佳化的難易。

1. 入場券

白話說明：哪一種新座標最後能逼近任何函數？誰又逼近得最快？

通用近似定理：節點夠多（或階數夠高），就能把緊緻集上的任何連續函數逼近到任意小的誤差。緊緻集指有界又含邊界的範圍，例如區間 $[0, 1]$。多項式（Weierstrass 定理）、一層 sigmoid 網路、RBF 網路都成立；差別在誤差下降的速度與最佳化難不難。

圖說 `lec05-kp17-summary`：三個通用近似器與它們的速度。



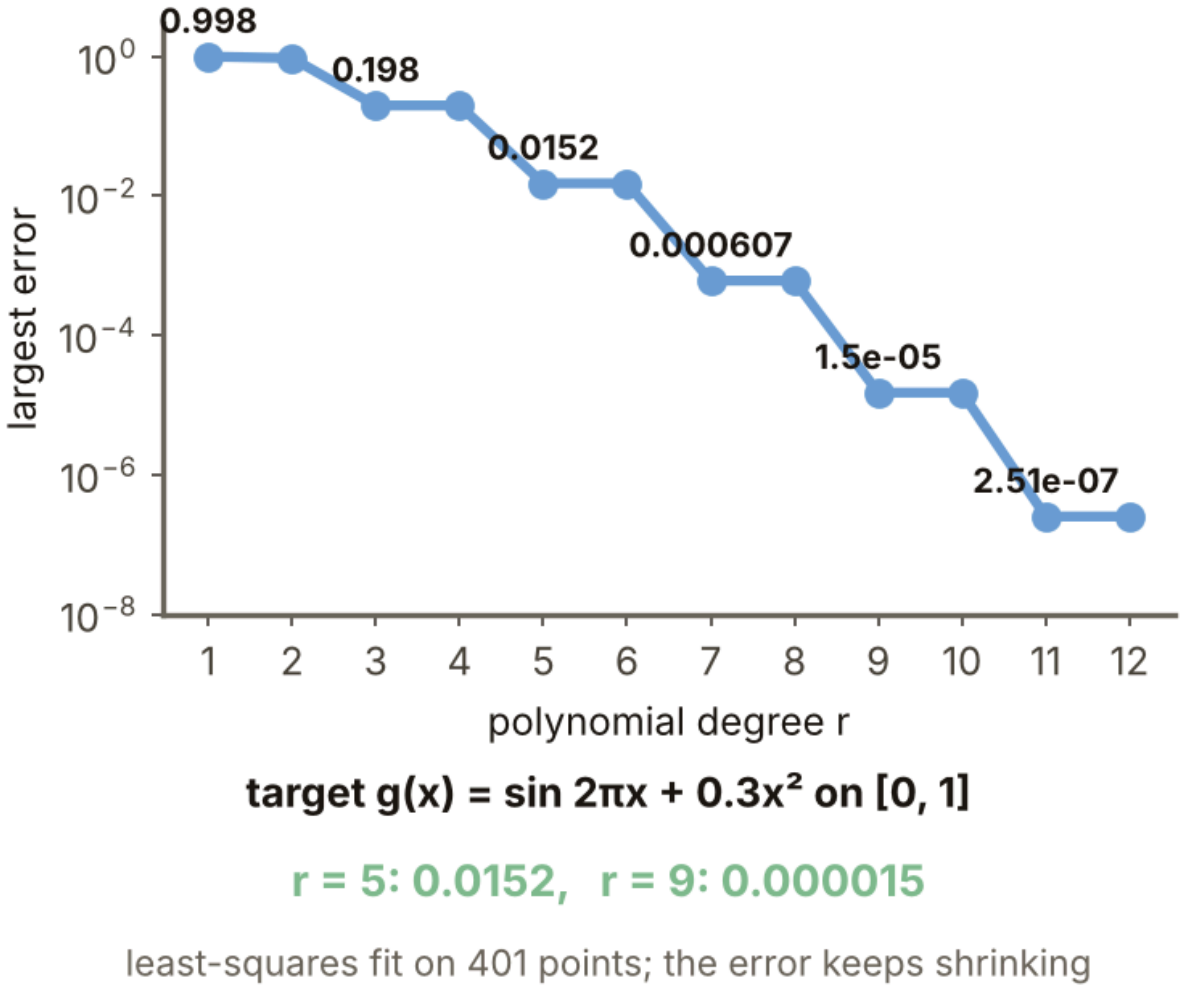
2. 多項式的保證

正式定義（Weierstrass 定理）：緊緻集 S 上的連續函數 g，對任何 $\epsilon > 0$，存在 r 階多項式 ϕ 使

$$|g(x) - \phi(x)| < \epsilon, \qquad \forall x \in S.$$

例子（本講義設計）：$g = \sin 2\pi x + 0.3x^2$，$[0, 1]$，401 點最小二乘；最大誤差 $r = 1, 3, 5, 7, 9, 11$：$0.998, 0.198, 0.0152, 0.000607, 0.000015, 2.5 \times 10^{-7}$。最大誤差是整個區間最差的一點，不是平均；階數 $2m - 1$ 與 $2m$ 誤差相同，因為偶數部分只是 t^2 加常數（$t = 2x - 1$），$r = 2$ 就配完，之後全靠奇數階。

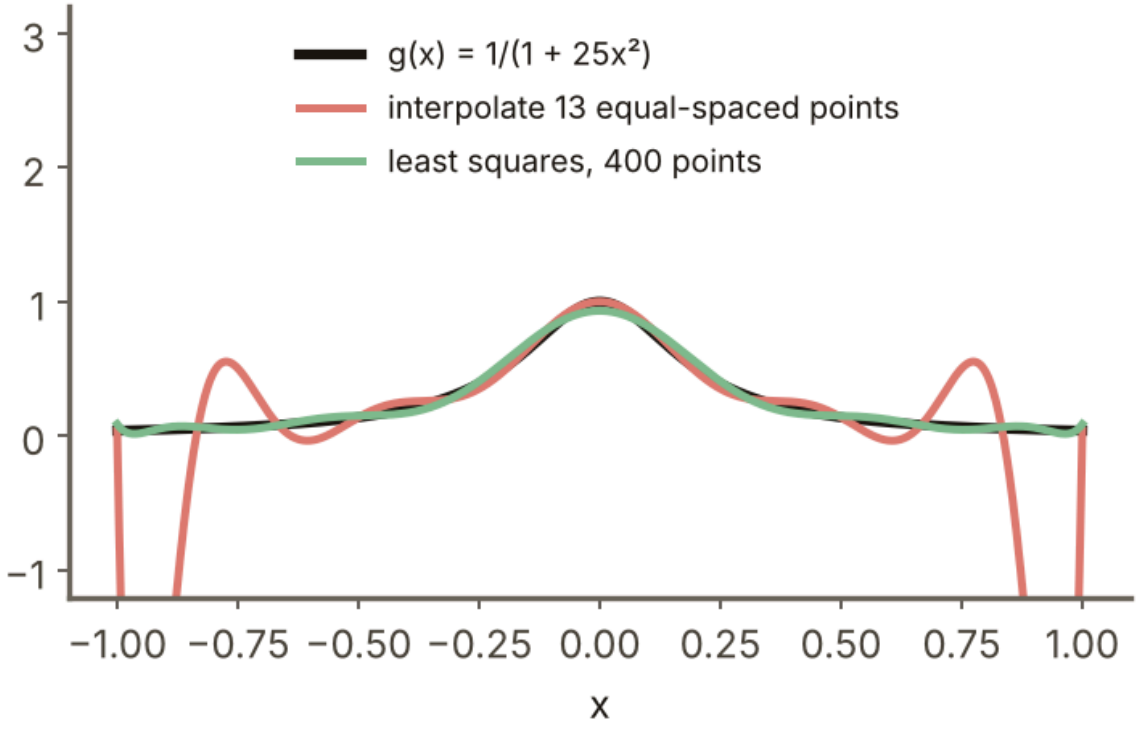
圖說 `lec05-kp17-polyerr`：多項式最大誤差對階數。



3. 龍格現象

龍格現象：用等距的點內插（強迫多項式通過每個取樣點）高階多項式，端點附近會劇烈擺動，誤差反而變大。**常見迷思**：階數越高擬合越好。例子：$g = 1/(1+25x^2)$，$[-1,1]$；等距內插 $r = 4, 8, 12, 16, 20$ 的最大誤差 $0.44, 1.05, 3.66, 14.4, 59.8$；同一函數用 400 點最小二乘，$0.33, 0.15, 0.068, 0.031, 0.014$，降得慢但穩。來源也提醒高階多項式有連乘的數值誤差與自由參數太多的問題，折衷是分段近似。

圖說 `lec05-kp17-runge`：龍格函數與兩種 12 階多項式。



degree 12: interpolation error 3.66, least squares 0.068

equal-spaced degrees 4, 8, 12, 16, 20 → 0.44, 1.05, 3.66, 14.4, 59.8

a high order alone does not give a good fit

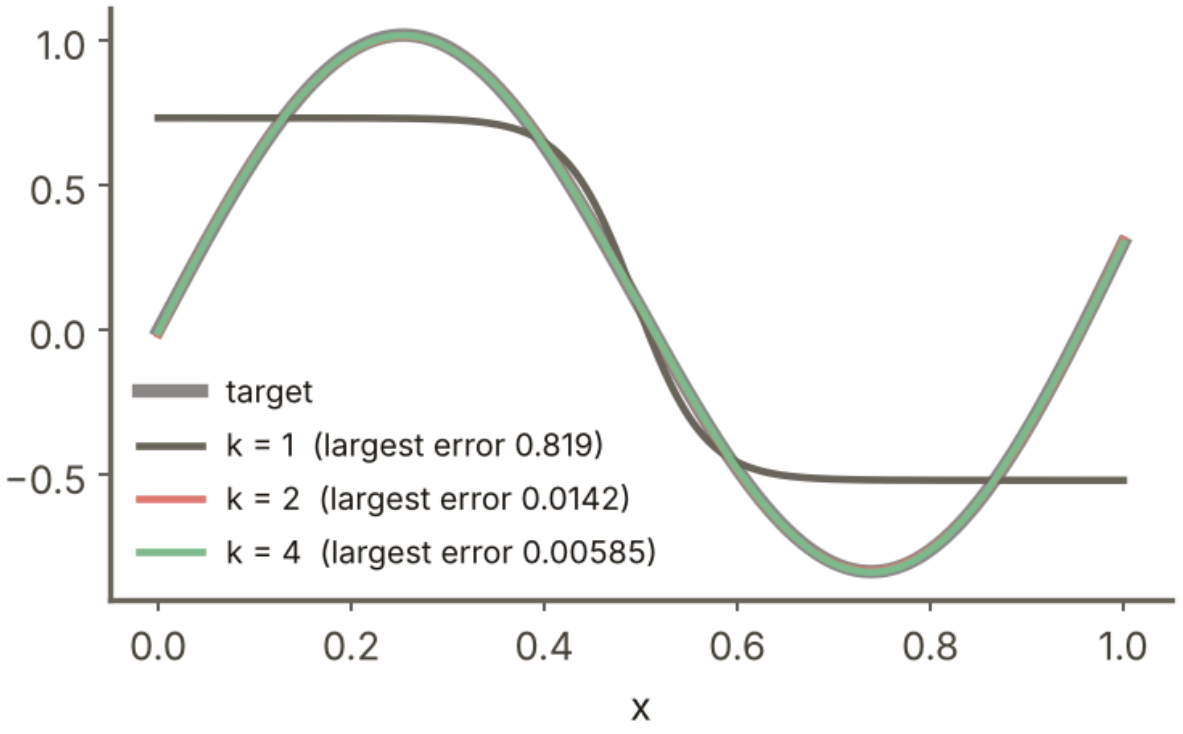
4. sigmoid 網路

擠壓函數：把任何輸入壓進一個有限範圍的單調遞增函數，例如 sigmoid。定理（來源引 Cybenko、Funahashi、Hornik 等）：活化函數是擠壓函數時，單隱藏層、k 夠大的網路

$$\phi(x) = \sum_{j=1}^{k} w_j^o f\left(w_j^{hT} x\right) + w_o^o$$

能把緊緻集上的連續函數逼近到任意誤差。同一個目標、$k = 1, 2, 3, 4, 6, 8$、8 個隨機起點取最好：最大誤差 $0.819, 0.0142, 0.0056, 0.0058, 0.0045, 0.0011$。

圖說 `lec05-kp17-mlpfit`：目標波形與 $k = 1, 2, 4$ 的擬合。



one hidden layer of k sigmoid nodes, best of 8 starts

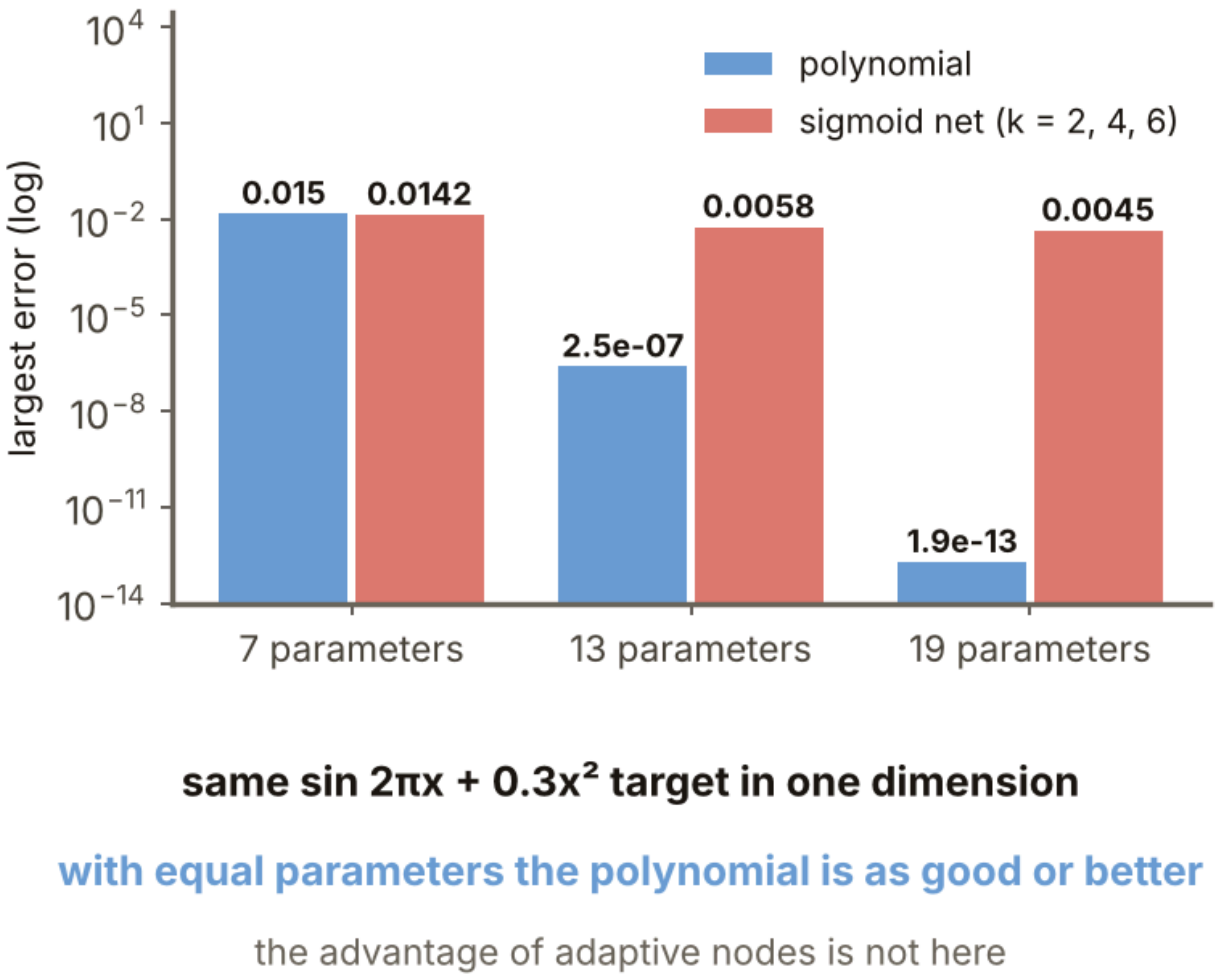
k = 1, 2, 3, 4, 6, 8: 0.819, 0.0142, 0.0056, 0.0058, 0.0045, 0.0011

two sigmoids already follow the wave

5. 一維公平比

7 個參數：多項式 $r = 6$ 是 0.0152；sigmoid 網路 $k = 2$（$3k + 1 = 7$）是 0.0142，差不多。13 個參數：多項式 $r = 12$ 是 2.5×10^{-7}；網路 $k = 4$ 是 0.0058。網路的優勢不在一維平滑目標；定理說的速率差，要到高維才看得出來。

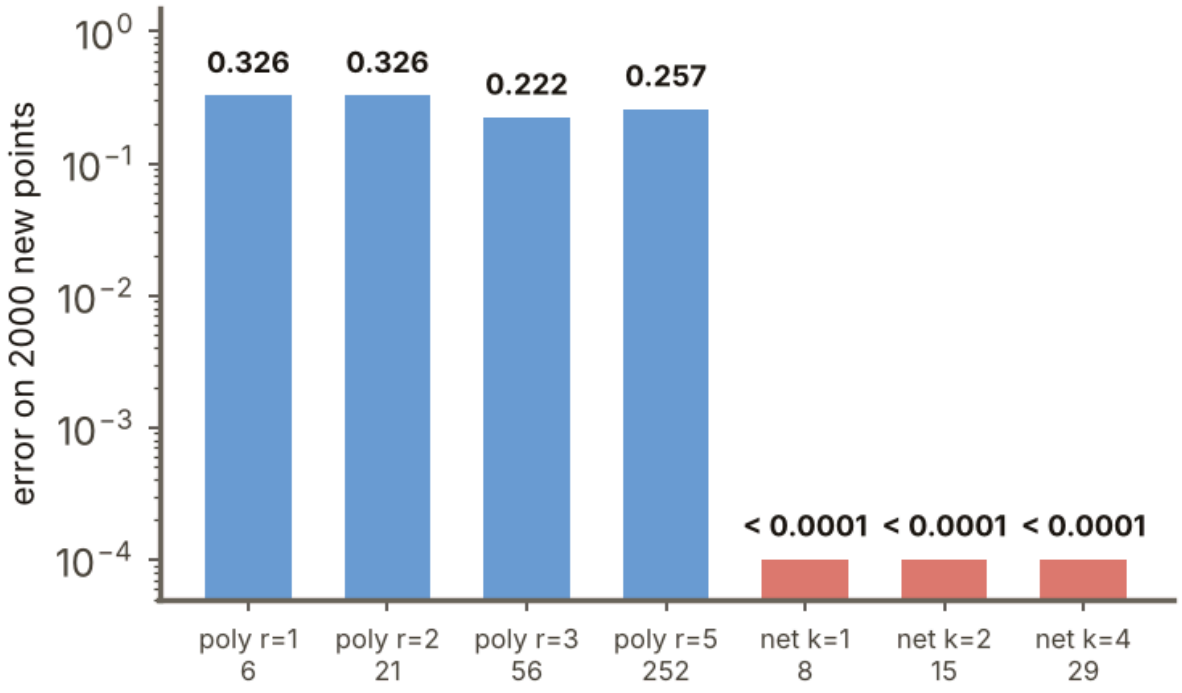
圖說 `lec05-kp17-equal`：相同參數量的最大誤差。



6. 高維

例子（本講義設計）：輸入 $l = 5$（標準常態），目標 $\tanh(2w^T x)$（只依賴單一方向 w 的「脊函數」），3000 個訓練點、2000 個新點，誤差為均方根。多項式 $r = 1, 2, 3, 5$（6、21、56、252 項）新點誤差 $0.326, 0.326, 0.222, 0.257$；網路 $k = 1, 2, 4$（8、15、29 個參數）都低於 0.0001。註記：這個目標剛好是網路的形狀，是偏袒網路的設計，且常態輸入不是緊緻集。

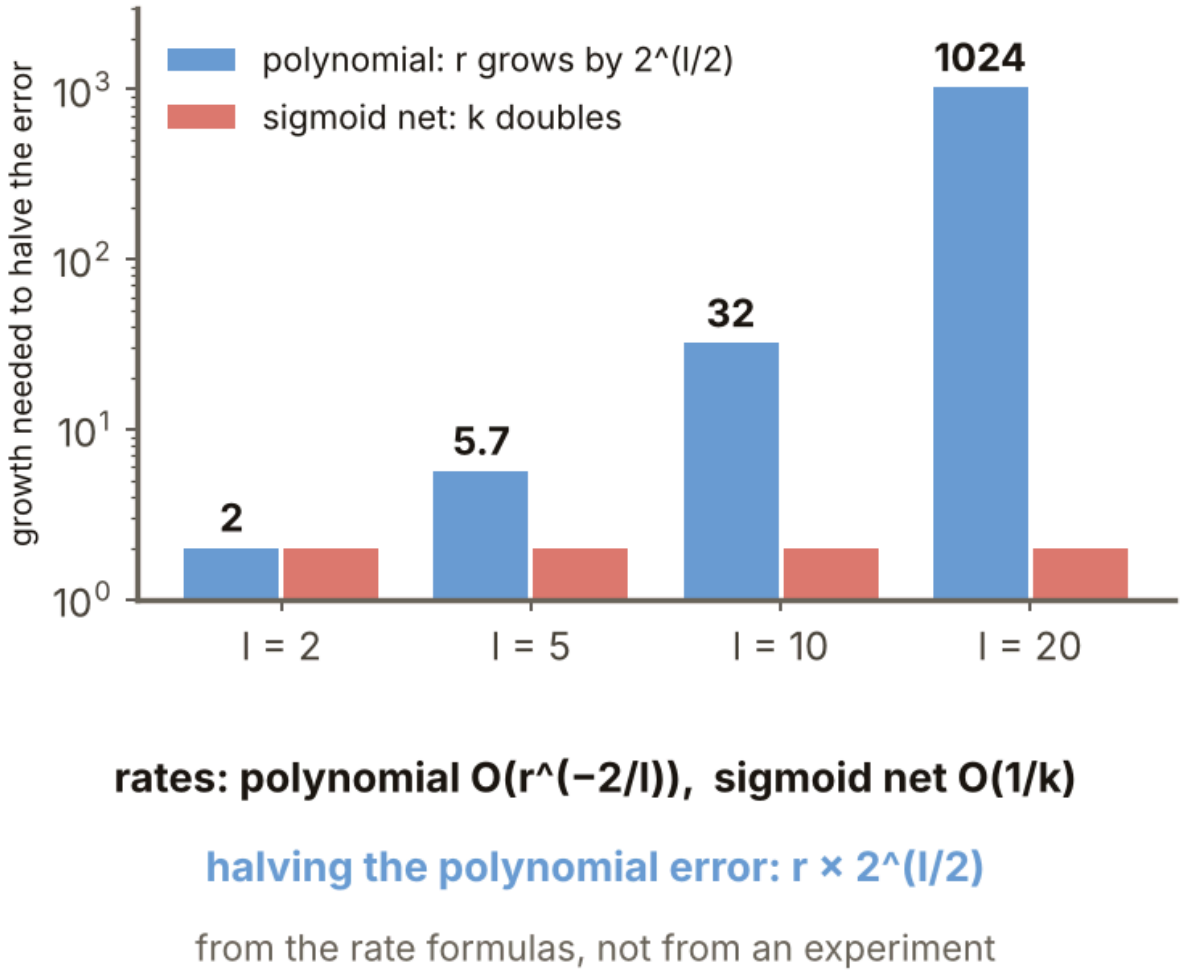
圖說 `lec05-kp17-ridge`：多項式與網路在 5 維脊函數上的新點誤差。



7. 速率

速率（Barron 93，來源）：多項式 $O(r^{-2/l})$；一層 sigmoid 網路 $O(1/k)$，輸入維度 l 完全沒出現在式子裡。誤差減半，多項式的 r 要乘 $2^{l/2}$：$l = 2, 5, 10, 20$ 是 $2, 5.7, 32, 1024$ 倍；網路的 k 永遠只要加倍。這是最壞情況的漸近速率，不是實測；平滑目標（如第 2 節）可快得多，r 與 k 也不是逐參數的比較。

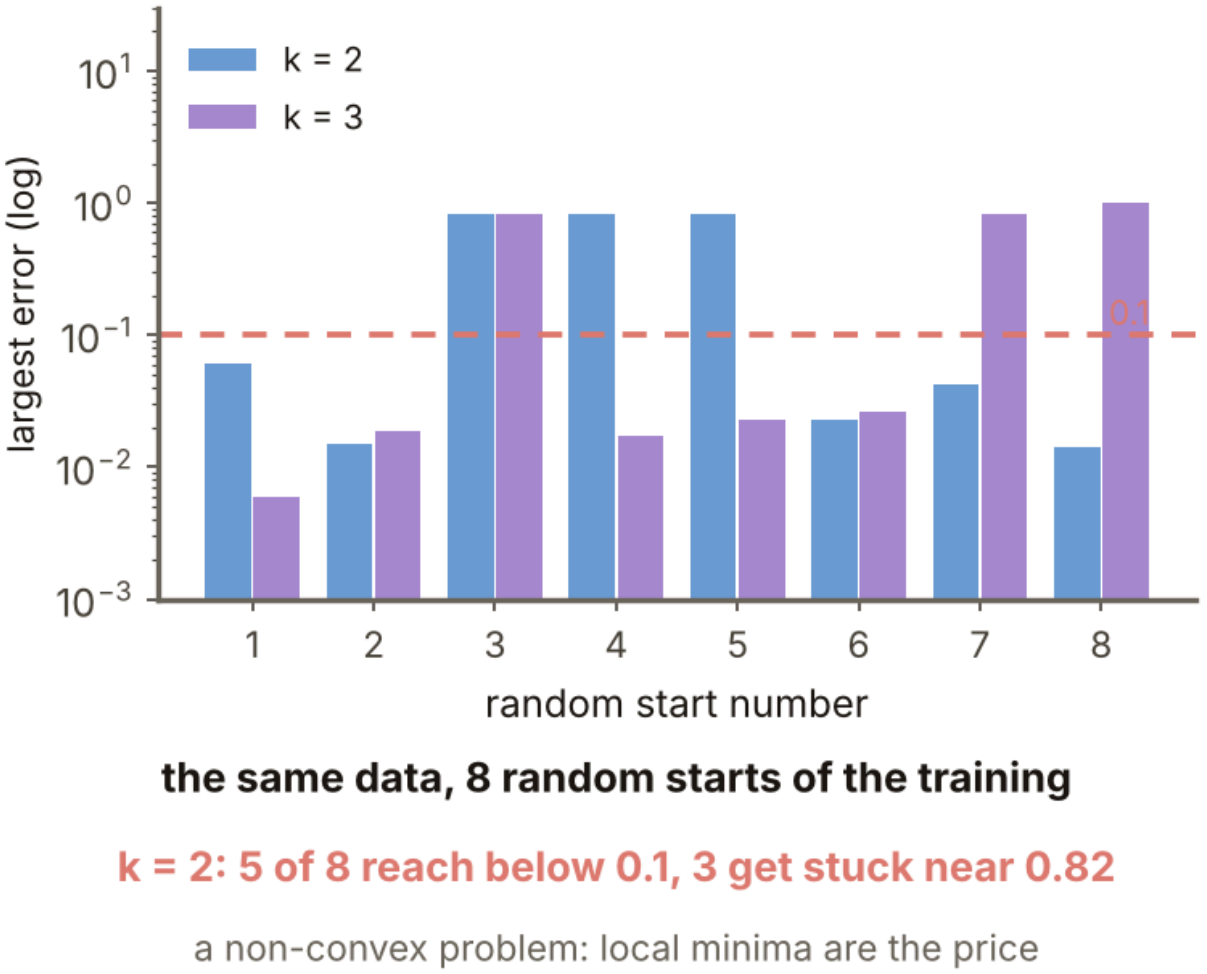
圖說 `lec05-kp17-halving`：誤差減半所需的增長。



8. 為什麼與代價

固定基底：像 $x_1^2 x_2$ 這種，不管資料長什麼樣都一樣的基底函數；多項式就是。**資料自適應基底**：$f(w^T x)$ 裡的 w 由資料最佳化出來的基底函數；網路的隱藏節點就是。來源說所有固定基底的展開，都逃不過誤差下降隨維度變慢的宿命。代價是最佳化從線性變成非線性：同一份資料 $k = 2$ 的 8 個隨機起點，5 個最大誤差低於 0.1，3 個卡在 0.82 附近（程式計算）。

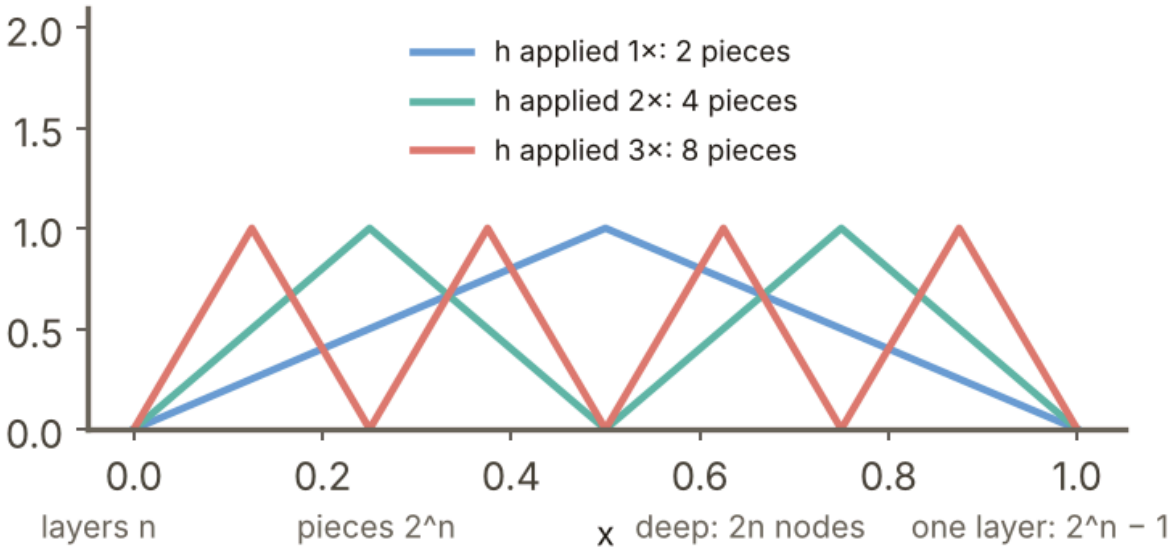
圖說 `lec05-kp17-restarts`：8 個隨機起點的最大誤差。



延伸：多層更有效、練習與解題示範

多層更有效：帽函數 $h(x) = 2\min(x, 1-x)$ 用 2 個 ReLU 節點（$\max(0, x)$ 這種折線型活化函數）做得出，原理與 sigmoid 相同；疊 n 層得 2^n 段直線，程式數過 $n = 1..4$：2、4、8、16。深的需 $2n$ 個節點；只有一個隱藏層的 ReLU 網路最多 $k+1$ 段，要 $2^n - 1$ 個。$n = 3, 6, 10$：深 6、12、20 個，單層 7、63、1023 個。來源說用多於一個隱藏層，可能以較少的神經元達到同樣的精度。

圖說 `lec05-kp17-hat`：帽函數疊層與節點數對照表。



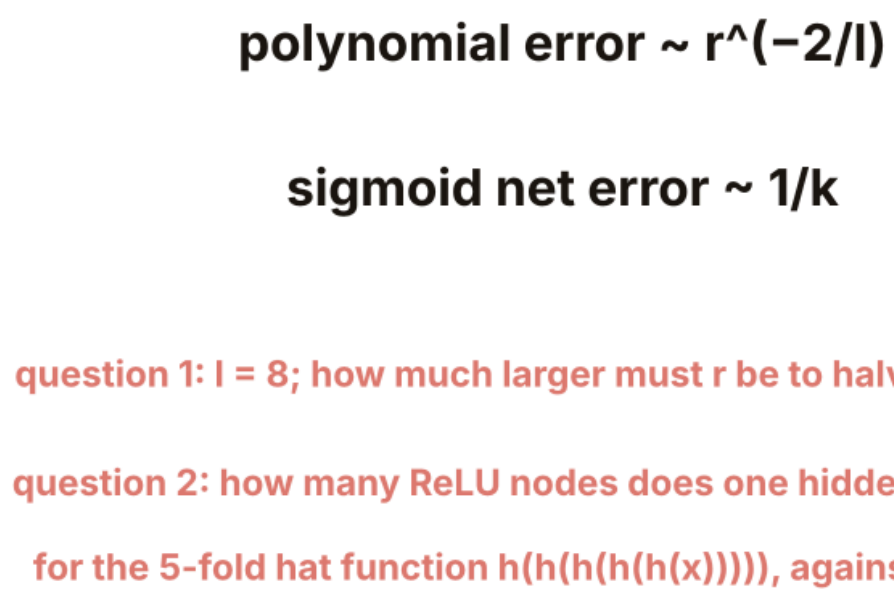
3	**8**	6	7
6	**64**	12	63
10	**1024**	20	1023

h(x) = 2 min(x, 1−x) costs 2 ReLU nodes per layer

小練習：

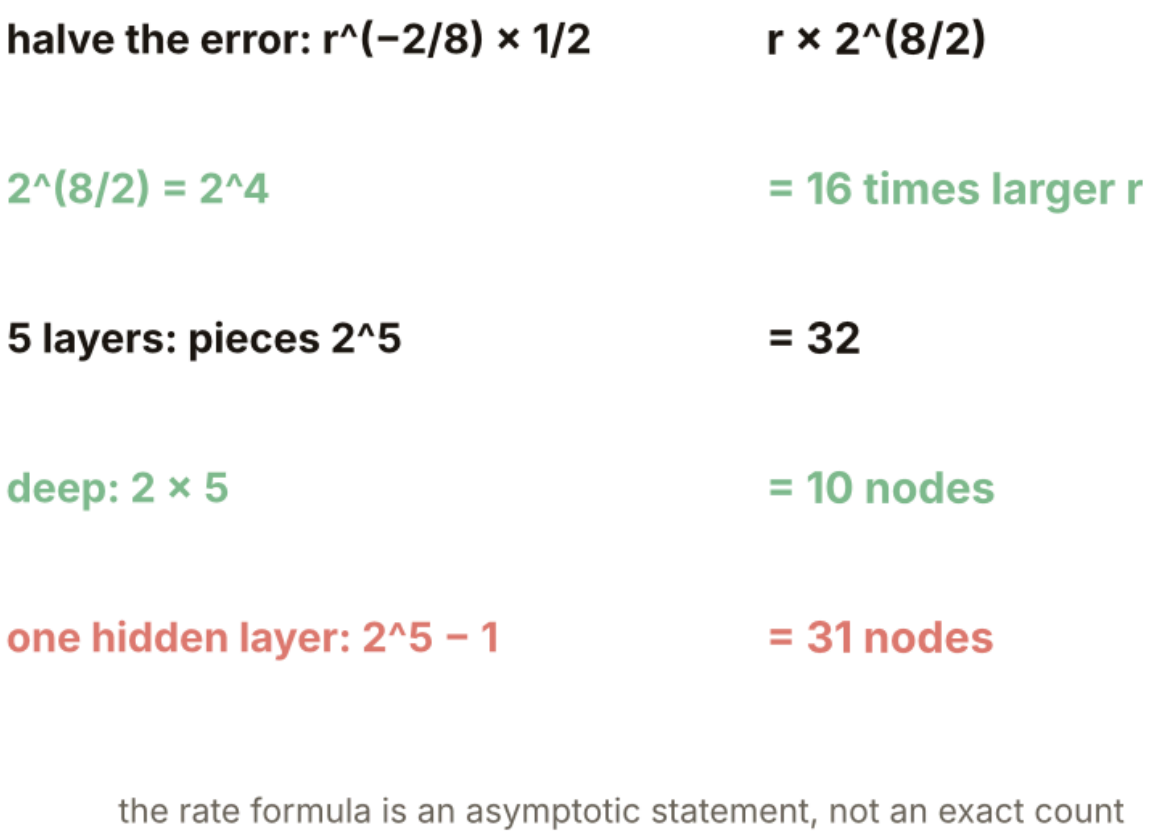
1. $l = 8$，多項式誤差 $\sim r^{-2/l}$。誤差減半，r 要乘多少倍？
2. 5 層帽函數有幾段？深網路要幾個 ReLU 節點、單隱藏層要幾個？

圖說 `lec05-kp17-practice`：練習的設定。



題 1、2 解題示範：① 減半 $r^{-2/8}$，r 要乘 $2^{8/2} = 2^4 = 16$ 倍。② 5 層有 $2^5 = 32$ 段；深網路 $2 \times 5 = 10$ 個節點；單隱藏層 $2^5 - 1 = 31$ 個。③ 核對：32 段要 31 個折點，單層 k 個節點最多 k 個折點，所以 $k \geq 31$；題 1 是漸近式，不是精確的實測。

圖說 `lec05-kp17-practice-sol`：兩題的計算。



術語與來源

中文	English
通用近似定理	Universal approximation theorem
龍格現象	Runge phenomenon
擠壓函數	Squashing function
固定基底	Fixed basis
資料自適應基底	Data-adaptive basis

來源：第四章 KP17，§4.16（2026-10-25 讀取）。Weierstrass 定理、sigmoid 網路的通用近似、$O(r^{-2/l})$ 對 $O(1/k)$ 的速率、固定對自適應基底的解釋、多層更有效率與「入場券」說法依來源；所有實驗（多項式與 sigmoid 網路的最大誤差、龍格現象、高維脊函數、隨機起點、帽函數的片段數）由本講義設計並重算（［補充］，（程式計算））。