KP25 Boosting 與 AdaBoost：把「弱」變「強」

> 程度：大學三年級
>
> 圖型識別｜第四章 §4.22

簡報閱讀與下載

學習目標

- 能推導 AdaBoost 的權重與 $\alpha_m = \frac{1}{2}\ln\frac{1-P_m}{P_m}$，並手算一輪權重更新。
- 能說明 AdaBoost 對過擬合相對免疫的邊距解釋，以及這個解釋的限制。
- 能說明 AdaBoost 在標籤有雜訊的困難任務上會退化的原因。

KP25 Boosting 與 AdaBoost：把「弱」變「強」

一句話重點：一個只比亂猜好一點的分類器，反覆針對「上次做錯的樣本」重新訓練並加權投票，訓練誤差可以被壓到任意低；但它不是萬靈丹。

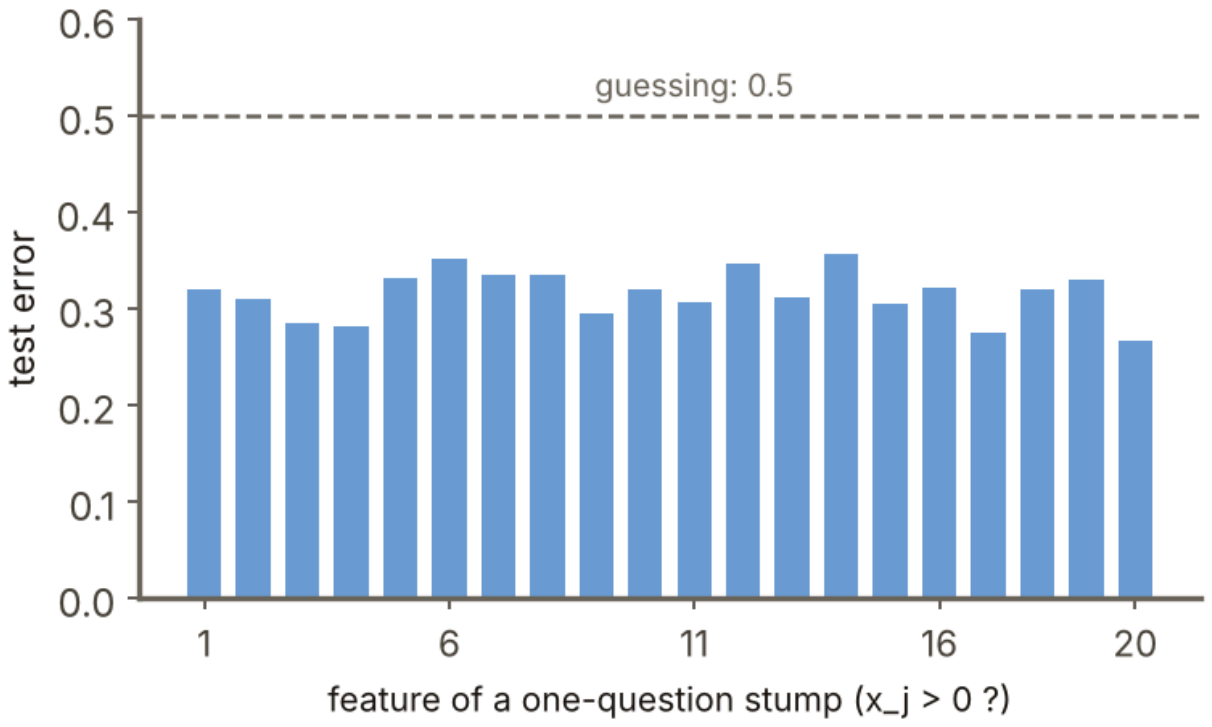
1. 弱變強

白話說明：弱分類器能不能被提升成強分類器？（標籤 $y \in \{\pm 1\}$，分類器輸出 $\phi \in \{\pm 1\}$。）

- **弱分類器**：錯誤率只比亂猜（0.5）好一點點的分類器。
- **決策樁**（stump）：只問一個特徵的一個問題，例如「$x_j > 0$？」的樹。

例子（本講義設計）：20 維兩類高斯（均值 $\mp a$，$a = 2/\sqrt{20}$），訓練 200、測試 400 點；20 個「$x_j > 0$？」決策樁測試錯誤 27% 到 36%，平均 31.6%。機制：每輪換一個樣本權重分布，給最難（被分錯）的點更多權重，最後加權投票。

圖說 `lec05-kp25-weak`：20 個決策樁的測試錯誤。



each of the 20 stumps: test error 27% to 36%, mean 31.6%

best stump of round 1: training 25.5%, test 28.75%

better than guessing, but not by much

2. 權重的誕生

逐級最佳化：每次只最佳化新加入的分類器，先前的凍結：$F_m = F_{m-1} + \alpha_m \phi_m$。對指數損失（KP20）$\sum_i \exp(-y_i F(x_i))$ 逐級拆開：

$$J = \sum_i w_i \exp\big(-y_i \alpha \phi(x_i)\big), \qquad w_i = \exp\big(-y_i F_{m-1}(x_i)\big).$$

w_i 不含 α 也不含 ϕ，就是樣本權重；於是 ϕ_m 要最小化加權錯誤率 P_m（權重正規化為總和 1）。

圖說 `lec05-kp25-wts`：權重從指數損失長出來。

$$\text{minimize } \Sigma_i \exp(-y_i F_m(x_i)),\ F_m = F_{m-1} + \alpha\varphi$$

$$= \Sigma_i w_i \exp(-y_i \alpha \varphi(x_i))$$

$$w_i = \exp(-y_i F_{m-1}(x_i))$$

contains neither α nor φ: it is the sample weight

so φ must minimize the weighted error

$$P_m = \Sigma_i w_i \cdot [y_i \varphi(x_i) < 0]$$

weights are not a heuristic:

they fall out of the exponential loss

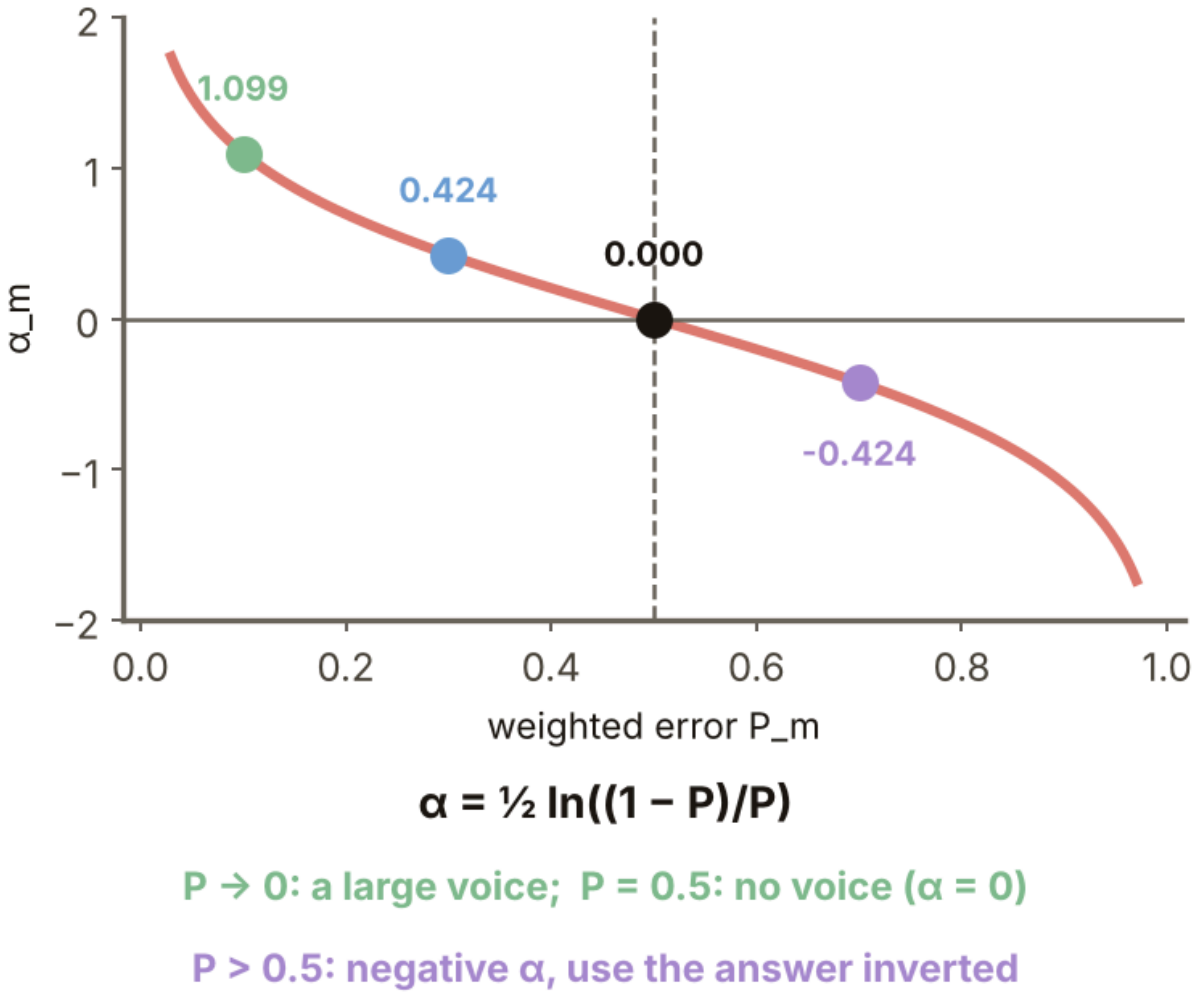
3. 話語權 α

正式定義：代回 J，$\alpha_m = \arg\min\{e^{-\alpha}(1-P_m) + e^{\alpha}P_m\}$，微分為零得

$$\alpha_m = \tfrac{1}{2}\ln\frac{1-P_m}{P_m}.$$

$P = 0.1$：1.099；0.3：0.424；0.5：0；0.7：-0.424。很準 → 話語權大；亂猜 → 0；比亂猜還差（$P > 0.5$）→ 負，把答案反過來用。

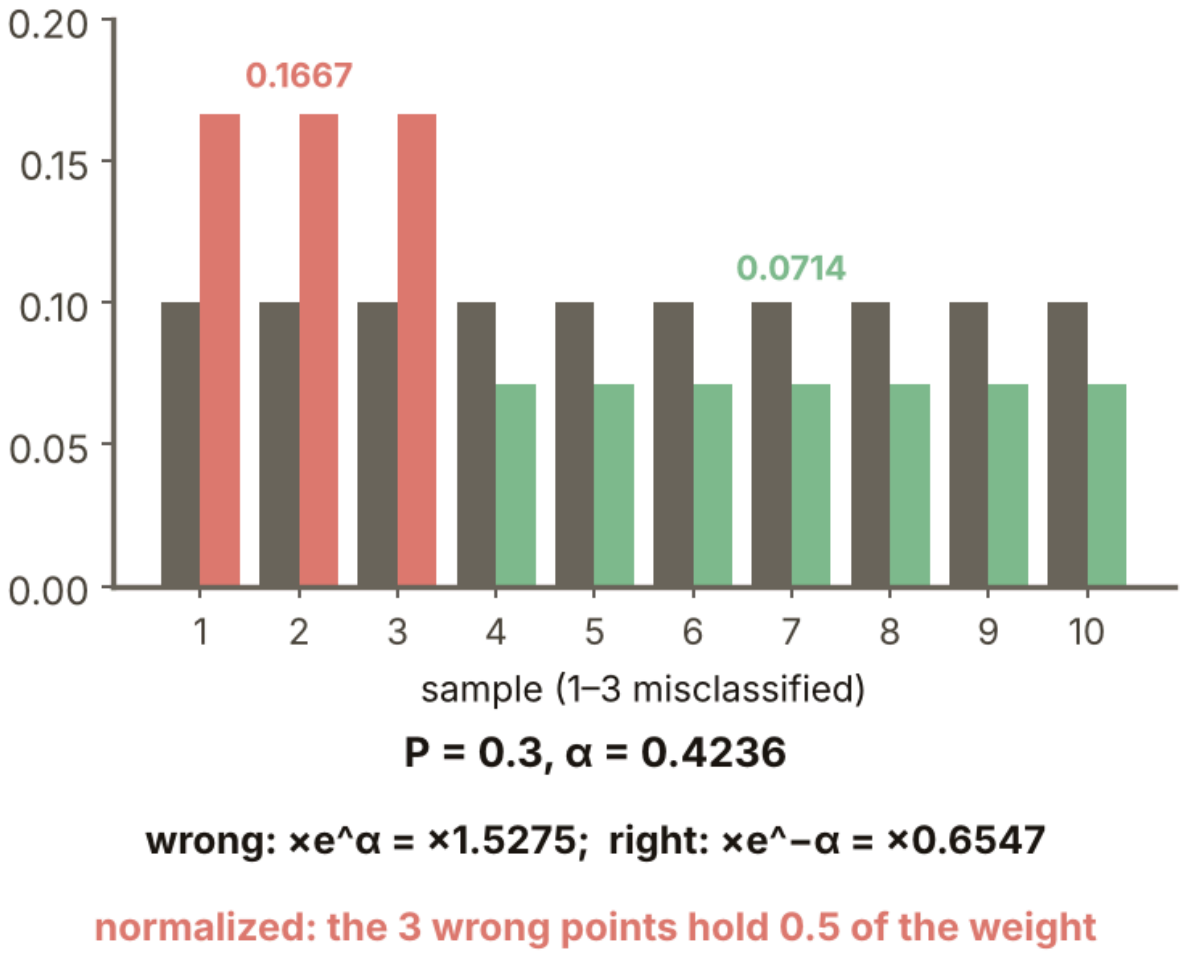
圖說 `lec05-kp25-alpha`：α 對加權錯誤率。



4. 權重更新

$w_i \leftarrow w_i \exp(-y_i \alpha_m \phi_m(x_i))/Z_m$；做錯（$y\phi < 0$）變大，做對變小。**手算**（本講義設計）：10 點各 0.1，錯 3 個：$P = 0.3$、$\alpha = 0.4236$；錯的乘 $e^{\alpha} = 1.5275$（0.1528），對的乘 $e^{-\alpha} = 0.6547$（0.0655）；$Z = 0.9165$。正規化後：錯的各 0.1667，對的各 0.0714；錯的三個合起來剛好 0.5，下一輪的 ϕ 必須先照顧它們。

圖說 `lec05-kp25-update`：更新前後的 10 個權重。



5. 演算法與設定

$w_i = 1/N$；重複：找最小化 P_m 的 ϕ_m、算 α_m、更新並正規化權重；最後 $f(x) = \text{sign}\sum_k \alpha_k \phi_k(x)$。**設定**（本講義重做 Example 4.3）：20 維兩類高斯、訓練 200 點、測試 400 點；每輪從所有特徵與門檻挑最好的決策樁；跑 2000 輪。第 1 輪：訓練錯誤 25.5%、測試 28.75%，比隨便一個固定決策樁（平均 31.6%）好。

圖說 `lec05-kp25-algo`：AdaBoost 演算法。

start: $w_i = 1/N$

repeat:

find φ_m **minimizing** P_m **(weighted error)**

$\alpha_m = \tfrac{1}{2} \ln((1 - P_m) / P_m)$

$w_i \leftarrow w_i \exp(-y_i \alpha_m \varphi_m(x_i))$, **then divide by** Z_m

until a stopping rule is met

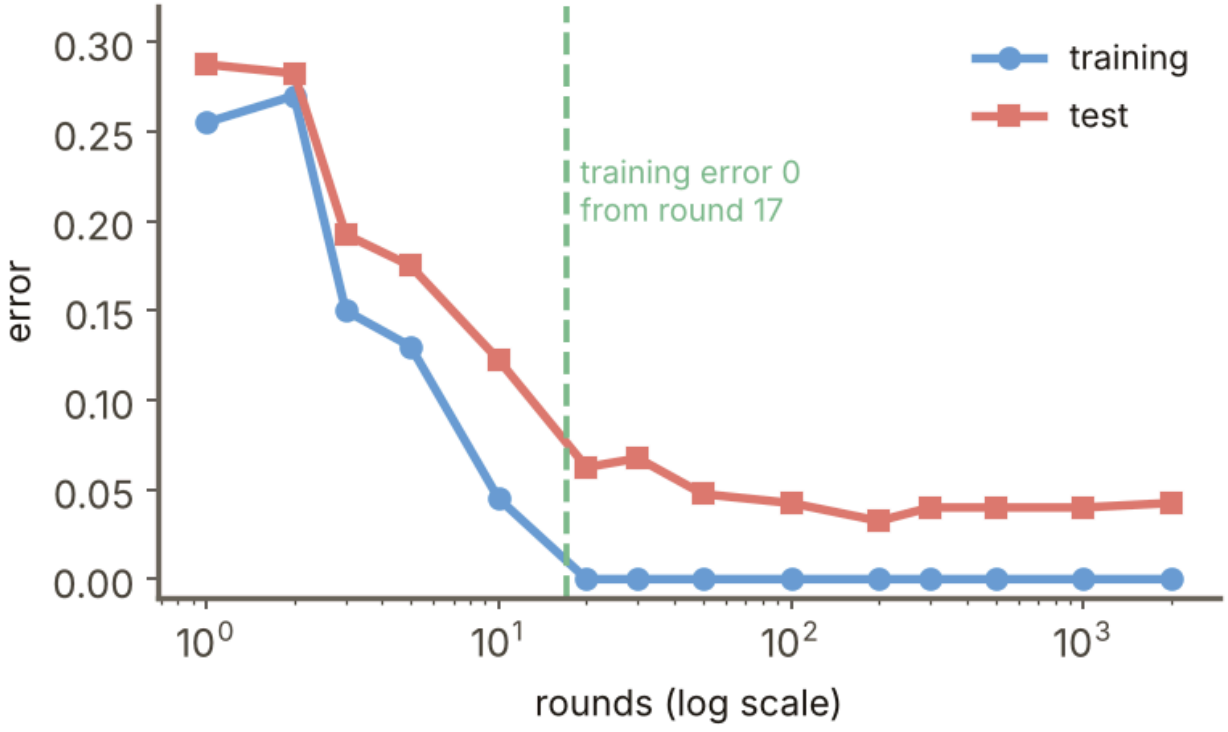
$f(x) = \text{sign}(\Sigma_k \alpha_k \varphi_k(x))$

Example 4.3: 20-D Gaussians, 200 training, 400 test points,
base classifier = a one-question stump

6. 錯誤曲線

訓練錯誤：第 1 輪 25.5%、10 輪 4.5%、第 17 輪起為 0。測試錯誤：28.75%（1）、12.25%（10）、4.75%（50）、3.25%（200）、4.0%（500）、4.25%（2000）。訓練錯誤歸零後測試錯誤還繼續降，約 200 輪後持平在約 4%，在抽樣誤差內沒有上升（400 個測試點，1% 只是 4 點）。

圖說 `lec05-kp25-curve`：訓練與測試錯誤對輪數（對數軸）。



test error: 28.7% (1), 12.2% (10), 3.25% (200), 4.25% (2000)

after training error reaches 0 the test error keeps falling

to about round 200, then stays flat near 4%

7. 邊距解釋

正規化邊距 $\text{margin} = yF(x)/\sum_k \alpha_k \in [-1,1]$：正的才分對，越大信心越高。上界（Schapire 等）：泛化誤差 $\lesssim \text{prob}\{\text{margin} < \gamma\} + O(\sqrt{V_c/(N\gamma^2)})$，與輪數 K 無關，這就是免疫力的來源。**實驗**（本講義設計）最小邊距：第 1 輪 -1.000、10 輪 -0.205、50 輪 $+0.148$、200 輪 $+0.203$、2000 輪 $+0.220$；邊距 < 0.1 的比例 25.5%、8.5%、0%。批評：這個上界很鬆（除非 N 到數萬），只能當定性解釋；逐級最佳化本身也是隱含的正則化。

圖說 `lec05-kp25-margin`：不同輪數的最小邊距與測試錯誤。

rounds	min margin	margin < 0.1	test
1	-1.000	25.5%	28.75%
10	-0.205	8.5%	12.25%
50	+0.148	0.0%	4.75%
100	+0.179	0.0%	4.25%
200	+0.203	0.0%	3.25%
2000	+0.220	0.0%	4.25%

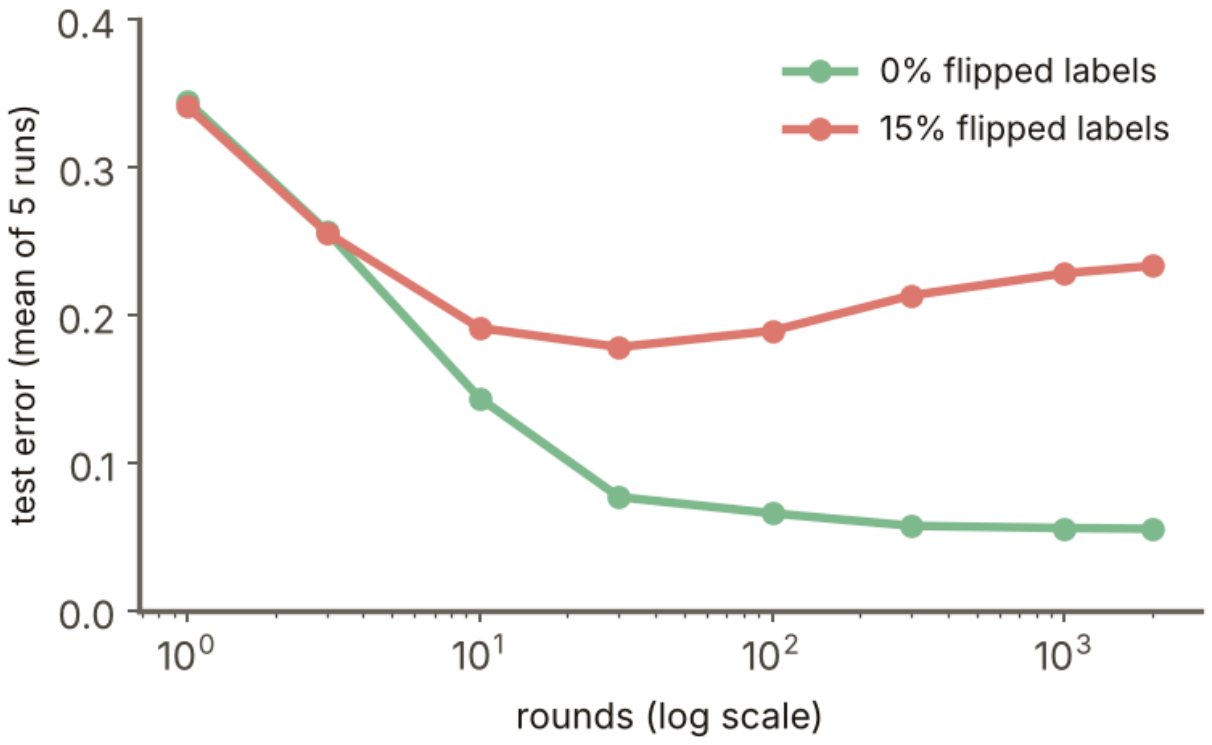
margin = yF(x) / Σα, in [−1, 1], positive when correct

boosting keeps raising the smallest margins

8. 不是萬靈丹

例子（本講義設計）：同類資料，訓練標籤隨機翻 15%；翻 0% 與 15% 各 5 次新抽樣平均（和前面單次實驗的數字不同；測試標籤乾淨）。測試錯誤：乾淨：14.4%（10 輪）→ 6.6%（100）→ 5.5%（2000）；翻 15%：19.1% → 18.9% → 23.3%，最低 17.8%（30 輪）。可能原因：指數損失對大負邊距的壞樣本懲罰過重；2000 輪後 15.5% 的翻標籤樣本占了 36% 的權重（其中一次實驗）。**常見迷思**：AdaBoost 永遠不會過擬合；在貝氏誤差高、標籤有雜訊的困難任務上它可能急劇退化（來源）。**怎麼記**：弱分類器 + 對錯的點加權 + 加權投票；權重由指數損失長出來，α 由加權錯誤率決定。

圖說 `lec05-kp25-noise`：標籤乾淨與翻 15% 的測試錯誤。



clean labels: 5.5% at the end

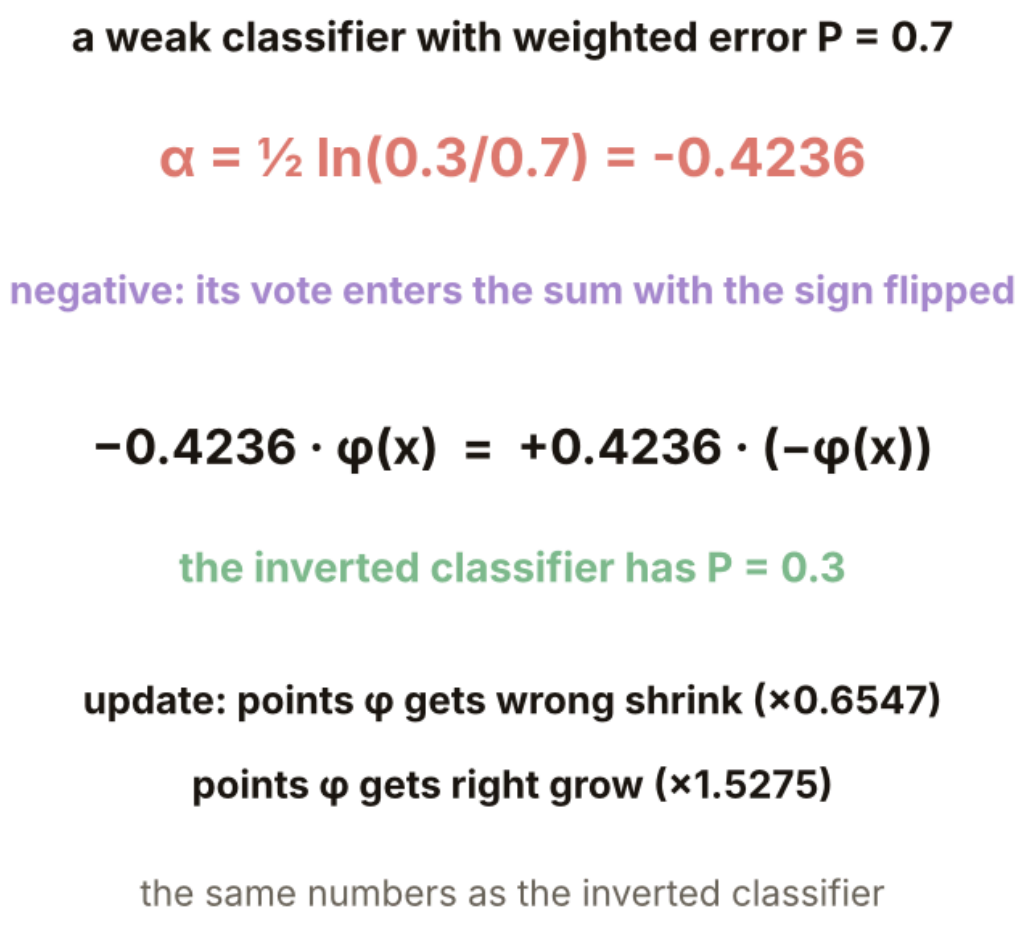
15% flipped: best 17.8% at round 30, 23.3% at 2000

after 2000 rounds 36% of the weight sits on the 15.5% flipped points

延伸：負的 α、練習與解題示範

負的 α：$P = 0.7 : \alpha = \frac{1}{2}\ln(0.3/0.7) = -0.4236$；$-0.4236\,\phi = +0.4236\,(-\phi)$，$-\phi$ 的加權錯誤率是 0.3。ϕ 做錯的點乘 $e^{-0.4236} = 0.6547$（變小），做對的乘 1.5275（變大），與反過來的分類器完全一樣。

圖說 `lec05-kp25-neg`：負 α 與反過來的分類器。



小練習：5 個樣本權重各 0.2，被 ϕ 分錯 1 個，加權錯誤率 $P = 0.2$。

1. α 是多少？
2. 更新並正規化後，每個樣本的權重是多少？

圖說 `lec05-kp25-practice`：練習的設定。

5 samples with equal weights 0.2; one is misclassified

weighted error P = 0.2

question 1: α for P = 0.2

question 2: new weights after the update and normalization

$$w_i \leftarrow w_i \exp(-y_i\, \alpha\, \varphi(x_i)) \,/\, Z$$

題 1、2 解題示範：① $\alpha = \frac{1}{2}\ln\frac{0.8}{0.2} = \frac{1}{2}\ln 4 = 0.6931$；$e^{\alpha} = 2$、$e^{-\alpha} = 0.5$。② 錯的 $0.2 \times 2 = 0.4$，對的 4 個各 $0.2 \times 0.5 = 0.1$；$Z = 0.8$；正規化：錯的 0.5，對的各 0.125。③ 核對：總和 $0.5 + 4 \times 0.125 = 1$；錯的點剛好占一半，與第 4 頁的 3 個點占 0.5 同一個規律：更新後，被舊 ϕ 分錯的權重總和恆為 0.5，舊 ϕ 的加權錯誤率變成 0.5，所以必須換新的 ϕ。若決策樁家族可取反，搜尋會直接選 $-\phi$（$P = 0.3$），負的 α 因而少見。

圖說 `lec05-kp25-practice-sol`：計算過程。

$$\alpha = \tfrac{1}{2}\ln(0.8/0.2) = \tfrac{1}{2}\ln 4 = 0.6931$$

$$e^{\alpha} = 2, \quad e^{-\alpha} = 0.5$$

$$\text{wrong: } 0.2 \times 2 = 0.4; \ \text{right } (\times 4): 0.2 \times 0.5 = 0.1 \text{ each}$$

$$Z = 0.4 + 4 \times 0.1 = 0.8$$

$$\text{normalized: wrong } 0.5, \ \text{right } 0.125 \text{ each}$$

$$\text{the misclassified sample now holds half the weight}$$

術語與來源

中文	English
弱分類器	Weak classifier
決策樁	Stump
逐級最佳化	Stage-wise optimization
正規化邊距	Normalized margin

來源：第四章 KP25，§4.22（2026-10-25 讀取）。弱學習的提升問題、指數損失與逐級最佳化、權重的來源、α 公式、權重更新、演算法、邊距解釋與上界很鬆的批評、不是萬靈丹、「怎麼記」依來源；決策樁的錯誤、10 點手算、重做 Example 4.3 的錯誤曲線與邊距表、15% 標籤翻轉實驗、負 α 與練習由本講義設計並重算（［補充］，（程式計算））。