KP26 類別不平衡問題

> 程度：大學三年級
>
> 圖型識別｜第四章 §4.23

簡報閱讀與下載

學習目標

- 能說明類別不平衡為什麼會損害分類器，以及為什麼準確率會騙人。
- 能說出資料層與代價敏感兩類對策，並比較它們的取捨。
- 能計算召回、精確率與平衡準確率。

KP26 類別不平衡問題

一句話重點：一類有一萬筆、另一類只有十筆時，「追求簡單」的分類器會理所當然地忽略稀有類，而稀有類往往正是我們真正在乎的那一類。

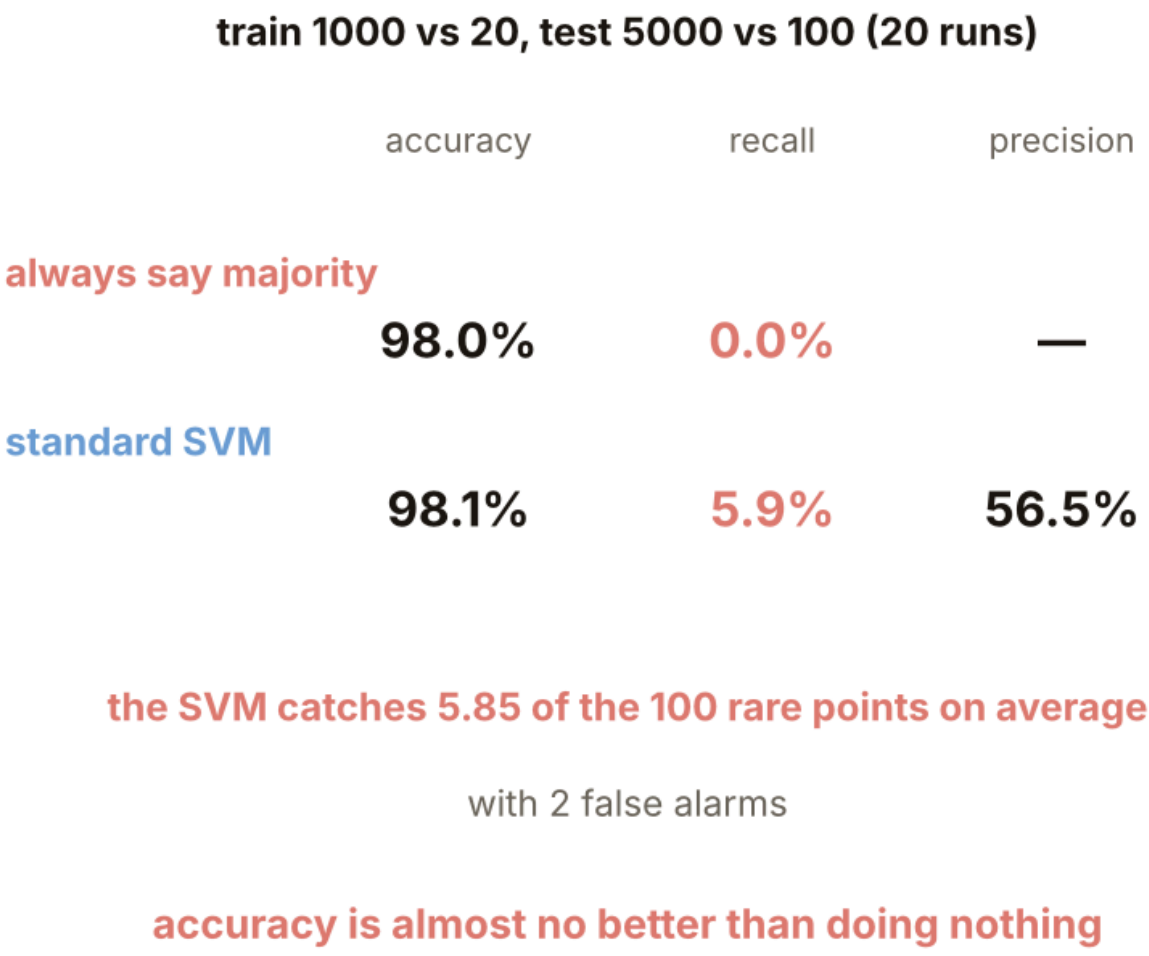
1. 準確率的陷阱

白話說明：資料裡有一類只有 20 筆時，連「準確率很高」都可靠嗎？

- **類別不平衡**：某一類樣本極多、另一類極少；常見於文字分類、罕見疾病、浮油偵測。
- **召回率**：少數類的點被抓到的比例；**精確率**：被判為少數類的點裡真的是少數類的比例。

例子（本講義設計）：兩類二維高斯（均值差 2），訓練 1000 對 20，測試 5000 對 100，20 次平均。全判多數：準確率 98.0%、召回 0；一般 SVM：98.1%、召回 5.9%、精確率 56.5%（平均抓到 5.85 個、誤報 2 個）。

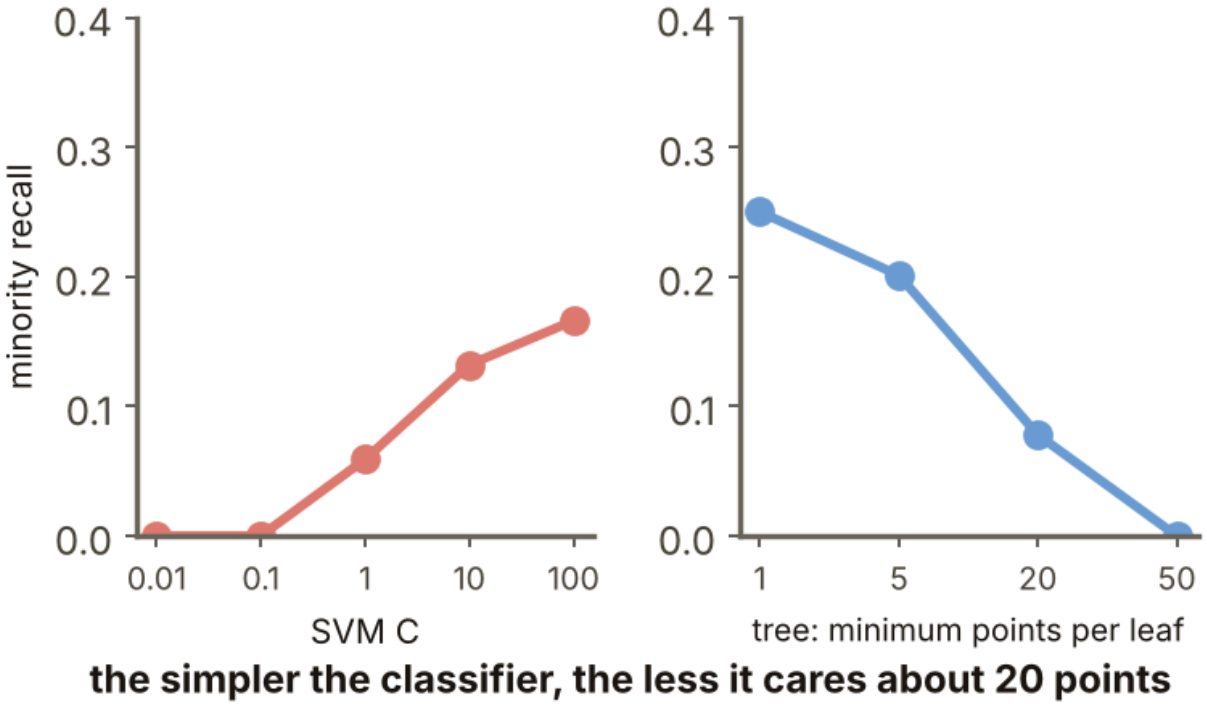
圖說 `lec05-kp26-trap`：全判多數與一般 SVM 的準確率、召回與精確率。



2. 簡單性偏好

推理（來源）：為了泛化，我們一路要求分類器簡單（正則化、剪枝）；簡單的假設不會花力氣照顧稀有案例，忽略 20 個點對整體代價影響微乎其微。SVM（本講義設計）：C 越大越不正則，召回：$C = 0.01$、0.1：0%；1：5.9%；10：13.2%；100：16.6%；準確率都約 98%。決策樹：每片葉至少 k 點（越大越簡單）：$k = 1$：召回 25.0%；5：20.1%；20：7.8%；50：0%。

圖說 `lec05-kp26-simple`：召回對 SVM 的 C 與樹的葉大小。



3. 難度與資料量

來源（Japkowicz）：大不平衡未必有害，要與任務難度、訓練點數一起看：簡單任務或資料量大時可能沒問題；困難（類別重疊）或點數不足時，小不平衡也可能致命。簡單任務（本講義設計，均值差 4，少數類召回）：100:100：97.4%；1000:100：91.6%；1000:10：65.3%；10000:100：78.2%；10000:10：43.3%。困難任務（均值差 1.5）：100:100：79.8%；1000:100：14.9%；1000:10、10000:100、10000:10：0%。少數類只有 10 點時，簡單任務也差。**常見迷思**：只要比例懸殊就一定失敗；比例不是唯一的因素。

圖說 `lec05-kp26-grid`：簡單與困難任務在五種比例下的少數類召回。

minority recall of an RBF SVM (balanced test set)

majority : minority	easy task	hard task
100 : 100	97.4%	79.8%
1000 : 100	91.6%	14.9%
1000 : 10	65.3%	0.0%
10000 : 100	78.2%	0.0%
10000 : 10	43.3%	0.0%

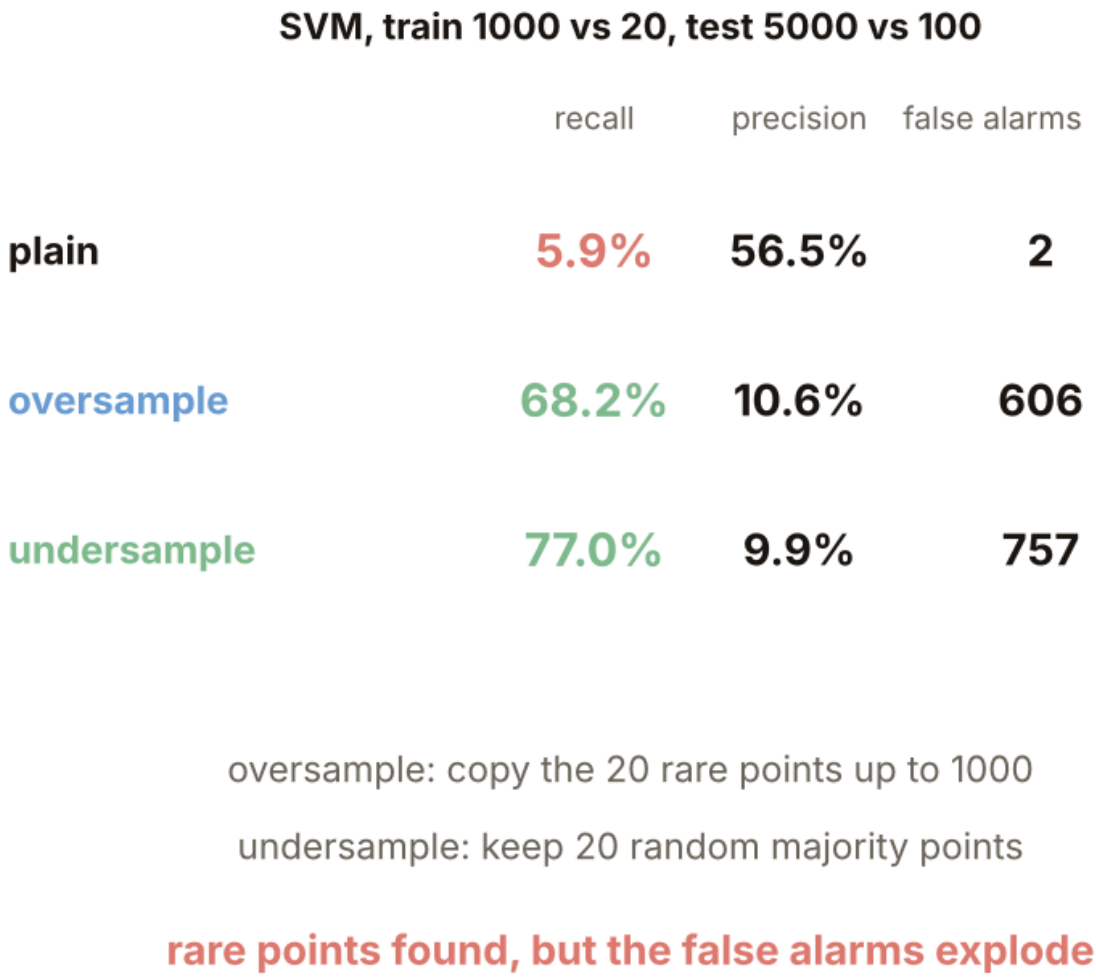
easy: class means 4 apart; hard: 1.5 apart (unit variance)

the count of rare points matters as much as the ratio

4. 改資料

做法：過採樣把 20 個少數點複製到 1000 個；欠採樣隨機只留 20 個多數點；同一個 SVM。結果（召回／精確率／誤報）：一般 5.9%／56.5%／2；過採樣 68.2%／10.6%／606；欠採樣 77.0%／9.9%／757。少數類找回來了，但精確率掉到約 10%，準確率掉到 85% 到 88%。

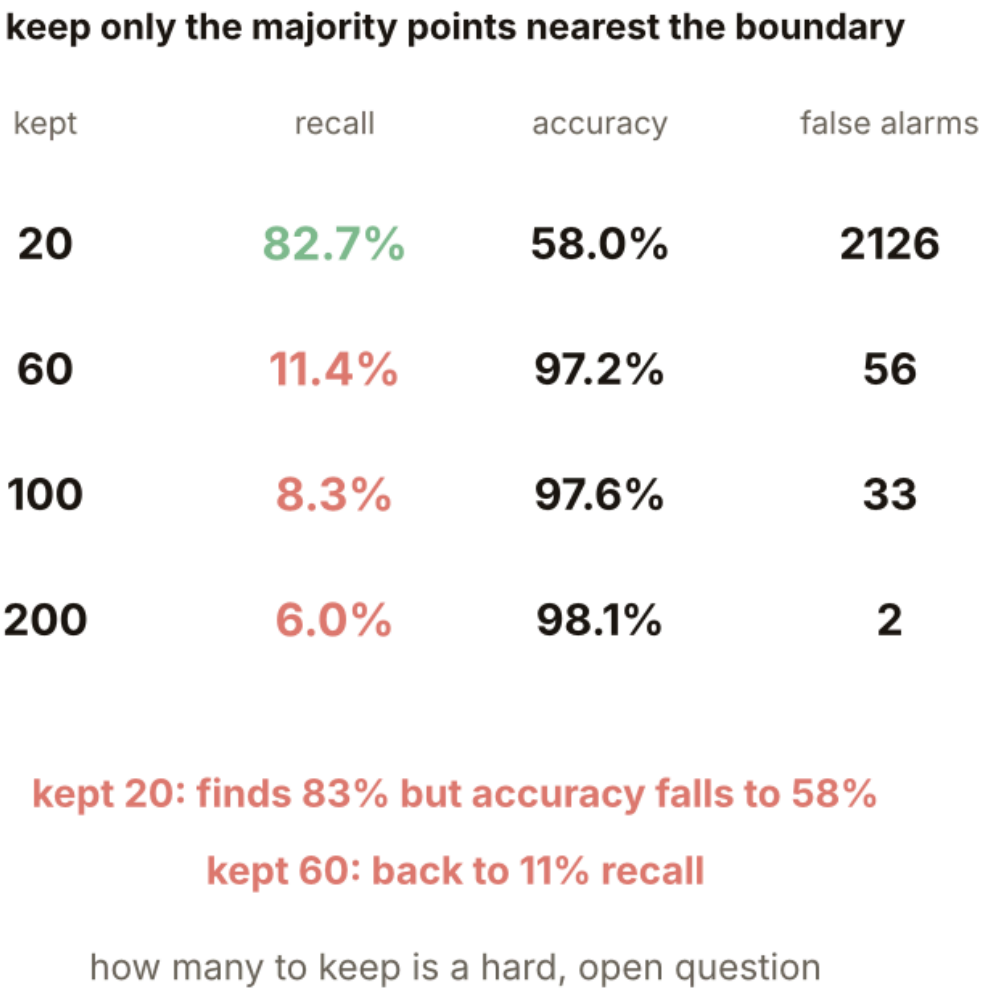
圖說 `lec05-kp26-data`：三種資料層處理的召回、精確率與誤報。



5. 聚焦重抽樣

聚焦欠採樣刪掉遠離邊界的點，聚焦過採樣針對邊界附近（來源）。本講義做法：先訓練一個 SVM，只留最靠近它的邊界的多數點。結果（本講義設計，召回／準確率）：留 20 個：82.7%／58.0%；60 個：11.4%／97.2%；100 個：8.3%／97.6%；200 個：6.0%／98.1%。目標分布調到多少才對是未解問題（來源）：留 20 與 60 個兩點相差極大（只測了這兩點）；留 20 個時誤報 2126 個，比隨機欠採樣的 757 個還多。

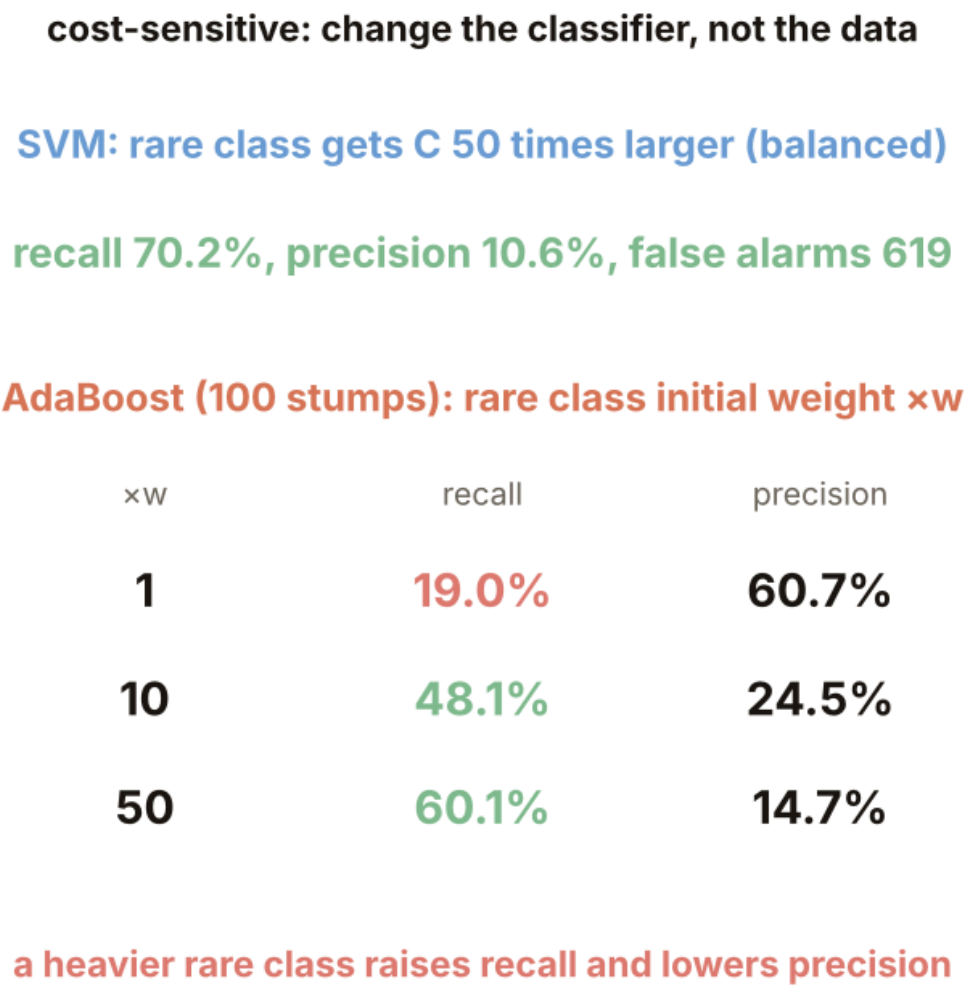
圖說 `lec05-kp26-focus`：聚焦欠採樣留下的多數點數與召回、準確率。



6. 改代價

做法（來源）：SVM 兩類用不同的 C，少數類較大（幾何上是以不同速率縮小凸包）；AdaBoost 迭代中給少數類較重的權重（KP25 的權重本來就為難樣本設計）。SVM（本講義設計）：少數類 C 設為多數類的 50 倍：召回 70.2%、精確率 10.6%、誤報 619、準確率 87.3%。AdaBoost（決策樁 100 個，少數類權重 ×1、×10、×50）：召回 19.0%、48.1%、60.1%；精確率 60.7%、24.5%、14.7%。

圖說 `lec05-kp26-cost`：代價敏感的 SVM 與 AdaBoost 結果。



7. 對策比較

SVM（召回／精確率／準確率）：一般 5.9%／56.5%／98.1%；過採樣 68.2%／10.6%／87.5%；欠採樣 77.0%／9.9%／84.7%；代價敏感 70.2%／10.6%／87.3%。決策樹（每片葉至少 5 點）：一般 21.0%／42.3%／97.9%；過採樣 33.8%／25.8%／96.7%；欠採樣 77.8%／9.2%／81.7%；代價敏感 43.2%／16.4%／94.4%。沒有哪個明顯贏；差別是取捨：要抓多少稀有類、能容忍多少誤報（單一資料設定，兩種分類器的細節不同；精確率為 20 次各自的平均）。

圖說 `lec05-kp26-table`：SVM 與決策樹四種處理的比較表。

	recall	precision	accuracy
SVM			
plain	**5.9%**	**56.5%**	**98.1%**
oversample	**68.2%**	**10.6%**	**87.5%**
undersample	**77.0%**	**9.9%**	**84.7%**
cost-sensitive	**70.2%**	**10.6%**	**87.3%**
decision tree (min 5 per leaf)			
plain	**21.0%**	**42.3%**	**97.9%**
oversample	**33.8%**	**25.8%**	**96.7%**
undersample	**77.8%**	**9.2%**	**81.7%**
cost-sensitive	**43.2%**	**16.4%**	**94.4%**

recall up, precision and accuracy down: no free lunch

8. 怎麼記

怎麼記（來源）：不平衡的傷害不是來自「數字不一樣」，而是來自「簡單性偏好 × 稀有類」的交互作用。對策兩條：改資料（重抽樣）或改代價（加權）。評估要看召回與精確率，不只看準確率；全判多數也有 98.0%。類別不平衡在實務上非常重要；設計者必須意識到它並警覺各種對策（來源）。

圖說 `lec05-kp26-recap`：類別不平衡的重點。

harm = simplicity preference × a rare class

not the difference in counts alone

two families of cures

change the data: over / under sampling

(random or focused near the boundary)

change the cost: heavier rare class

(SVM C, AdaBoost weights)

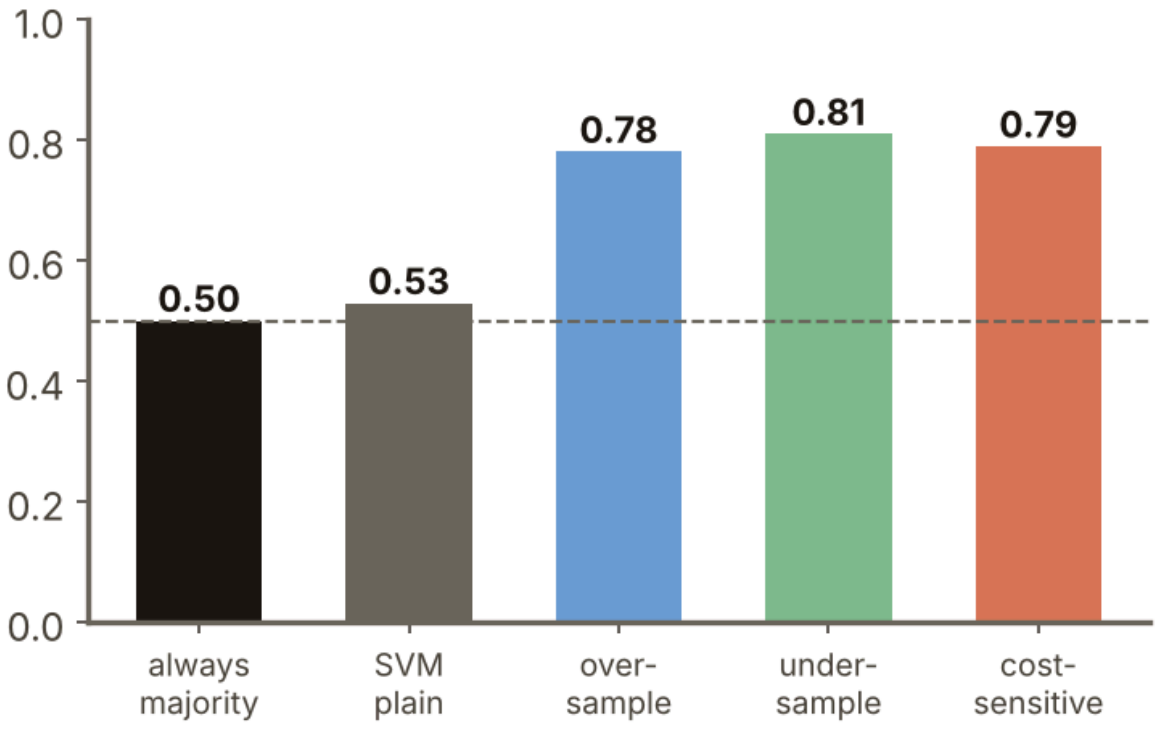
judge by recall and precision, not accuracy alone

the right class ratio is an open problem

延伸：平衡準確率、練習與解題示範

正式定義：平衡準確率 $=(\text{召回}+\text{特異度})/2$，特異度 $=\mathrm{TN}/(\mathrm{TN}+\mathrm{FP})$（TP、FN、FP、TN 為真陽、偽陰、誤報、真陰）。平衡準確率把兩類的召回一視同仁，是一種選擇，不看精確率。結果（SVM，同前面的設定）：全判多數 0.50；一般 0.53；過採樣 0.78；欠採樣 0.81；代價敏感 0.79。全判多數剛好 0.50，一般 SVM 只比它好一點；準確率卻是 98.0% 對 98.1%，把這個差別藏起來了。

圖說 `lec05-kp26-bal`：五種方法的平衡準確率。



小練習：1000 個負例、10 個正例（稀有類）。A：全判負；B：抓到 10 個正例中的 6 個，並誤報 40 個負例。

1. A 與 B 的準確率與召回各是多少？
2. A 與 B 的平衡準確率各是多少？

圖說 `lec05-kp26-practice`：練習的設定。

1000 negatives and 10 positives

A: says negative for everyone

B: catches 6 of the 10 positives, 40 false alarms

question 1: accuracy and recall of A and B

question 2: balanced accuracy of A and B

balanced accuracy = (recall + TN/(TN+FP)) / 2

題 1、2 解題示範：① A：TP 0、FN 10、FP 0、TN 1000；準確率 $1000/1010 = 0.990$、召回 0。B：TP 6、FN 4、FP 40、TN 960；準確率 $966/1010 = 0.956$、召回 0.6。② A：$(0 + 1)/2 = 0.5$；B：特異度 $960/1000 = 0.96$，$(0.6 + 0.96)/2 = 0.78$。③ 核對：A 的準確率比 B 高，卻一個稀有點也沒抓到；B 的精確率只有 $6/46 = 0.13$，這就是取捨。

圖說 `lec05-kp26-practice-sol`：計算過程。

A: TP 0, FN 10, FP 0, TN 1000

accuracy 1000/1010 = 0.990, recall 0, balanced 0.5

B: TP 6, FN 4, FP 40, TN 960

accuracy 966/1010 = 0.956, recall 0.6

specificity 960/1000 = 0.96, balanced 0.78

A has the higher accuracy and is useless

術語與來源

中文	English
類別不平衡	Class imbalance
召回率	Recall

來源：第四章 KP26，§4.23（2026-10-25 讀取）。類別不平衡損害分類器、傷害來自簡單性偏好與稀有類的交互作用、要與任務難度和資料量一起看、資料層與代價敏感兩類對策、聚焦重抽樣、目標分布是未解問題、「怎麼記」依來源；準確率陷阱、C 與葉大小掃描、難度與資料量表、各種對策的比較、平衡準確率與練習由本講義設計並重算（［補充］，（程式計算））。